RESEARCH REPORT · 2026 Q4

单细胞基础模型（scFM）发展调研报告

从「细胞语言模型」到「虚拟细胞世界模型」：起源、技术版图、产业生态与核心痛点

基于 2018–2026 年 10 月的论文、开源仓库、机构与公司公告的一手资料梳理

版本 **v1.0**　完成时间 **2026-10-21**　覆盖范围 **学术 · 开源 · 产业 · 监管**　引用 **40+ 一手来源**

390M 细胞
公开报道中最大单细胞预训练语料（CellOS，厂商口径）

12B 参数
公开报道中的参数天花板（CellOS，MoE，厂商口径）

1%–10%
预训练数据即达性能平台期（Nat Methods 2026）

4.2%
扰动数据中可检出真实基因交互的比例

说明：本报告区分「论文/官方数据」与「厂商宣称」。凡属后者，均在正文标注；未标注者默认可在参考文献中找到一手出处。报告不构成投资建议。

00 执行摘要：十个判断

如果用一句话概括：单细胞基础模型已经完成了「从 0 到 1」的范式验证，但尚未完成「从 1 到 10」的价值验证。它现在最大的问题不是模型不够大，而是**评测、数据与落地闭环**没有跟上。

1. 起源是两条曲线的交汇

一条是单细胞测序通量的指数增长（2009 年首篇 scRNA-seq，2015 年 Drop-seq/10x，2016 年人类细胞图谱启动）；另一条是 NLP 预训练范式的成熟（2018 年 BERT/GPT）。2018–2019 年的 scVI/scANVI 代表「统计生成」路线，2021 年的 scBERT 首次把 BERT 的「掩码—微调」范式搬到

2. 2023–2025 是「规模竞赛」

训练语料从 3,000 万（Geneformer）→ 5,000 万（scFoundation）→ 1 亿（CellFM）→ 1.12 亿（TranscriptFormer）→ 2.7 亿（State）→ 3.9 亿（CellOS，厂商口径）；参数量从 1,000 万 → 1 亿 → 8 亿 → 12B。但规模与能力并不线性相关。[2] [4] [6] [10] [11] [28]

转录组，2022–2023 年的 tGPT/scGPT 则把 GPT 的自回归范式引入。[1] [5]

3. 2025–2026 出现「能力转向」

研究重心从「细胞注释/嵌入」转向「扰动预测/虚拟细胞/世界模型」。标志性事件：Arc 的 State（2025-06）、Cell 的 AIVC 宣言（2024-12）、Arc 虚拟细胞挑战赛（2025）、CZI TranscriptFormer（2025）、以及 2026 年一批 diffusion/JEPA/flow-matching 模型。[11] [14] [12] [10] [27]

4. 评测危机是当前最大痛点

多项独立评测得出相似结论：zero-shot 的 scFM 往往不如 HVG、Harmony、逻辑回归等简单基线；不同评测之间排名不稳定；预训练/测试集重叠造成数据泄漏；指标（MSE/Pearson）与生物学相关性脱节。[16] [17] [18] [19] [21]

5. 数据比模型更硬

高质量**扰动数据**稀缺、批次效应与稀疏/丢零普遍、双细胞与环境 RNA 污染、公开数据重复计数、许可碎片化（Apache-2.0 / GPL / CC BY-NC-ND / 无 LICENSE 并存），共同构成比「参数量」更难的瓶颈。[1] [13] [15]

6. 架构共识尚未形成

BERT 式编码器、GPT 式解码器、encoder-decoder、RetNet、Mamba+Transformer、离散扩散、JEPA、flow matching 并存。基因没有自然顺序、细胞被当作独立样本、固定基因词表——这三个「原罪」仍未被普遍解决。[1] [6] [27] [29]

7. 产业「两头热、中间冷」

研究机构（Arc、CZI、Broad、Gladstone）、算力厂商（NVIDIA）与早期创业公司（Xaira、Tahoe、Noetik）很热；但真正把 scFM 嵌入药物研发决策链、形成「模型—湿实验—数据」闭环的案例仍然很少。[12] [13] [28]

8. 中国形成「一超多强」格局

清华张学工一系（scFoundation / scMulan / xTrimoGene）是学术源头；中山大学—华为—新格元（CellFM，8 亿参数/1 亿细胞）、阿里达摩院（Lingshu-Cell）、之江实验室—华大（scDiffformer）、同济（AlphaCell）、中科院（GeneCompass）构成多点突破；腾讯 scBERT 是最早的 BERT 路线但已停更。[5] [6] [7] [27] [30]

9. 「基础模型」之名尚未坐实

更准确的说法是「大规模预训练表征模型」：它在微调、特征提取、域内/近域任务上确有价值；但 zero-shot 通用性、跨数据集稳健性、稀有细胞可靠性都还没有被严格证明。[16] [19] [22]

10. 下一个分水岭是「数据闭环」

谁能持续产生高质量扰动数据、并把湿实验验证接回训练回路，谁就有机会重新点燃 scaling law。纯靠爬取公开 atlas 的路线，已经接近天花板。[11] [13] [15]

◆ 阅读指引

第 1–2 章回答「它是什么、从哪来」；第 3–4 章给出技术分类与 20 个代表模型的全景表；第 5–6 章梳理 2024–2026 的五个重点方向与产业生态；第 7–8 章是报告的核心——把「痛点」拆成可验证的九类问题，并呈现正反双方证据；第 9–10 章给出趋势判断与选型建议。

01 什么是单细胞基础模型

单细胞基础模型（single-cell foundation model, scFM）是指：在千万到亿级单细胞组学数据上，以自监督方式预训练、可迁移到多种下游任务的深度神经网络。它的核心隐喻是「细胞即句子，基因即词」。

1.1 一个四段式范式

① tokenization

把每个细胞的稀疏表达向量变成 token 序列：**基因排名**（Geneformer）、**表达值分箱**（scBERT）、**连续值投影**（scFoundation）、**基因名文本**（Cell2Sentence / GenePT）、**表达感知注意力**（TranscriptFormer）。

② pretraining

自监督目标：**掩码基因预测**（BERT 式）、**自回归下一基因**（GPT 式）、**对比学习**、**去噪/重建**、**多任务**（表达值+元数据+扰动）。

③ adaptation

全量微调、**LoRA**、冻结主干+线性探针、持续预训练、上下文学习/提示。算力从单卡到多机不等。

④ deployment

三类输出：**细胞嵌入**（聚类/注释/检索）、**基因嵌入与注意力**（GRN/基因功能）、**生成谱**（扰动/药物响应/虚拟细胞）。

⑤ 下游任务

细胞类型注释、批次整合、多模态整合、缺失表达补全、基因功能预测、GRN 推断、扰动预测、空间反卷积、虚拟细胞模拟。

⑥ 评价

零样本 / 微调 / 少样本；准确性、生物学保守性、批次去除、效率、稳定性、可解释性——目前尚无统一标准。

1.2 它与「专用工具」的区别

传统工具（Seurat、Scanpy、Harmony、scVI、CellTypist）是**任务专用**的：每个任务一个模型、一个假设。scFM 的承诺是**一个主干、多种任务**：预训练学到「基因共表达语法」，再通过微调或提示迁移到新任务。这个承诺在 2023–2024 年被广泛接受，但在 2025–2026 年受到系统性质疑（见第 7–8 章）。

概念辨析

基础模型 ≠ 大语言模型。多数 scFM 只是借用了 Transformer 架构与自监督目标，并不具备自然语言模型的指令遵循、推理与对话能力。2025 年后出现的 CellWhisperer、CellHermes 等「细胞语言模型」才尝试把转录组翻译成文本、再用 LLM 做推理，但这类路线目前仍是少数。[26] [29]

02 起源与演进：一条时间线

单细胞基础模型不是某一天突然出现的。它经历了「统计生成 → 语言模型迁移 → 规模竞赛 → 虚拟细胞」四个阶段，每个阶段都对应一次对「细胞数据像什么」的重新理解。

2.1 前史：数据爆炸与统计生成模型（2009–2020）

2009 年 Tang 等发表首篇单细胞转录组测序；2015 年 Drop-seq 与 inDrop 把通量提高两个数量级；2016 年 10x Genomics 商业化、人类细胞图谱（HCA）启动。[34] 数据从「几百个细胞」变成「百万级细胞」，传统聚类与差异表达方法开始失效。

2018 年，Lopez 等提出 **scVI**——用变分自编码器（VAE）对 scRNA-seq 计数建模，第一次把「深度生成模型」用于单细胞。2019 年的 **scANVI** 加入标签信息，**scGen** 尝试用隐空间向量算术预测扰动响应。这一路线今天仍是最强的基线之一：2025 年的零样本评测显示，scGPT 的中位 ASW（0.53）与 scVI（0.54）几乎持平。[17]

2.2 语言模型的迁移（2018–2023）

「基础模型（foundation model）」一词在 2021 年由 Stanford CRFM 系统化定义为「在大规模数据上预训练、可适配广泛下游任务」的模型。[47] 在此之前，2018 年 BERT 与 GPT 的相继发布，已经把「预训练—微调」变成 NLP 的标准流程。研究者很快意识到：细胞的基因表达向量与句子的词向量在结构上有相似性——都是高维、稀疏、有上下文依赖的序列。于是出现了三条迁移路径：

- **BERT 式（掩码预测）**：2021 年 12 月，腾讯 AI Lab 的 **scBERT** 预印本发布，用 Performer 架构在 PanglaoDB（约 110 万细胞、209 个数据集）上做掩码基因预测，再微调到细胞注释。这是第一个明确以「单细胞 BERT」为名的模型。[5]
- **GPT 式（自回归）**：2022 年的 **tGPT** 把「细胞」当作 token、把「细胞序列」当作句子，用 2,200 万细胞训练；2023 年的 **scGPT** 则把基因当 token、用掩码自注意力做生成式预训练，训练语料 3,300 万细胞。[3]
- **排名式（rank tokenization）**：2022 年预印本、2023 年发表于 Nature 的 **Geneformer**，按表达量把每个细胞的基因排序、取前 2,048 个基因作为序列，用 6 层 BERT 在 Genecorpus-30M（约 3,000 万细胞）上预训练。它的重要性在于证明了「迁移学习」在数据稀缺的网络生物学任务上有效。[2]

> **◆ 为什么是 2021–2023**
>
> 三个条件同时成熟：① 公开单细胞数据达到千万级（CELLxGENE、HCA、GEO）；② Transformer 与自监督训练 recipe 开源；③ GPU 算力可负担（数天到数周、4–12 张 A100/H100 即可训练数千万到一亿参数的模型）。[1]

2.3 规模竞赛（2023–2025）

2023 年之后，论文的主线变成「更大的数据 + 更大的参数」：

- **scFoundation**（2024，Nature Methods）：5,000 万人类细胞、1 亿参数、19,264 个基因，非对称 encoder-decoder，报告了参数/FLOPs 与重建 loss 的幂律关系。[4]
- **GeneCompass**（2024，Cell Research）：1.2 亿人+鼠细胞（质控后 1.0177 亿），12 层/12 头/768 维、约 1 亿参数，注入启动子、基因共表达、TF 调控等四类先验知识。[7]
- **UCE**（2023 预印本，2026 Nature）：3,600 万细胞、8 个物种、33 层/6.5 亿参数，主打「零样本通用嵌入」，可嵌入训练时未见的物种。[8]
- **CellFM**（2025，Nature Communications）：1 亿人类细胞、8 亿参数，基于 RetNet，在华为 MindSpore + 32 张昇腾 910 上训练。[6]
- **TranscriptFormer**（2025，CZI）：1.12 亿细胞、12 个物种、跨度 15.3 亿年进化，368–542 M 参数，MIT 许可。[10]
- **State**（2025，Arc Institute）：约 1.7 亿观测细胞 + 1 亿扰动细胞，SE+ST 双模块，主打扰动响应预测。[11]

2.4 虚拟细胞转向（2024–2026）

2024 年 12 月，Stanford、Genentech 与 CZI 在 *Cell* 发表《How to build the virtual cell with artificial intelligence》，正式提出「AI 虚拟细胞（AIVC）」的路线图：通用表征、跨物种、可预测动力学、可在计算机上做实验。[14] 此后，领域的关键词从「annotation」变成「perturbation」「virtual cell」「world model」。

2009 **首篇单细胞转录组测序**

Tang 等，单细胞进入组学时代。

2015–2016 **通量革命与数据基础设施**

Drop-seq / inDrop / 10x Genomics；人类细胞图谱（HCA）启动。 数据层

2018 **scVI：深度生成模型进入单细胞**

VAE 对计数建模，成为此后所有评测的「强基线」。 统计生成

2021.12 **scBERT：第一个「单细胞 BERT」**

腾讯 AI Lab，PanglaoDB 约 110 万细胞，Performer + 掩码基因预测。 语言模型迁移

2022 **tGPT 与 Geneformer 预印本**

tGPT 把细胞当 token；Geneformer 用排名序列 + BERT，证明迁移学习在网络生物学有效。 两条路线

2023 **Geneformer 登上 Nature；scGPT 预印本**

「细胞语言模型」成为显学；CELLxGENE 等公开语料快速扩张。 范式确立

2024 **scFoundation / GeneCompass / scGPT 正式发表**

数据规模进入 5,000 万–1.2 亿；参数进入 1 亿级；多模态与跨物种出现。 规模竞赛

2024.12 **Cell：AI 虚拟细胞宣言**

Stanford + Genentech + CZI 提出 AIVC 三阶段目标与全球协作倡议。 范式转向

2025.02 **Tahoe-100M 开源**

1 亿细胞、6 万药物—细胞相互作用、50 个癌细胞系 × 1,200 种药物；Arc 虚拟细胞图谱首发的 3 亿细胞之一。 扰动数据

2025.05 **CellFM：8 亿参数、1 亿细胞**

中山大学 + 华为 + 新格元，MindSpore/昇腾，国产算力路线。 中国

2025.06 **State：Arc 的首个虚拟细胞模型**

1.7 亿观测 + 1 亿扰动细胞；Tahoe-100M 上扰动区分度提升（博客 50%，论文摘要 30%+）、DEG 准确率翻倍；2026-08 正式发表于 *Cell*。 虚拟细胞

2025.12 **首届 Virtual Cell Challenge 收官**

5,000+ 注册、1,200+ 队伍、300+ 最终提交；结论：扰动预测模型「尚未在所有指标上稳定超过朴素基线」。 评测

2026.06 **Nature Methods：数据规模出现平台期**

2,220 万细胞、400 个模型、6,400 次实验；性能在 1%–10% 数据即饱和，单细胞领域「没有清晰的数据 scaling law」。 反思

2026.07–09 **世界模型与扩散模型登场**

阿里达摩院 Lingshu-Cell（离散扩散）、同济 AlphaCell（Mamba+Transformer+OT-CFM）、百曜 CellOS（JEPA+MoE，12B，厂商口径）、之江—华大 scDifformer（扩散后训练）。 新架构

03 技术版图：四把尺子看懂一个 scFM

面对一个 scFM，最有效的提问顺序是：它把什么当成 token？用什么目标预训练？吃什么模态？最终输出什么？这四个问题基本决定了它的能力边界。

3.1 按架构：五种主流路线

A. Encoder-only（BERT 式）

双向注意力 + 掩码基因预测。代表：**scBERT**、**Geneformer**、**GeneCompass**、**UCE**、**SCimilarity**。优点是嵌入质量高、适合分类/检索/注释；缺点是不能直接生成表达谱。

B. Decoder-only（GPT / 自回归）

单向注意力 + 下一 token 预测。代表：**tGPT**、**scGPT**、**TranscriptFormer**。优点是天然支持生成与扰动模拟；缺点是基因顺序被人为强加，且推理成本随基因数增长。

C. Encoder–decoder / 非对称

编码器压缩、解码器重建，常用「表达值 + 基因身份」双通道。代表：**scFoundation**（19,264 基

D. 非 Transformer 主干

CellFM 用 RetNet（线性注意力，长序列更省算力）；**AlphaCell** 用 Mamba + Transformer 混合；

因、1 亿参数）、**CellPLM**。适合补全、去噪、跨平台迁移。

Geneformer V2 把上下文从 2,048 扩到 4,096。方向都是「比 Transformer 更适合高维稀疏表」。

E. 扩散 / 流匹配 / JEPA

Lingshu-Cell（掩码离散扩散）、**scDifformer**（扩散后训练）、**AlphaCell**（OT-CFM 流匹配）、**CellOS**（JEPA 联合嵌入预测）。它们不再「复述输入」，而是在隐空间或概率路径上建模状态转移——这是 2026 年最值得关注的架构变化。

F. 文本桥接（LLM 路线）

Cell2Sentence 把细胞转成基因名序列微调 GPT-2；**GenePT** 直接用 GPT-3.5 生成基因嵌入；**CellWhisperer / CellHermes** 用自然语言做零样本注释与推理。优势是冷启动与可解释性，劣势是表达值精度。[35] [36]

3.2 按 tokenization：这是最被低估的设计选择

腾讯 Jarvis Lab 的 ACL 2025 综述把单细胞基础语言模型拆成「tokenization—预训练/调优范式—下游任务」三层，其中 tokenization 直接决定了模型能保留多少定量信息、能覆盖多少基因。[31]

策略	做法	代表模型	优点	代价
排名（rank）	按表达量排序，取 top-k 基因	Geneformer、scGPT（部分）	对测序深度与批次更稳健；序列短	丢失绝对表达量；低表达关键基因被截断
分箱（binning）	把连续表达值离散成若干 bin	scBERT	实现简单、可复用分类头	bin 边界敏感；稀疏零值信息损失
连续投影	用线性层直接映射表达值	scFoundation、CellPLM	保留定量信息；适合重建	对噪声与批次更敏感
基因名文本	把基因符号当词、细胞当句	Cell2Sentence、GenePT	可复用 LLM 语义先验；零样本强	表达值精度低；依赖基因命名规范
表达感知注意力	把 log-count 作为注意力 bias	TranscriptFormer	不复制 token、保留计数；跨物种	实现复杂；对超参敏感
细胞为 token	细胞是词、组织是句	tGPT、CellPLM	显式建模细胞间关系；速度快	单细胞分辨率下降；依赖空间/邻接信息

3.3 按模态：从单一转录组走向「多组学 + 空间」

- **RNA-only**：绝大多数模型（Geneformer、scGPT、scFoundation、CellFM、GeneCompass）。
- **RNA + ATAC**：scGPT 的多组学版本、CellPLM 的多模态扩展。
- **RNA + 蛋白**：**CAPTAIN**（2026，Nature Communications）在 co-assayed CITE-seq 上预训练，是「蛋白模态」的代表。[26]
- **RNA + 空间**：**Nicheformer**（Nature Methods 2025）、**scGPT-spatial**、**Novae**；2026 年的统一评测显示，空间/图模型在保留组织结构上更好，但在纯细胞身份任务上不如表达模型。[24] [37]

- **跨物种**：UCE（8 物种）、TranscriptFormer（12 物种、15.3 亿年进化）、GeneCompass（人+鼠）。

值得注意的一个趋势是「生物语言模型」的合流：TranscriptFormer 用 ESM-2 的蛋白嵌入作为基因表征；DNA 语言模型（如华大 Genos）为调控序列提供先验；单细胞模型则提供细胞状态与扰动响应。未来的 scFM 很可能不是「单细胞专用」，而是**蛋白**—**基因组**—**转录组**—**空间**多语言模型的联合体。[10] [40]

3.4 按目标：从「表征」到「生成」再到「模拟」

表征型（representation）

输出细胞/基因嵌入，服务聚类、注释、检索。**UCE、SCimilarity、Geneformer**。评测相对成熟，价值最确定。

生成型（generative）

重建或生成表达谱，服务去噪、补全、跨平台。**scFoundation、scMulan、Lingshu-Cell**。指标与生物学一致性争议最大。

模拟型（simulation）

给定起始状态与扰动，预测状态转移。**State、AlphaCell、CellOS、GEARS**。最接近「虚拟细胞」，也最难验证。

04 模型全景：20 个代表与两条规模曲线

下表按「首次公开时间」排序，只收录有论文、预印本或官方模型卡可查的模型。不同论文的细胞计数口径（是否去重、是否含鼠/多物种、是否质控后）差异很大，跨行比较时请把它们当作数量级而非精确值。

模型	时间	牵头机构	预训练语料	参数	架构 / 目标	模态	许可
scBERT	2021.12 NMI 2022	腾讯 AI Lab	~110 万 PanglaoDB，209 数据集	未公开	BERT / Performer，掩码基因	RNA	GPL-3.0
tGPT	2022	同济大学等	~2,200 万	未公开	GPT，细胞为 token	RNA	开源
Geneformer	2022 Nature 2023	Gladstone / UCSF	3,000 万 Genecorpus-30M	10.3M / 106M	BERT，rank token；V2 语料 95M（当前 checkpoint 23M）、4,096 上下文	RNA	开源*
scGPT	2023 Nat Methods 2024	多伦多大学 / Vector	3,300 万	53M	GPT 式掩码自注意力，生成式；12 层/512 维	RNA + ATAC	MIT

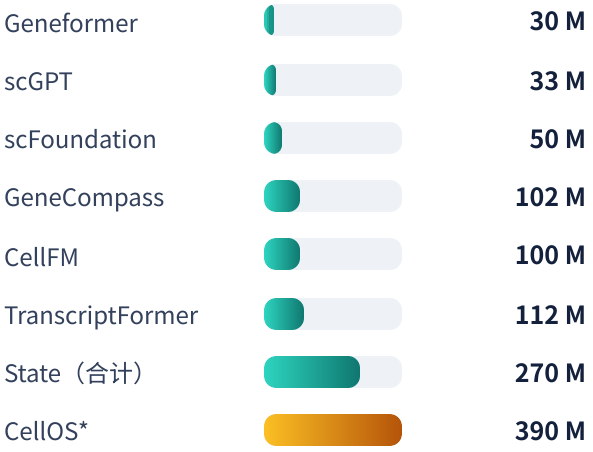
模型	时间	牵头机构	预训练语料	参数	架构 / 目标	模态	许可
scFoundation	2023.05 Nat Methods 2024	清华大学 + 百图生科	5,000 万	100M	非对称 encoder–decoder；19,264 基因	RNA	Apache-2.0
xTrimoGene	2023.11 NeurIPS 2023	百图生科 + 清华	>5,000 万	未公开	非对称，面向扰动与药敏	RNA	API
CellPLM	2024 ICLR 2024	密歇根州立等	未公开	未公开	细胞为 token；空间转录组预训练	RNA + 空间	开源
GeneCompass	2024.10 Cell Research	中科院动物所/计算所等	1.0177 亿 人 + 鼠，质控后	~100M	BERT + 四类生物先验知识	RNA	无 LICENSE
scMulan	2024.01 bioRxiv v2	清华大学	~1 亿等效	368M	生成式，多任务属性预测	RNA	CC BY-NC-ND
SCimilarity	2024.11 Nature 638	Genentech	2,340 万 412 项研究	未公开	度量学习，跨研究细胞检索	RNA	开源
UCE	2023 Nature 2026	Stanford	3,600 万 8 物种，300+ 数据集	650M	33 层，零样本通用嵌入	RNA	开源
State	2025.06 Cell 2026	Arc Institute	1.7 亿观测 + 1 亿扰动	未公开	SE + ST 双模块；集合注意力	RNA + 扰动	非商用
TranscriptFormer	2025.04 Science 2026	CZI	1.12 亿 12 物种	368–542M	自回归 + 表达感知注意力；ESM-2 基因嵌入	RNA	MIT
Nicheformer	2024 Nat Methods 2025	Helmholtz Munich	未公开	未公开	单细胞 + 空间联合预训练	RNA + 空间	开源
CellFM	2025.05 Nat Commun	中山大学 + 华为 + 新格元	1 亿人类细胞	800M	RetNet；MindSpore + 昇腾	RNA	Other
CAPTAIN	2026.05 Nat Commun	湖南大学等	未公开	未公开	多模态联合预训练	RNA + 蛋白	见论文
scDiffformer	2026.07 NAR	之江实验室 + 华大研究院	未公开	未公开	预训练 + 扩散后训练 + 微调	RNA + 空间	CC BY-NC
Lingshu-Cell	2026.08	阿里达摩院	未公开	未公开	掩码离散扩散；18,000 基因	RNA	预印本
AlphaCell	2026.03	同济大学 DELTA Lab	未公开	1.2B 解码器	Mamba + Transformer + OT-CFM 流匹配	RNA	预印本
CellOS	2026.07	百曜科技	3.905 亿 47,845 样本；厂商口径	12B MoE	LLM-JEPA 双视角 + Dense-to-MoE	RNA	未开源

* Geneformer 的代码与权重许可在不同版本/仓库中不完全一致，商用前需逐一核对；「开源」仅表示代码可见，不代表可自由商用。未公开项以「未公开」标注，未做推测。

训练语料规模（百万细胞）

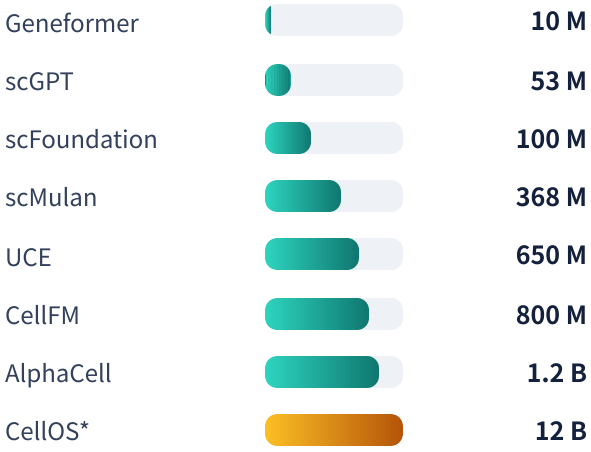
参数量级（对数视角）

不同论文的去重与质控口径不同，仅作数量级对比



* 厂商口径。State 为 1.7 亿观测 + 1 亿扰动之和。

从 1,000 万到 120 亿，跨度约三个数量级



* 厂商口径，MoE 稀疏激活；与稠密模型不可直接比较。

△ 数字陷阱

「最大」是一个高频营销词。2025 年 CellFM 自称「比同代单物种模型大约 8 倍」；2026 年 CellOS 自称「公开报道中参数规模最大的单细胞基础模型」。二者都缺少独立第三方复核，且训练数据、评测集、任务定义均不同。看到「最大」时，先问三个问题：**和谁比？用什么任务比？数据有没有泄漏？**

4.1 三个「不是最大但很重要」的模型

SCimilarity

2024

Genentech

不做生成，只做「细胞检索」：把 2,340 万细胞映射到统一空间，输入一个细胞就能找到全身相似的细胞状态。它的价值在于把 scFM 变成**可查询的数据库**，并用湿实验验证了体外命中。

度量学习 · 23.4M 细胞 · Nature

State

2025

Arc Institute

第一个把「扰动数据」放在中心位置的模型：SE 学嵌入、ST 学状态转移。它明确说「测序数据只能看到相关，扰动数据才能看到因果」，这是虚拟细胞路线的方法论宣言。

SE + ST · 270M 细胞 · 非商用

TranscriptFormer

2025

CZI

用 12 个物种、15.3 亿年进化跨度训练，证明「跨物种通用表征」可行；MIT 许可 + 模型卡齐全，是目前工程可用性最好的跨物种模型之一。

112M 细胞 12 物种 MIT

05 2024–2026 的五个重点方向

如果把 2023 年定义为「scFM 元年」，那么 2024–2026 的主线不是「再做一个更大的模型」，而是把模型推向更难的生物学问题，并反过来暴露了评测与数据的短板。

5.1 规模化与数据工程：从「堆数据」到「选数据」

2023–2024 的默认假设是「数据越多越好」。2026 年 6 月 *Nature Methods* 的一项系统研究打破了它：作者用 2,220 万细胞训练了 400 个模型、做了 6,400 次实验，发现性能在只用 **1%–10%** 预训练数据时就进入平台期；在某些任务上，简单基线（HVG、Harmony）与复杂 transformer 表现相当甚至更好；单细胞领域**没有清晰的数据 scaling law**。[15]

这与「数据质量/多样性比数量更重要」的判断一致：去重、去批次、去低质量细胞、平衡细胞类型分布，比再加一亿个同质细胞更有价值。Arc 的 scBaseCount 用 AI agent 统一清洗 2 亿细胞，正是这条思路的基础设施化。[13]

5.2 扰动预测与虚拟细胞：从「描述」到「干预」

这是目前最热、也最难的方向。核心问题是：给定起始细胞状态和一个扰动（基因敲除、药物、细胞因子），能否预测全转录组的响应？

- **State**（Arc，2025）：在 Tahoe-100M 上，Arc 博客称扰动区分度提升 50%、差异表达基因识别准确率翻倍；2026-08 正式发表于 *Cell* 的论文摘要则表述为「效应区分度提升超过 30%」。两个数字口径不同，引用时应以论文为准。Arc 称这是「第一个稳定超过线性基线的模型」。[11] [41]
- **Virtual Cell Challenge 2025**：H1 胚胎干细胞、300 个 CRISPRi 扰动、约 30 万细胞。最终结论相当克制：「扰动预测模型尚未在所有指标上稳定超过朴素基线」；几乎所有模型在 MAE 上都不如基线；获胜方案都是「深度学习 + 经典统计特征」的混合体。冠军是百图生科（BioMap Research）的 xTrimoSCPerturb，它基于改进的 scFoundation 架构，并显式加入训练集 DEG 频率与平均表达作为特征。[12]
- **2026 的新玩家**：Lingshu-Cell（阿里达摩院，离散扩散，VCC H1 基准领先）、AlphaCell（同济，流匹配 + 世界模型）、CellOS（百曜，JEPA + 12B MoE）。它们共同的关键词是「状态转移」而不是「表达重建」。[27] [29] [28]

▲ 一个残酷的对照

EMBL 团队在 Norman 双扰动数据上比较了 5 个基础模型 + 2 个深度学习模型与线性基线：**所有模型的误差都高于 additive 基线**，交互预测没有一个优于「预测无变化」；在 FDR 5% 下，124,000 个基因对里只有 5,035 个（4.2%）是真实交互。换句话说，大部分「扰动预测」的可用信号极其稀疏。[18]

5.3 多模态与空间：从「一维转录组」到「组织上下文」

单细胞数据丢失了空间位置，而空间数据又往往分辨率不足。2025–2026 年的解法是「联合预训练」：Nicheformer 把单细胞与空间数据放在一起；CellPLM 把细胞当 token、组织当句子；scGPT-spatial 把空间邻域纳入注意力；CAPTAIN 把 RNA 与蛋白放在同一个框架里。[37] [24] [26]

但 2026 年 7 月的统一评测给这股热潮泼了冷水：在 6 个代表性模型（Nicheformer、CellPLM、scGPT-spatial、GenePT、scELMo、Novae）上，**没有模型在所有任务上领先**；排名会随模态、预处理、tokenization、生物先验、域偏移和指标而变化。空间/图模型更擅长保留组织结构，表达模型更擅长细胞身份，语言衍生嵌入在某些扰动指标上有竞争力。[24]

5.4 跨物种与通用嵌入：一个「零样本」的例外

在大量负面评测中，跨物种通用嵌入是一个相对正面的例外。UCE 在 8 个物种、3,600 万细胞上训练，能嵌入训练时没见过的物种，并且零样本识别发育谱系；TranscriptFormer 用 12 个物种、15.3 亿年进化跨度，展示了跨物种细胞类型分类与疾病状态识别。[8] [10]

这类模型的价值不在「替代专用工具」，而在「把不同物种、不同平台、不同实验室的数据放进同一个坐标系」——这是比较生物学、跨物种药物毒理、以及数据稀缺物种研究的基础设施。

5.5 评测与基准：从「各自报喜」到「公共考场」

2024 年之前，每个模型论文都用自己的任务和数据集；2025 年之后，公共评测开始出现：

- **scEval**（耶鲁，Adv Sci 2026）：8 类任务、10 个 scFM，结论是「没有任何模型在所有任务上稳定优于专用方法」。
- **Cell_Eval**（Arc）：针对虚拟细胞的 7 项指标，强调差异表达与扰动强度，而不只是 MSE。
- **PertEval-scFM**（ICML 2025）：标准化扰动预测评测，结论是零样本嵌入相对简单基线「提升有限」。
- **SCMBench**（Nat Commun 2026）：23 种多组学整合方法，结论是「基础模型在多组学整合上不如领域专用模型」，并提出轻量适配策略。
- **VCC**（Arc，2025 起）：把「能否替代一次 Perturb-seq 实验」作为终极问题，用 H1 细胞系制造分布偏移。[16] [12] [22] [25]

5.6 新架构：扩散、JEPA、流匹配与「世界模型」

2026 年最值得注意的变化是：一批模型不再做「掩码—重建」，而是直接建模**状态分布与状态转移**。

离散扩散：Lingshu-Cell

阿里达摩院，2026-08。把转录组当成离散 token，用掩码离散扩散学习状态分布；不依赖 HVG 预选，覆盖约 18,000 个基因；支持「细胞类型/供体 × 扰动」的条件生成，在 VCC H1 基准与 PBMC 细胞因子响应上领先。[27]

JEPA：CellOS

百曜科技，2026-07。用「表达视角 + 群体感知视角」做联合嵌入预测，在隐空间对齐两种观测，而不是复述输入；Dense-to-MoE 扩容到 12B。厂商称在 Pearson_edist 上 0.619，对比 TranscriptFormer 0.373。**这些数字尚未经独立复现。**[28]

流匹配 + 世界模型：AlphaCell

同济 DELTA Lab，2026-03。19,253 个 HGNC 基因全量输入，Mamba+Transformer 压到 32×128 连续隐流形，再用 OT-CFM 建模扰动后的状态演化；1.2B MoE 解码器保证「隐空间任意点都能翻回真实表达谱」。[29]

扩散后训练：scDifformer

之江实验室 + 华大研究院，NAR 2026。提出「预训练—扩散后训练—微调」三步范式，把扩散模型作为后训练阶段来增强生成与空间反卷积能力。这是「不换主干、只换后训练」的务实路线。[30]

06 产业生态：谁在造模型，谁在造数据，谁在买单

单细胞基础模型不是一条独立的赛道，它嵌在「测序仪器—数据平台—模型—湿实验—药企」的五层结构里。越往上，玩家越少，越往下，越依赖规模效应。

6.1 五层结构

层级	核心能力	代表玩家	商业模式
① **测序与扰动数据生产**	高通量 scRNA-seq、Perturb-seq、药物筛选	10x Genomics、Parse Biosciences、Ultima Genomics、Tahoe、Arc、华大（Stereo-cell）	仪器/试剂、数据授权、服务
② **数据平台与图谱**	数据聚合、标准化、可查询	CZI（CELLxGENE）、Arc（Virtual Cell Atlas）、HCA、华大（10 Billion Cells Alliance）	公共品/联盟、云服务
③ **基础模型与工具**	预训练、微调、嵌入、生成	Arc、CZI、Gladstone、清华/BioMap、中山大学/华为、阿里达摩院、之江/华大	开源 + API、许可、联合研发
④ **垂直应用**	靶点发现、药敏预测、毒性评估、细胞治疗	Genentech/Roche、Recursion、Insitro、Xaira、Noetik、百曜	管线、平台合作、里程碑付款

层级	核心能力	代表玩家	商业模式
⑤ **算力与框架**	GPU、训练框架、推理优化	NVIDIA（BioNeMo）、华为（MindSpore/昇腾）、云厂商	硬件、云、软件订阅

6.2 海外：三家「公共品」机构定义了游戏规则

Arc Institute

2022–

非营利研究机构 · 美国

用「数据 + 模型 + 评测 + 竞赛」四件套建立生态：Tahoe-100M（1 亿细胞扰动数据）、scBaseCount（2 亿细胞 AI 清洗）、State（虚拟细胞模型，2026-08 正式发表于 *Cell*）、Cell_Eval、VCC。2026 年又推出 Stack（in-context learning，无需微调）与 Bolero（细胞状态条件化的调控序列模型），并获 The Audacious Project 支持「10 亿级细胞实验」。它的策略不是卖模型，而是**定义标准和公共数据**。[11] [41]

State　Stack　Tahoe-100M　VCC

CZI / Biohub

2016–

慈善基金会 · 美国

CELLxGENE 是全球最常用的单细胞数据门户；TranscriptFormer 是跨物种生成模型（2026-07 正式发表于 *Science*）；Virtual Cells Platform 提供模型、基准、数据与 CLI。2025-10 与 NVIDIA 扩大合作，把数据扩到 PB 级，并把 cz-benchmarks、CodonFM 等接入平台。CZI 的定位是**开放科学基础设施**，而非商业模型供应商。[32] [42]

CELLxGENE　TranscriptFormer　VCP

Genentech / Roche

2024–

药企 · 瑞士/美国

AIVC 宣言的共同作者；SCimilarity（*Nature* 638:1085–1094）让「细胞检索」进入药物发现流程；BRAID 部门把基础模型与 Perturb-seq、cell painting、optical pooled screen 绑定。这是**「药企自建模型」**路线的代表，但目前公开的落地仍以「模型提假设 + 湿实验验证」为主。[9] [43]

SCimilarity　AIVC　BRAID

6.3 大厂：算力与框架比模型更早赚钱

- **NVIDIA**：BioNeMo 框架已收录 Geneformer（10M/106M 检查点）及训练/推理 recipe；官方文档中**未找到 scGPT 条目**，因此「BioNeMo 支持 scGPT」一说暂无一手依据。对 NVIDIA 而言，scFM 是 GPU 与生物计算平台的重要应用场景。[33]
- **Google**：2025-10 与耶鲁发布 **C2S-Scale 27B**（基于 Gemma），在「免疫背景阳性/中性」双情境下模拟 4,000+ 药物，预测 CK2 抑制剂 silmitasertib + 干扰素可增强抗原呈递，并完成活细胞验证。这是目前少数具备「模型—湿实验」闭环的公开案例。[44]
- **Microsoft Research**：不是模型卖方，而是「裁判」——2025 年的零样本评测（Kedzierska 等）与 2026 年的数据规模研究（DenAdel 等）都出自 MSR，直接改变了领域的叙事。[17] [15]

- **Meta / Amazon**：在单细胞基础模型上没有公开的旗舰产品；贡献主要在通用模型、云平台与开源工具层。Google 的 AlphaGenome 属于基因组调控，不是单细胞表达模型，不宜混为一谈。
- **Altos Labs**：2025 年 VCC「Generalist Prize」得主，用 flow matching 在 700 万细胞上预训练，证明「非 Transformer 生成模型」在扰动预测上有竞争力。[12]

6.4 中国：一超多强，高校—企业深度绑定

路线	代表	关键事实	产业化状态
清华—百图系	scFoundation、xTrimoGene、scMulan	scFoundation：5,000 万细胞/1 亿参数/Apache-2.0；xTrimoGene 仅 API；scMulan 3.68 亿参数/CC BY-NC-ND	开源 + API 双轨；百图生科商业化
中山大学—华为—新格元	CellFM	1 亿细胞/8 亿参数；MindSpore + 32 张昇腾 910；Nat Commun 2025	国产算力标杆；许可见论文
阿里达摩院	Lingshu-Cell	离散扩散；18,000 基因；VCC H1 基准领先；2026-08 预印本	研究阶段，未开源
之江实验室—华大	scDiffformer	「预训练—扩散后训练—微调」三步；NAR 2026	论文阶段；华大另有 Stereo-cell 平台
同济 DELTA Lab	AlphaCell / CellHermes	Mamba+Transformer+OT-CFM；1.2B 解码器；与 Helmholtz Munich 合作	概念验证，预印本
中科院系	GeneCompass	1.0177 亿人+鼠细胞；约 1 亿参数；Cell Research 2024	开源但无 LICENSE
腾讯	scBERT	最早的 BERT 路线；PanglaoDB 110 万细胞；GPL-3.0	2023 年底后基本停更
创业公司	百曜科技（CellOS）	3.905 亿细胞/12B MoE/JEPA；厂商称多项 SOTA	融资与商业化早期

说明：华大（BGI）在单细胞侧的公开叙事是「Stereo-cell 平台 + 10 Billion Cells Alliance 数据联盟 + Genos 基因组模型」，并未发布以「单细胞表达基础模型」为名的旗舰模型；坊间流传的「华大 GeneCompass」为误传，GeneCompass 的作者单位均为中科院系统。[39] [40] [7]

6.5 创业公司与资本：从「卖模型」到「卖闭环」

2024–2026 年，单细胞/虚拟细胞方向的融资逻辑发生了明显变化：早期是「我们有更大的模型」，后来是「我们有专有数据 + 湿实验平台 + 药企合同」。典型玩家包括：

- **Xaira Therapeutics**：2024 年成立，单轮融资 10 亿美元，主打 AI + 湿实验闭环（据公开报道）。
- **Tahoe Therapeutics**（原 Vevo）：Tahoe-100M 的生产者，用 Mosaic 平台规模化生成药物扰动数据。
- **Noetik、Somite.ai、Cellarity**：分别聚焦肿瘤、发育/细胞命运、细胞行为的小分子重编程。
- **百曜科技**：以 CellOS 切入「AI 虚拟细胞」，声称布局管线资产与模型服务两条商业化路径。

共同点是：**没有一家把「基础模型 API」当作唯一收入来源**。模型是入口，数据和实验是壁垒，药物管线或平台合作才是收入。

6.6 开源与平台：许可正在成为真正的护城河

单细胞模型的「开源」分成四档：① 代码 + 权重 + 宽松许可（scFoundation Apache-2.0、TranscriptFormer MIT）；② 代码开放但权重受限/非商用（State、Geneformer 部分版本）；③ 只开代码、不开权重（部分中国模型）；④ 只提供 API（xTrimoGene）。

对企业用户而言，**许可比性能更早成为选型门槛**：CC BY-NC-ND 的模型不能直接商用；无 LICENSE 的仓库在法律上默认「保留所有权利」；GPL-3.0 可能传染整个软件栈。这是 2026 年 scFM 落地最被低估的摩擦。

生态热度也可以量化：GitHub 上 scGPT 约 1,655 star、scFoundation 约 433 star；HuggingFace（经镜像数据，2026-10）Geneformer 近 30 天下载约 4,862 次、likes 321，CellFM 约 34 次，scFoundation 官方仓下载为个位数。这与「论文引用量」形成鲜明反差——**真正被下载、被跑起来的模型，远少于被引用的模型**。[45]

07 核心痛点：十个可验证的问题

这一章不罗列「挑战」这种空话，而是把每个痛点拆成「现象—证据—影响—可能解法」。所有数字都来自可查的论文或官方页面。

P1　数据规模悖论：更多数据 ≠ 更好模型

现象：预训练语料从 3,000 万涨到 3.9 亿，但性能提升远小于预期。

证据：Nature Methods 2026 的系统研究用 2,220 万细胞训练 400 个模型、做 6,400 次实验，发现性能在 1%–10% 数据即饱和；「单细胞基础模型没有清晰的数据 scaling law」。Kedzierska 等也观察到「预训练数据超过阈值后不再带来增益」。[15] [17]

影响：「堆数据—堆参数」的商业叙事失效；算力投入的边际回报下降；数据*多样性与质量*比数量更重要。

可能解法：数据选择（data selection）、去重、按任务分层采样、持续学习、以「验证集上的任务增益」决定是否加入新数据。

P2　数据质量：稀疏、丢零、双细胞与环境 RNA

现象：scRNA-seq 天生稀疏（dropout）、有双细胞（doublet）、环境 RNA 污染、批次效应；这些问题在千万级语料上被放大。

证据：2025 年综述明确指出：大规模聚合数据会引入「不同采样与测序协议造成的巨大变异」，双细胞、环境 RNA 等伪影会被模型学成虚假模式；在千万级细胞上做 QC 极其困难。[1]

影响：模型学到的可能是「测序平台特征」而不是「生物学特征」；跨数据集泛化失败；批次校正与生物信号保留难以两全。

可能解法：AI agent 自动清洗（scBaseCount）、统一元数据 schema、合成数据增强、把技术协变量显式建模进模型。

P3　数据泄漏：预训练集与测试集「偷偷重叠」

现象：很多 benchmark 数据集本身就包含在预训练语料里，导致「零样本」成绩被高估。

证据：2026 年的一项审计用 MinHash 逐细胞比对：PBMC 3k 有 **80.4%** 的细胞、人胰岛图谱有 **77.0%** 的细胞与 Genecorpus-30M 显著重叠；而截止日之后发布的数据集（AIDA v2、Tahoe-100M）重叠率为 0%。被污染细胞的嵌入在同供体、同类型内显著更「紧」。[21]

影响：「zero-shot 很强」的结论可能站不住；不同论文的排名不可比；这是一种「双重 dipping」——同一批细胞既塑造预训练表征，又充当评测集。

可能解法：公开逐细胞训练清单、时间切分（cut-off date）、指纹/成员推断审计、使用预训练截止后发布的数据集。

P4　评测体系缺失：没有统一的「考场」

现象：每个模型论文用自己的任务、数据集、指标；跨论文比较几乎不可能。

证据：2025 年综述直言「单细胞领域缺乏统一的基准框架」；2026 年的 harmonised benchmark 发现，6 个模型在 3 种模态、多任务上的排名会随预处理、tokenization、指标而翻转，「没有模型全面领先」。[1] [24]

影响：用户无法选型；资本无法判断技术优劣；「SOTA」变成营销词。

可能解法：scEval、Cell_Eval、PertEval、SCMBench、VCC 等公共基准；强制报告超参、种子、算力、失败案例。

P5　Zero-shot 不敌简单基线：最尴尬的证据

现象：不微调、直接拿嵌入做下游任务时，scFM 往往不如 HVG、Harmony、逻辑回归、additive 基线。

证据：① Kedzierska：Geneformer 的 ASW 仅 0.38–0.52，HVG 基线除 PBMC 外全部胜出；scGPT 中位 ASW 0.53 ≈ scVI 0.54。② Boiarsky：PBMC 上 L1 逻辑回归在 accuracy 与 macro-F1 上均胜 scBERT；scBERT 去掉预训练

后无显著差异（p=0.34/0.59）。③ Ahlmann-Eltze：7 个模型在 Norman 双扰动上误差均高于 additive 基线，交互预测无一优于「无变化」。[17] [19] [18]

影响：「基础模型」的核心卖点（零样本泛化）被削弱；但在微调、域内、特征提取场景仍有价值（见 P9 后的「仍然成立的优势」）。

可能解法：把 zero-shot 与 fine-tuned 分开报告；默认提供强基线；用「少样本增益」而不是「零样本绝对分数」作为卖点。

P6　架构错配：基因没有顺序，细胞不是孤岛

现象：把基因当词、细胞当句，忽略了三个根本差异：① scRNA-seq 是「基因袋」而非序列；② 细胞间关系（邻域、信号）比句子间关系更重要；③ 单细胞数据量远小于文本、噪声远大于文本。

证据：CellPLM 的立论就是这三点，并用「细胞为 token、组织为句」+ 空间预训练来回应；2025 年综述也指出「基因没有自然线性顺序，任何序列建模都是近似」，并批评「每个细胞独立训练」忽略了细胞间互作。[38] [1]

影响：模型可能学到「排序伪影」；空间信息丢失；对细胞通讯、微环境相关任务天然不利。

可能解法：集合/图注意力、空间邻域编码、细胞间对比学习、把「组织」作为建模单元。

P7　可解释性：attention 不等于基因调控网络

现象：论文常把注意力权重当作 GRN 或基因重要性，但注意力并不稳定对应生物学机制。

证据：2025 年综述明确警告：注意力「不总是特征重要性或交互的直接指标」，某些头可能完全不捕捉生物学相关连接；基因嵌入在跨细胞平均时也会偏向广表达基因，低表达但关键的调控基因容易被「平均掉」。[1]

影响：基于注意力的「新靶点发现」可信度存疑；监管与药企难以采信黑箱结论。

可能解法：注意力 + 扰动实验交叉验证、基因中心预训练目标、稀疏可解释头、与已知 GRN 数据库对齐。

P8　稀有细胞与长尾：总体 97.5%，稀有类仍失败

现象：数据分布极度不平衡，模型偏向常见细胞类型；总体准确率很好看，稀有细胞召回率系统性失败。

证据：2025 年综述指出零样本下少数群体注释不可靠；2026 年的受控实验（162 次训练：3 骨架 × 3 数据集 × 6 种长尾损失 × 3 种子）显示总体准确率可达 97.5%，但 rare-class recall 仍系统性失败，且失败由数据结构而非预训练决定。[1] [23]

影响：稀有细胞往往是疾病关键（干细胞、罕见免疫亚群、微小转移灶）；「总体指标」会掩盖真正的临床价值。

可能解法：重采样/重加权、分层评测、macro-F1 与 per-class recall、针对稀有类的外部验证集。

P9　落地成本：算力、微调门槛、许可与监管

现象：预训练要数十张 GPU、数周；微调要调参经验；很多模型禁止商用；监管对「AI 虚拟细胞」尚无明确路径。

证据：综述指出「预训练需要 4–12 张 A100/H100 数天到数周，更大模型需要更大集群一个月以上」；微调「资源密集且需要大量建模知识」；2026 年多个中国模型的论文许可为 CC BY-NC-ND，直接限制商用。[1] [6] [7]

影响：中小实验室与初创公司被挡在门外；药企更倾向「买 API/联合研发」而非自建；开源社区的复现成本高。

可能解法：LoRA/量化/蒸馏、轻量版模型、托管 API、清晰的商用许可、与湿实验服务打包。

P10　多模态与空间：融合仍处于早期

现象：绝大多数 scFM 仍是 RNA-only；RNA+ATAC、RNA+蛋白、RNA+空间的联合预训练模型数量少，且往往在单一模态上表现更好。

证据：SCMBench 评测 23 种多组学整合方法，结论是「基础模型在多组学整合上不如领域专用模型」；2026 年的 harmonised benchmark 也发现，空间/图模型更擅长保留组织结构，表达模型更擅长细胞身份，**没有模型在所有模态上领先**。[25] [24]

影响：真实生物学同时涉及转录组、表观组、蛋白组与空间位置；单模态模型可能错过调控层与微环境信息，限制「虚拟细胞」的保真度。

可能解法：多模态联合预训练（CAPTAIN）、空间邻域编码（Nicheformer / CellPLM）、跨模态对齐与统一 tokenization、以生物学任务而非重建损失来选模态组合。

◆ 但也要说清楚：哪些优势仍然成立

① **微调 + 分布外泛化**：scGPT 在多发性硬化数据上优于逻辑回归，且样本越少优势越大；scFoundation 在多个任务上稳定靠前。② **嵌入作特征**：基因嵌入 + 线性解码优于均值/随机嵌入。③ **预训练确有贡献**：预训练模型普遍优于随机初始化。④ **域匹配优于规模**：用 Replogle 扰动数据预训练的线性模型稳定优于通用大模型。换句话说，scFM 的价值在「**域内/近域的微调与特征提取**」，而不是「开箱即用的通用智能」。[19] [18] [22]

08 争议与反思：「基础模型」是否名副其实

2024–2026 年，领域内部发生了一场罕见的公开争论。它不是「哪个模型更强」，而是「这个范式是否成立」。

8.1 三场具体的交锋

① 逻辑回归 vs scBERT

MIT/Broad 的 Boiarsky 等发现：在 PBMC 上，L1 逻辑回归的 accuracy 与 macro-F1 都高于 scBERT；把 scBERT 的预训练去掉，性能没有显著变化。scGPT 只在多发性硬化（分布外）数据上胜出。作者的结论很直接：**「预训练没有带来有意义的基因表征」**。[19]

② HVG vs Geneformer

Microsoft Research 的 Kedzierska 等做了 5 个数据集的零样本评测：Geneformer 的 ASW 只有 0.38–0.52，HVG 基线除 PBMC 外全部胜出；scGPT 与 scVI 几乎持平；批次整合不合格。作者承认部分数据与预训练重叠，但在非重叠子集上结论一致；浙江大学团队的独立评测也得出「没有单一 scFM 全面领先」。[17] [20]

③ additive vs 所有扰动模型

EMBL 的 Ahlmann-Eltze 等用 Norman 双扰动做「地狱测试」：所有深度学习模型的误差都高于「两个单扰动的加和」这一朴素基线；交互预测没有一个优于「预测无变化」。真正有信息的交互只占 4.2%。这不是「模型不够大」，而是**信号本身太稀疏**。[18]

8.2 模型方的回应与争论的实质

scGPT 作者在 *Nature Machine Intelligence* 发表 Reply，认为评测存在任务选择、超参设置、数据划分等偏差；双方的分歧不只是数字，而是**「什么算成功」**：

- 模型方倾向于用「多个任务的平均表现」「微调后的上限」来证明价值；
- 批评方倾向于用「零样本、强基线、分布外」来检验「基础模型」的成色；
- 双方都同意的一点是：**领域缺少统一、可复现、防泄漏的评测标准**。

这也是为什么 2025–2026 年出现了这么多「基准论文」——它们本身不是模型，却在重塑领域的评价体系。[16] [22] [24] [25]

8.3 「规模」是不是答案?

scFoundation 在 2024 年报告了清晰的 scaling law 曲线（3M/10M/100M 参数，loss 随 FLOPs 幂律下降）；但 2026 年的系统研究在「下游任务」上找不到同样的规律：性能在 1%–10% 数据即饱和，且简单基线常常追平。[4] [15]

这两个结论并不矛盾：**预训练损失可以 scaling，但下游任务的「生物学信号」未必随规模线性增长**。当某类任务（如双扰动交互）本身只有 4.2% 的真实信号时，再大的模型也只能拟合噪声。这是「数据墙」的真正含义。

8.4 一个平衡的判断

> **scFM 不是「无用」，而是「被误用」。**把它当成开箱即用的通用智能，会失望；把它当成**高质量的表征初始化 + 迁移学习起点 + 跨数据集坐标系**，它已经在多个场景证明价值。真正的分水岭不是「参数多大」，而是「有没有**域匹配的数据 + 可靠的基线 + 湿实验验证**」。

8.5 给读者的一份「八问清单」

1. **任务是什么?** 注释、整合、扰动、生成——不同任务的最优模型完全不同。
2. **有没有强基线?** HVG、Harmony、scVI、逻辑回归、additive——先跑基线，再谈 scFM。
3. **评估数据在预训练集里吗?** 查时间切分、查细胞重叠、查作者是否公开训练清单。
4. **是零样本还是微调?** 两者要分开报告；零样本差不代表微调差。
5. **指标对生物学有意义吗?** macro-F1、per-class recall、DEG 重叠、Pearson delta，比总体 accuracy 更可信。
6. **稀有类表现如何?** 要求 per-class 结果，不只看总体。
7. **许可允许商用吗?** 代码许可 ≠ 权重许可 ≠ 论文许可。

8. **能不能复现？**有没有种子、超参、算力、失败案例的披露。

09 趋势展望：2026–2028 的五条主线

下面的判断不是「预测某个模型会赢」，而是判断「哪些条件一旦成立，格局会变」。每条都给出可观察的信号。

9.1 数据层：观测数据接近饱和，扰动数据决定上限

公开的观测性 atlas 已经达到亿级（CELLxGENE、HCA、Arc VCA），继续堆观测数据的边际收益在下降；真正稀缺的是**同一细胞类型、同一平台、带对照的扰动数据**。Tahoe-100M（1 亿细胞、6 万药物—细胞相互作用）之所以重要，不是因为大，而是因为它把「药物 × 细胞系」变成了可训练的因果矩阵。[13]

可观察信号：① 扰动数据成本是否降到「每细胞美分」量级；② 是否出现跨实验室的扰动数据标准（类似 scBaseCount 的元数据 schema）；③ 药企是否愿意把内部 Perturb-seq 数据拿出来换模型。

9.2 模型层：「通用底座 + 领域适配器」会成为主流

2026 年的架构爆炸（diffusion、JEPA、flow matching、Mamba）不会产生一个「唯一正确」的主干。更可能的格局是：

- **通用表征底座**（UCE、TranscriptFormer、SCimilarity）：负责跨物种、跨平台的坐标系；
- **生成/模拟器**（Lingshu-Cell、AlphaCell、State）：负责扰动响应与状态转移；
- **领域适配器**（LoRA、蒸馏、轻量版）：负责具体组织、具体模态、具体药企场景；
- **文本接口**（CellWhisperer、CellHermes）：负责自然语言查询与可解释输出。

可观察信号：是否出现「模型卡 + 适配器市场」；是否出现类似 HuggingFace 的单细胞模型托管标准；是否出现跨模型的统一 tokenization。

9.3 评测层：从「排行榜」到「生物学有效性」

2025–2026 年的基准论文已经把问题说透：没有统一评测，就没有可比较的进步。接下来的演化方向是：

- **任务标准化**：VCC 用「能否替代一次 Perturb-seq」定义任务；Cell_Eval 用 7 项指标覆盖 DES/PDS/MAE/Pearson/Spearman/AUPRC。
- **防泄漏**：时间切分、逐细胞去重、公开训练清单、成员推断审计。
- **生物学指标**：DEG 重叠、通路富集、稀有类召回，而不是单一 MSE。

- **动态榜单**：模型提交—盲测—复现的持续评估，而不是论文里的「一次性 SOTA」。

可观察信号：VCC 是否成为年度惯例；是否有期刊要求提交「基准报告」；是否有第三方审计机构出现。

9.4 产业层：平台化、监管与「in silico evidence」

短期（2026–2027）最现实的商业模式不是「卖模型」，而是三种：① **平台订阅/API**（BioMap、CZI VCP、NVIDIA BioNeMo）；② **联合研发**（药企出数据和场景，模型方出方法和算力）；③ **管线资产**（用虚拟细胞筛靶点，再把候选推进临床）。

监管侧，美国 FDA 于 2025-01-06 发布首份 AI 药物开发草案指南，提出基于风险的「可信度（credibility）」框架，并披露 2016 年以来已收到 500+ 含 AI 成分的申报；但全文并未专门提及「虚拟细胞」。欧洲、中国对 AI 辅助药物研发的鼓励，为「计算证据」进入审评提供了政策窗口；不过「虚拟细胞预测」目前还不能替代动物实验或临床试验，只能作为**假设生成与优先级排序**工具。[46] [28]

目前公开的落地案例，几乎都是「模型提假设 → 湿实验验证」的混合证据链：Google C2S-Scale 预测 silmitasertib + 干扰素并被活细胞实验验证；Genentech SCimilarity 的查询命中被 3D 水凝胶体系复现；Recursion 的 Phenom 模型通过 BioNeMo 对外托管。尚无公开的「虚拟细胞模型直接支撑 FDA 申报」案例。[44] [9] [43]

9.5 中国：算力自主、许可治理、数据联盟

- **算力自主**：CellFM 在 MindSpore + 昇腾 910 上完成 8 亿参数训练，证明了「非 NVIDIA 栈」的可行性；这会推动更多国内团队做类似尝试。[6]
- **许可治理**：目前中国团队的许可高度分裂（Apache-2.0 / GPL-3.0 / CC BY-NC-ND / 无 LICENSE）。如果要产业化，**商用许可的清晰化**比再发一个更大的模型更重要。
- **数据联盟**：华大联合 18 家机构发起「10 Billion Cells Alliance」，建设生命/疾病/扰动三大图谱库，明确指向细胞尺度基础模型与虚拟细胞。[39]

9.6 三个可能改变格局的「如果」

如果扰动数据成本降 10 倍

scaling law 可能在下游任务上重新成立；State/AlphaCell 这类「状态转移」模型会最先受益；纯观测模型的优势会被进一步压缩。

如果监管接受 in silico 证据

虚拟细胞从「研究工具」变成「审评材料」，药企付费意愿会显著上升；但前提是可解释性、可复现性与验证协议先到位。

如果多模态统一图谱出现

RNA + 蛋白 + 空间 + 扰动在同一坐标系里对齐，会出现真正的「细胞世界模型」；单模态模型的竞争壁垒将大幅下降。

一个谨慎的时间判断

2026–2027：评测标准化、许可分层、VCC 常态化；2027–2028：出现「虚拟细胞辅助」的临床前候选药物（仍以动物实验为准）；2028 之后：通用虚拟细胞仍是长期目标，短期不要期待「替代湿实验」。**以上为基于当前证据的推测，不是承诺。**

10 选型与行动建议

这一章是「怎么用」，不是「哪个最好」。不同任务的最优解差异极大，下面给出一个从任务出发的选型矩阵。

10.1 按任务的选型矩阵

任务	推荐起点	备选	关键提醒
细胞类型注释	CellFM / scGPT 微调	CellTypist、逻辑回归、scBERT	先跑基线；报告 macro-F1 与 per-class recall；注意标记基因覆盖
批次整合	Harmony / scVI 基线	scGPT、Geneformer	先证明「不输基线」；用 iLISI + 生物保守性双指标
跨物种 / 跨平台	UCE、TranscriptFormer	GeneCompass	检查物种与组织覆盖；零样本可先用，别急着微调
扰动预测	State、scFoundation	GEARS、线性/additive 基线	必须报告 DES/PDS/MAE；注意训练集与测试集的扰动重叠
药物响应	scFoundation / xTrimoGene	领域专用的药敏模型	细胞系与药物拆分要严格；警惕数据泄漏
空间转录组	Nicheformer、CellPLM	Novae、scGPT-spatial	组织结构指标（邻域一致性）比细胞身份更重要
细胞检索	SCimilarity	UCE	嵌入稳定性与跨研究可比性；先做小规模验证
基因功能 / GRN	Geneformer（微调）	GeneCompass、scGPT	注意力≠调控；必须用扰动或已知数据库交叉验证

10.2 给研究团队

做对的五件事

1. **先定义任务与基线**：HVG、Harmony、scVI、逻辑回归、additive——基线跑不过，不要上大模型。
2. **把「零样本」与「微调」分开报告**：两者的结论经常相反。
3. **做数据审计**：时间切分、去重、检查预训练集是否包含测试集。
4. **报告失败案例**：稀有类、分布外、跨平台的表现，比平均分更有信息量。
5. **公开超参与算力**：种子、学习率、batch size、GPU 时——这是可复现的前提。

常见的五个坑

1. 把「预训练 loss 下降」当成「下游能力提升」。
2. 用总体 accuracy 掩盖稀有类失败。
3. 在预训练数据上做「零样本」评测。
4. 忽略许可，把 CC BY-NC-ND 的模型用于商业产品。
5. 用 MSE 选模型，却在论文里讲生物学故事。

10.3 给企业与投资人

- **不要自建通用大模型**：除非你有亿级细胞和千卡算力，否则「开源底座 + 领域微调 + 专有数据」是更优解。
- **看数据闭环，不看参数量**：能持续产生扰动数据、能把湿实验接回训练回路的团队，比「参数最大」的团队更有长期价值。
- **把许可当尽职调查项**：代码许可、权重许可、论文许可、数据许可，四者可能不一致。
- **用第三方基准做验收**：VCC、Cell_Eval、scEval、SCMBench 的成绩，比厂商自测更可信。
- **警惕「最大」「首个」「SOTA」**：这三个词在 2025–2026 年的单细胞赛道出现频率极高，但很少附带可比条件。

10.4 给政策与联盟

- **建公共扰动数据基础设施**：比资助「再训练一个模型」更能提升国家竞争力。
- **推动评测标准与数据审计**：资助第三方基准、要求公开训练清单、建立模型卡规范。
- **明确商用许可与合规边界**：尤其是医疗场景下的数据隐私、模型责任与可解释性要求。
- **支持国产算力栈**：MindSpore/昇腾的案例证明可行，但需要更多模型与工具链适配。

A 方法与局限

资料范围

截至 2026-10-21。来源包括：Nature / Nature Methods / Nature Communications / Nature Machine Intelligence / Cell / Cell Research / Genome Biology / Advanced Science / Nucleic Acids Research 等期刊页；bioRxiv、arXiv、ACL Anthology、ICML/PMLR 预印本与会议页；Arc Institute、CZI、NVIDIA、BioMap、华大等机构官网与模型卡；GitHub 仓库与 HuggingFace 模型页（部分网络受限，未能直接打开）。

检索关键词：single-cell foundation model、scFM、virtual cell、perturbation prediction、scGPT、Geneformer、scFoundation、CellFM、State、Tahoe-100M、Cell_Eval、zero-shot benchmark；中文侧：单细胞大模型、虚拟细胞、扰动预测、细胞图谱。

已知局限

- 部分论文（Nature 系、Cell 系）只能读到摘要或新闻稿，方法细节未逐条核对。
- 厂商宣称的数字（CellOS 12B、3.905 亿细胞、Pearson_edist 0.619）未独立复现，正文已标注。
- 不同论文的细胞计数口径不同（是否去重、是否质控、是否含鼠/多物种），跨行比较仅作数量级参考。
- 中国企业的融资、管线信息多来自媒体转述，缺少港交所/公司公告级一手文件。

三处需要纠正的流传说法

流传说法	核查结果	一手来源
「华大 GeneCompass」	GeneCompass 作者单位均为中科院系统（动物所、计算所、自动化所、网络信息中心）+ X-Compass 联盟，论文与 GitHub 均无 BGI 署名	[7]
「GeneCompass 12 亿参数」	原文为 12 层/12 头/768 维，「总参数超过 1 亿」，不是 12 亿	[7]
「CellWhisperer 是中国团队」	作者全部为奥地利 CeMM/维也纳医科大学，通讯作者 Christoph Bock	Nat Biotechnol 2025, DOI 10.1038/s41587-025-02857-9

B 附录：术语表与开源资源

B.1 术语表

术语	含义（在本报告语境下）
scFM	单细胞基础模型（single-cell foundation model）：在千万到亿级单细胞数据上自监督预训练、可迁移到多任务的模型。

术语	含义（在本报告语境下）
Tokenization	把细胞的基因表达向量转成模型可处理的 token 序列的方式；常见有排名、分箱、连续投影、基因名文本、表达感知注意力。
零样本（zero-shot）	不针对下游任务微调，直接用预训练模型的嵌入或生成能力做预测。
微调 / LoRA	在预训练模型上用小规模任务数据更新参数；LoRA 只训练低秩适配器，大幅降低算力。
Perturb-seq	把 CRISPR 扰动与单细胞转录组测序结合，读出「 perturbation → 表达变化」的高通量实验。
AIVC	AI 虚拟细胞（AI virtual cell）：能表征、预测、模拟细胞状态与扰动响应的计算模型。
GRN	基因调控网络（gene regulatory network）：基因之间的调控关系图。
MoE	混合专家（mixture of experts）：用多个「专家」子网络稀疏激活，扩大参数量而控制推理成本。
JEPA	联合嵌入预测架构（joint-embedding predictive architecture）：在隐空间预测另一视角/另一状态，而不是重建输入。
流匹配 / OT-CFM	学习从初始分布到目标分布的连续变换；OT-CFM 用最优传输构造条件流，常用于扰动后的状态演化建模。
离散扩散	在离散 token 空间上做「加噪—去噪」的生成模型，适合稀疏、非序列的转录组计数。
ASW / AvgBIO	平均轮廓系数（聚类分离度）/ 平均生物保守性分数，常用于细胞嵌入评测。
PDS / DES	扰动区分度分数 / 差异表达分数，VCC 与 Cell_Eval 的核心指标。
数据泄漏 / 双重 dipping	预训练语料包含评测细胞，导致零样本成绩虚高；同一批细胞既塑造表征又充当测试集。

B.2 主要开源资源

模型 / 工具	仓库或模型页	许可 / 备注
scGPT	github.com/bowang-lab/scGPT	MIT；CZI VCP 有模型卡
Geneformer	huggingface.co/ctheodoris/Geneformer	代码/权重许可需逐版本核对
scFoundation	github.com/biomap-research/scFoundation	Apache-2.0
CellFM	github.com/biomed-AI/CellFM	标注 Other；论文 CC BY-NC-ND
GeneCompass	github.com/xCompass-AI/GeneCompass	无 LICENSE 文件
scBERT	github.com/TencentAILabHealthcare/scBERT	GPL-3.0；2023 年底后基本停更
SCimilarity	github.com/Genentech/scimilarity	开源；Nature 638:1085
TranscriptFormer	github.com/czi-ai/transcriptformer	MIT
UCE	github.com/snap-stanford/UCE	开源；Nature 2026
Cell_Eval	github.com/ArcInstitute/cell-eval	评测框架
CellPLM	github.com/OmicsML/CellPLM	ICLR 2024
Nicheformer	github.com/theislab/nicheformer	Nat Methods 2025

以上链接为公开仓库/模型页；如遇 404，请在论文的 Data/Code Availability 段落查找最新地址。本报告未对每个仓库的可用性做逐一运行验证。

R 参考文献

按正文引用顺序编号。链接为公开可访问的一手页面；付费墙论文同时给出 DOI 或预印本。

1. Baek S, Song K, Lee I. Single-cell foundation models: bringing artificial intelligence into cell biology. *Exp Mol Med* 57:2169–2181 (2025). https://www.nature.com/articles/s12276-025-01547-5
2. Theodoris CV, Xiao L, Chopra A, et al. Transfer learning enables predictions in network biology. *Nature* 618:616–624 (2023). https://www.nature.com/articles/s41586-023-06139-9
3. Wang H, Zhao J, Su Y, et al. scGPT: toward building a foundation model for single-cell multi-omics using generative AI. *Nat Methods* 21:1470–1480 (2024). https://www.nature.com/articles/s41592-024-02201-0；模型卡 https://virtualcellmodels.cziscience.com/model/scgpt
4. Hao M, Gong J, Zeng X, et al. Large-scale foundation model on single-cell transcriptomics (scFoundation). *Nat Methods* (2024). https://www.nature.com/articles/s41592-024-02305-7；预印本 https://www.biorxiv.org/content/10.1101/2023.05.29.542705v1.full
5. Yang F, Wang W, Wang F, et al. scBERT as a large-scale pretrained deep language model for cell type annotation of single-cell RNA-seq data. *Nat Mach Intell* 4:852–866 (2022). https://doi.org/10.1038/s42256-022-00534-z；预印本 https://www.biorxiv.org/content/10.1101/2021.12.05.471261v3.full
6. Zeng Y, Xie J, Shangguan N, et al. CellFM: a large-scale foundation model pre-trained on transcriptomics of 100 million human cells. *Nat Commun* 16:4679 (2025). https://www.nature.com/articles/s41467-025-59926-5
7. Yang X, Liu G, Feng G, et al. GeneCompass: deciphering universal gene regulatory mechanisms with a knowledge-informed cross-species foundation model. *Cell Res* 34:830–845 (2024). https://www.nature.com/articles/s41422-024-01034-y
8. Rosen Y, Brbić M, Roohani Y, et al. Universal cell embeddings (UCE): a foundation model for cell biology. *Nature* (2026). https://www.nature.com/articles/s41586-026-10689-z
9. Heimberg G, Kuo T, DePianto DJ, et al. A cell atlas foundation model for scalable search of similar human cells (SCimilarity). *Nature* 638:1085–1094 (2025; online 2024-11-20). https://www.nature.com/articles/s41586-024-08411-y
10. Pearce JD, Simmonds SE, Mahmoudabadi G, et al. A cross-species generative cell atlas across 1.5 billion years of evolution: the TranscriptFormer single-cell model. *bioRxiv* (2025)；正式版 *Science* (2026-07-02), DOI 10.1126/science.aec8514. https://doi.org/10.1101/2025.04.25.650731；模型卡 https://virtualcellmodels.cziscience.com/model/transcriptformer
11. Arc Institute. Arc Institute’s first virtual cell model: State. 2025-06-23. https://arcinstitute.org/news/virtual-cell-model-state；正式版 *Cell* (2026-08-31), DOI 10.1016/j.cell.2026.07.052
12. Arc Institute. Virtual Cell Challenge 2025 Wrap-Up: Winners and Reflections. 2025-12-06. https://arcinstitute.org/news/virtual-cell-challenge-2025-wrap-up
13. Arc Institute / Tahoe. Tahoe Open Sources Tahoe-100M… 2025-02-25. https://arcinstitute.org/news/arc-vevo
14. Bunne C, Roohani Y, Rosen Y, et al. How to build the virtual cell with artificial intelligence: priorities and opportunities. *Cell* (2024). https://doi.org/10.1016/j.cell.2024.11.015；新闻稿 https://www.eurekalert.org/news-releases/1068117
15. DenAdel A, Hughes M, Thoutam A, et al. Evaluating the role of pretraining dataset size and diversity on single-cell foundation model performance. *Nat Methods* (2026). https://www.nature.com/articles/s41592-026-03120-y

16. Liu T, Li K, Wang Y, Li H, Zhao H. Evaluating the utilities of foundation models in single-cell data analysis (scEval). *Adv Sci* 13(27):e14490 (2026). https://doi.org/10.1002/advs.202514490；预印本 https://www.biorxiv.org/content/10.1101/2023.09.08.555192v6.full

17. Kedzierska KZ, Crawford L, Amini AP, Lu AX. Zero-shot evaluation reveals limitations of single-cell foundation models. *Genome Biol* 26:101 (2025). https://doi.org/10.1186/s13059-025-03574-x

18. Ahlmann-Eltze C, Huber W, Anders S. Deep-learning-based gene perturbation effect prediction does not yet outperform simple linear baselines. *Nat Methods* (2025). https://doi.org/10.1038/s41592-025-02772-6

19. Boiarsky R, Singh N, Buendia A, Getz G, Sontag D. Deeper evaluation of a single-cell foundation model. *Nat Mach Intell* (2024). https://doi.org/10.1038/s42256-024-00949-w

20. Wu J, Ye Q, Wang Y, et al. Biology-driven insights into the power of single-cell foundation models. *Genome Biol* (2025). https://doi.org/10.1186/s13059-025-03781-6

21. Ali S. Auditing pretraining contamination in single-cell foundation model benchmarks. *arXiv*:2607.20572 (2026). https://arxiv.org/abs/2607.20572

22. Wenteler A, Occhetta M, Branson N, et al. PertEval-scFM: benchmarking single-cell foundation models for perturbation effect prediction. *ICML* 2025, PMLR 267:66633–66677. https://proceedings.mlr.press/v267/wenteler25a.html

23. Dong Z, Zhong J. Rethinking class imbalance for single-cell foundation models. *arXiv*:2609.23325 (2026). https://arxiv.org/abs/2609.23325

24. Chen S, Zahedi R, Chhuo L, et al. Harmonised benchmarking of foundation models for single-cell and spatial transcriptomics reveals context-dependent generalisation. *arXiv*:2607.17227 (2026). https://arxiv.org/abs/2607.17227

25. Wang Y, Fan Y, Wang X, et al. SCMBench: benchmarking domain-specific and foundation models for single-cell multi-omics data integration. *Nat Commun* (2026). https://www.nature.com/articles/s41467-026-72570-x

26. Ji B, Hu T, Wang J, et al. CAPTAIN: a multimodal foundation model pretrained on co-assayed single-cell RNA and protein. *Nat Commun* (2026). https://www.nature.com/articles/s41467-026-72882-y

27. Zhang H, Yuan G-H, Yuan C, et al. Lingshu-Cell: a generative cellular world model for transcriptome modeling toward virtual cells. *arXiv*:2603.25240 (2026). https://arxiv.org/abs/2603.25240

28. 量子位. 从 LLM 到 JEPA，中国团队正在把「世界模型」搬进细胞内部（CellOS 发布报道）. 2026-07-03. https://www.qbitai.com/2026/07/442746.html；动脉网专访. 2026-07-04. https://www.phirda.com/artilce_43055.html

29. Chuai G, Chen X, Yang X, et al. Towards building a world model to simulate perturbation-induced cellular dynamics by AlphaCell. *bioRxiv* (2026). https://doi.org/10.1101/2026.03.02.709176；中文报道 https://m.163.com/dy/article/KNOPN27O05119734.html

30. scDifformer: a pretraining–diffusion post-training–fine-tuning paradigm for virtual cell modeling. *Nucleic Acids Res* (2026). https://doi.org/10.1093/nar/gkag706

31. Zhang F, Chen H, Zhu Z, et al. A survey on foundation language models for single-cell biology. *ACL* 2025 (Long Papers), pp. 528–549. https://aclanthology.org/2025.acl-long.26.pdf

32. Chan Zuckerberg Initiative. Virtual Cells Platform: models, benchmarks and data. https://virtualcellmodels.cziscience.com/

33. NVIDIA. BioNeMo Framework: Geneformer model card & recipes. https://docs.nvidia.com/bionemo-framework/latest/models/geneformer/

34. Regev A, Teichmann SA, Lander ES, et al. The Human Cell Atlas. *eLife* 6:e27041 (2017). https://doi.org/10.7554/eLife.27041

35. Levine D, Rizvi SR, Lévy S, et al. Cell2Sentence: teaching large language models the language of biology. *bioRxiv* (2023). https://doi.org/10.1101/2023.09.11.557287

36. Chen Y, Zou J. GenePT: a simple but effective foundation model for genes and cells built from ChatGPT. *bioRxiv* (2023). https://doi.org/10.1101/2023.10.16.562533

37. Schaar AC, Todorov H, et al. Nicheformer: a foundation model for single-cell and spatial omics. *Nat Methods* (2025). https://www.nature.com/articles/s41592-025-02814-z

38. Wen H, Tang W, Dai X, et al. CellPLM: pre-training of cell language model beyond single cells. *ICLR* 2024. https://proceedings.iclr.cc/paper_files/paper/2024/hash/173bcdbd820edbe43284e0941109ada9-Abstract-Conference.html

39. BGI. Stereo-cell and the 10 Billion Cells Alliance. 2025-08-22. https://en.genomics.cn/scientificdiscoverie-7179.html

40. BGI Group. 2025 milestones: Genos genome foundation model. https://en.genomics.cn/bgigroupmilestones2025.html

41. Arc Institute. State 正式版：Predicting cellular responses to perturbation. *Cell* (2026-08-31). DOI 10.1016/j.cell.2026.07.052；Stack 预印本 2026-01-09, bioRxiv 10.64898/2026.01.09.698608；https://arcinstitute.org/tools/stack

42. Chan Zuckerberg Initiative. CZI and NVIDIA expand partnership for virtual cell models. 2025-10-28. https://chanzuckerberg.com/newsroom/nvidia-partnership-virtual-cell-model/

43. Genentech. BRAID: Biology Research | AI Development. https://www.gene.com/scientists/our-scientists/braid

44. Google. C2S-Scale 27B: AI co-scientist for cancer therapy discovery. 2025-10-15. https://blog.google/innovation-and-ai/products/google-gemma-ai-cancer-therapy-discovery/

45. GitHub / HuggingFace 镜像数据（2026-10-21）：scGPT repo stars、Geneformer 近 30 天下载与 likes。原始页面：https://github.com/bowang-lab/scGPT；https://hf-mirror.com/api/models?search=Geneformer

46. U.S. FDA. Framework to advance credibility of AI models used in drug and biological product submissions (draft guidance). 2025-01-06. https://www.fda.gov/news-events/press-announcements/fda-proposes-framework-advance-credibility-ai-models-used-drug-and-biological-product-submissions

47. Bommasani R, Hudson DA, Adeli E, et al. On the opportunities and risks of foundation models. *arXiv*:2108.07258 (2021). https://arxiv.org/abs/2108.07258

本报告基于公开资料整理，旨在提供研究地图与判断框架，不构成投资或医疗建议。厂商宣称的数据均已标注；引用请以原始论文/官方页面为准。

报告结构：摘要 · 定义 · 起源 · 技术版图 · 模型全景 · 重点方向 · 产业生态 · 痛点 · 争议 · 展望 · 建议 · 方法 · 参考文献