RESEARCH REPORT • 2026

单细胞大模型
问题、方案与架构

十二个可验证问题 · 六个架构大类 · 二十七个模型的设计取舍

从“把 BERT 搬到细胞”到“用分布预测干预”：一次以代价为中心的技术盘点

汇报版 v1.0

2026 年 10 月 26 日

资料截至 2026-10 · 厂商口径单独标注

四个部分，回答两个问题

01 问题

12 个可验证的问题，分四层

机理 · 证据 · 解法 · 判据

02 架构

6 个架构大类，按建模单元 × 学习信号划分

每类给出归纳偏置与共同天花板

03 模型

27 款模型的独特设计与代价

一张速查表 + 逐模型点评

04 判断

13 项独立评测的结论

5 条趋势判断 + 3 组建议

六条判断，先看结论

01	**问题是分层的**	修好一层，代价会以另一种形式出现在下一层。
02	**最硬的问题不在模型侧**	泄漏、饱和、噪声，都是数据与评测制度问题。
03	**六个大类 = 两组坐标的可行组合**	建模单元 × 学习信号；主干是正交选择。
04	**每一类都有结构性代价**	没有免费午餐：丢幅值、丢序、丢分辨率、丢可解释。
05	**2026 的主线是换监督信号**	从“重建表达”转向“预测干预后的分布”。
06	**评测仍停在重建指标**	与“干预正确性”错位，是最大的方法论缺口。

十二个问题，四层管线

数据层

模型吃什么

P1 规模幻觉

数据翻十倍，下游增益趋零

P2 噪声与批次

学到的是平台，不是生物学

P3 数据泄漏

零样本成绩被预训练污染

P4 长尾与偏移

稀有类型、跨物种失效

表示层

模型怎么读

P5 词表与顺序

基因没有顺序，词表不通用

P6 值的离散化

分箱丢幅值，排序丢绝对量

P7 语境缺失

细胞被当成孤岛

目标层

模型学什么

P8 重建≠理解

注意力不等于基因调控网络

P9 扰动与因果

打不过加法基线，真实交互 4.2%

P10 生成与多模态

全谱生成与跨模态对齐仍早

适配与评价

怎么用、怎么判

P11 适配成本

微调贵、超参敏感、许可分裂

P12 评测失焦

指标与生物学脱节

这 12 个问题不是并列清单：修好一层，代价会出现在下一层。

模型吃什么：四个问题决定上限

P1

规模幻觉

语料从 3,000 万涨到 3.9 亿，但下游增益在 1%–10% 数据处就停了。没有可用的数据 scaling law 。

判据 下游指标 vs token 数曲线

P2

噪声与批次

零值二义、双细胞、环境 RNA ； 批次效应与生物效应同量级。 ASW 好看，整合可能已经失败。

判据 两组对照 + 噪声注入

P3

数据泄漏

PBMC 3k 有 80.4% 、人胰岛 77.0% 的细胞与预训练语料重叠。唯一没有架构解的问题。

判据 截止日 + 逐细胞指纹

P4

长尾与偏移

总体准确率 97.5% ， 稀有类召回仍系统性失败。 HVG 与截断恰好丢掉低表达标记。

判据 per-class recall

只有 P2 有真正的架构解（显式协变量、噪声建模、集合损失）； 其余三个只能靠数据工程与评测制度。

核心矛盾：模型在拟合测量，而不是拟合生物学。

模型怎么读：三个被低估的设计选择

P5

词表与顺序

基因没有自然顺序，词表随物种与平台变化。四种解法：位置嵌入、秩、蛋白身份、调控先验。

判据　能否嵌入未见基因 / 物种

P6

值的离散化

分箱丢幅值、丢序、边界不可迁移。实测排序： soft binning > 连续 ≈ log 分箱 > 硬分箱。

判据　跨数据集 + DE 端误差

P7

语境缺失

解离测序把组织打散成独立细胞，而生物学发生在细胞之间。空间与邻域信息被完全抹掉。

判据　去坐标后性能掉多少

表示层进步最快：蛋白语言模型让基因身份不再依赖固定词表；软分箱与分布头让表达值不再被硬边界切断。

核心矛盾：为了兼容词表与语言模型，牺牲了定量信息。

模型学什么：三个错位的奖励函数

P8

重建 ≠ 理解

掩码重建的最优解是学共表达，不是学调控。注意力权重是路由，不是因果。

判据 与 ChIP/Perturb-seq 重叠

P9

扰动与因果

Norman 双扰动上，所有模型误差都高于 additive 基线。真实交互仅 4.2%。

判据 DES/PDS + 未见扰动

P10

生成与多模态

全转录组生成要同时建模两万个相关维度与零膨胀；多模态数据少、缺失普遍。

判据 分布距离 + DE 保真

目标层的问题必须换损失，不能换主干：把 Transformer 换成 Mamba、把 12 层加到 40 层，都不会让模型从“重建”转向“预测干预”。

核心矛盾：奖励函数在奖励复述，而不是奖励干预。

模型怎么用、怎么判：最后一公里

P11

适配成本

预训练要数十张 GPU；微调对种子与超参敏感。许可四分五裂： Apache / MIT / GPL / CC BY-NC-ND / 无 LICENSE 。

判据 10% 标注的增益 / 单卡可跑

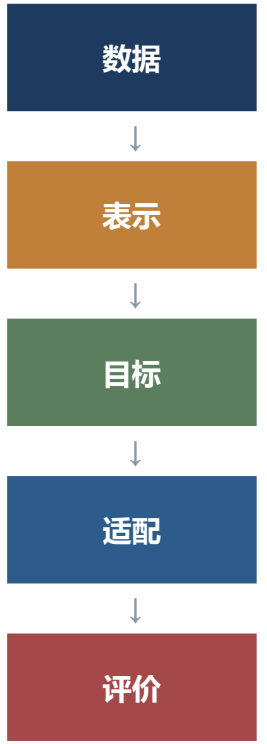
P12

评测失焦

MSE 被近零差异基因稀释； benchmark 饱和、排行榜不可比。饱和是“可识别性失败”，不是能力到顶。

判据 预注册 + 盲测 + 复现包

一条向下游传导的因果链



修好一层，代价会以另一种形式出现在下一层。

六个大类：建模单元 × 学习信号

按「建模单元 × 学习信号」得到的六个架构大类

同一个主干（Transformer / RetNet / Mamba）可以出现在任何一类；分类看的是它把什么当作第一性对象、用什么信号学习



两个坐标

横轴：第一性对象是什么——基因、细胞、表达谱、状态分布、语言。

纵轴：监督从哪里来——掩码重建、似然生成、对齐、隐空间预测。

主干是正交维度

Performer / RetNet / Mamba / Flowformer 只决定“能读多长、多快”，不决定“学什么”。同一个 Mamba 可以出现在 A 类与 E 类。

掩码基因序列：看一半，猜一半

定义

基因 token 序列 + 掩码重建； BERT 配方可原样复用。

归纳偏置

共表达即语法：两个基因总一起出现，就能互相推断。

结构性代价

只奖励“重建自己”，不奖励“干预正确”。

代表模型

scBERT | Geneformer | GeneCompass | Nicheformer | UCE | CellFM | scPRINT | RegFormer

变体谱 硬分箱（scBERT）→ 秩（Geneformer）→ 连续（CellFM）→ 软分箱（State）→ 蛋白身份（UCE）→ 分布头（scPRINT）

适用 注释、检索、基因功能、数据稀缺时的迁移起点

不适用 扰动预测、生成、跨物种定量

一句话： A 类的竞争史，就是一部 tokenizer 迭代史。

四类结构，四种代价

B 类 • 自回归基因序列

顺着往下写

定义	$p(x)=\prod p(g,c \mid \text{前序})$；训练信号是似然，不是重建。
能力	条件生成、计数分布、不确定性。
代表	scGPT：块状掩码，让“敲除”变成一次前向。 TranscriptFormer：ZTP 计数头 + 247k 跨物种词表。 scMulan：元数据即 prompt。
代价	推理逐 token；基因顺序人为；对分布外过度自信。

它把“生成”变成可计算的目标，但顺序是人为的。

scGPT • TranscriptFormer • scMulan

C 类 • 连续谱编解码

压成向量，再还原

定义	$z=E(x)$，$\hat{x}=D(z)$；显式建模“整谱”。
能力	去噪、补全、跨平台、跨模态。
代表	scFoundation：只编码非零位，90% 的零不进注意力。 CellVQ：细胞压成 2^16 码本整数。 CAPTAIN：蛋白 query 去读 RNA。
代价	固定基因数；MSE 被高表达主导。

它把“整谱”变成可压缩对象，但基因关系被压进一个向量。

scFoundation • xTrimoGene • CellVQ • CAPTAIN

B 类与 C 类的共同点：都换了损失函数；区别是换似然，还是换重建目标。

另外两类：换建模单元

D 类 • 细胞集合

细胞看细胞

定义	细胞为 token，同一张切片或同一组扰动里的细胞互相注意。
机制	线性注意力 / 集合编码器 / 下一细胞预测。
代表	CellPLM：切片内 Flowformer + 16 分量高斯混合。 State：256 个细胞的集合，MMD/ 能量距离。 tGPT：细胞序列当文本。
代价	基因关系被压平；推理需邻域；集合丢分辨率。

它把“语境”带进模型，但丢掉了单基因分辨率。

CellPLM • State • tGPT • Tahoe-x1

E 类 • 状态分布

学分布，不学点

定义	学 p(x_t | x_0, c)：扩散去噪、流匹配速度场、JEPA 隐空间预测。
机制	不再复述输入，而是建模状态转移。
代表	Lingshu-Cell：掩码离散扩散 + 条件生成。 AlphaCell：OT-CFM 在 32×128 隐流形上建模转移。 CellOS：JEPA 双视角 + 12B MoE。
代价	采样慢；可解释性弱；评测没跟上。

它把“干预”变成分布搬运，但还没学会解释自己。

Lingshu-Cell • AlphaCell • CellOS • scDifformer

D 类与 E 类的共同点：都换了建模单元；区别是建模细胞集合，还是建模状态分布。

语言接口，以及一个正交维度

F 类：定义

把细胞与语言放进同一坐标系：序列化、文本嵌入、对比对齐。

F 类：代价

读得到“是什么”，读不到“多少”。

主干：正交维度

Performer / RetNet / Mamba 只决定“能读多长、多快”。

代表模型

Cell2Sentence | GenePT | LangCell | CellWhisperer | Transformer | Performer | RetNet | Mamba

变体谱	文本序列化（Cell2Sentence）→ 文本嵌入（GenePT）→ 对比对齐（CellWhisperer / LangCell）

适用	冷启动、自然语言检索、零样本注释	**不适用**	扰动预测、剂量响应、精细定量

一句话：语言是入口，不是终点。

三个定义了范式的模型

scBERT

2021 • 腾讯 AI Lab

110 万细胞 • 参数未公开

独特设计

用 gene2vec 替代位置编码；
Performer 把 16,907 长度的注意力降到线性。

首次证明 BERT 可行。

代价

200 维偏窄、词表封闭；
PBMC 上不敌逻辑回归。

历史意义 > 实用价值

Geneformer

2022 • Gladstone

2,990 万细胞 • 10M 参数

独特设计

秩编码：除中位表达再排序，把管家基因压后、转录因子顶前。

10M 参数，单卡可跑。

代价

丢绝对幅值； dropout 让整条排名平移；截断丢尾部。

第一个证明“迁移学习有效”

GeneCompass

2024 • 中科院

1.02 亿细胞 • >100M 参数

独特设计

四类先验拼成 3,841 维再投影： GRN 、启动子、基因家族、共表达。

人鼠同源映射 + 物种 token 。

代价

首层参数大；先验质量决定上限；仓库无 LICENSE 。

少数做了湿实验闭环的模型

三个把“生成”做进架构的模型

scGPT

2023 • 多伦多 /Vector

1,030 万细胞 • 53M 参数

独特设计

块状掩码：待预测基因只能看已知基因。

于是“敲除” = 把该基因设为未知，一次前向完成。

代价

每细胞分箱边界漂移； 1,200 HVG 限制覆盖；零样本不敌基线。

生态最完整的模型之一

TranscriptFormer

2025 • CZI

1.12 亿 / 12 物种 • 444M

独特设计

基因 softmax + 零截断泊松；计数以 log1p 进入注意力分数。

12 物种、 247,388 词表、 ESM-2 蛋白身份。

代价

输出头很宽；自回归推理慢；随机排列需靠打乱训练。

生成式 + 跨物种结合得最好

scFoundation

2023 • 清华 / 百图

5,000 万细胞 • 100M 参数

独特设计

非对称编解码：只编码非零位（约 10% ），解码全谱。

T/S 深度 token + 软分箱 + 30% 掩码 MSE 。

代价

固定 19,264 基因； MSE 被高表达主导； scaling 只在 loss 上成立。

最务实的稀疏设计

四个在不同维度上做到极致的模型

UCE

2023 • Stanford

3,600 万 / 8 物种 • 650M

独特设计

没有基因词表： ESM-2 蛋白嵌入即身份。

按表达加权抽 1,024 基因，零样本嵌入未见物种。

代价

抽样随机；嵌入表巨大；二分类目标丢幅值。

通用坐标系的最佳代表

CellFM

2025 • 中山大学 / 华为

1.02 亿细胞 • 800M 参数

独特设计

8 亿参数、 40 层 ERetNet 、 2,048 基因、连续标量。

MindSpore + 32 张昇腾 910 。

代价

单物种；参数与下游增益未解耦；许可为 Other 。

国产算力栈的可行性证明

State

2025 • Arc Institute

1.67 亿 + 1 亿扰动细胞

独特设计

不预测单个细胞，预测 256 个细胞的集合分布。

SE 学表征、 ST 学变换， MMD/ 能量距离做损失。

代价

非商用；集合丢单细胞分辨率；依赖扰动数据。

第一个把分布损失做成主流

CellPLM

2024 • ICLR

1,140 万细胞 • 82.4M

独特设计

细胞为 token ： 切片内细胞互相注意。

16 分量高斯混合；批次标签只进解码器。

代价

基因关系被压平；推理需邻域；位置编码实现有落差。

冻结嵌入 + 轻量头的首选

五个正在改写规则的模型

Lingshu-Cell

阿里达摩院

约 18,000 基因 • 未公开

独特设计

把转录组当离散分布去噪：掩码离散扩散，按条件生成。

代价

采样慢；预印本。

最彻底“换目标函数”

AlphaCell

同济 DELTA

19,253 基因 • 1.2B 解码器

独特设计

全基因输入 → 32×128 隐流形 → OT-CFM 建模状态转移。

代价

解码器巨大；可解释性弱。

连续时间生成路线

CellOS

百曜科技

3.905 亿细胞 • 12B MoE

独特设计

JEPA 双视角联合嵌入预测，不复述输入。

代价

厂商口径；未开源。

值得关注思路，不是数字

CAPTAIN

湖南大学等

426 万 CITE-seq • 382 蛋白

独特设计

蛋白 token 作 query、RNA 作 key/value。

代价

面板窄；物种写死为 2。

CITE-seq 规模化的第一步

RegFormer

华大研究院

2,500 万细胞 • 45 组织

独特设计

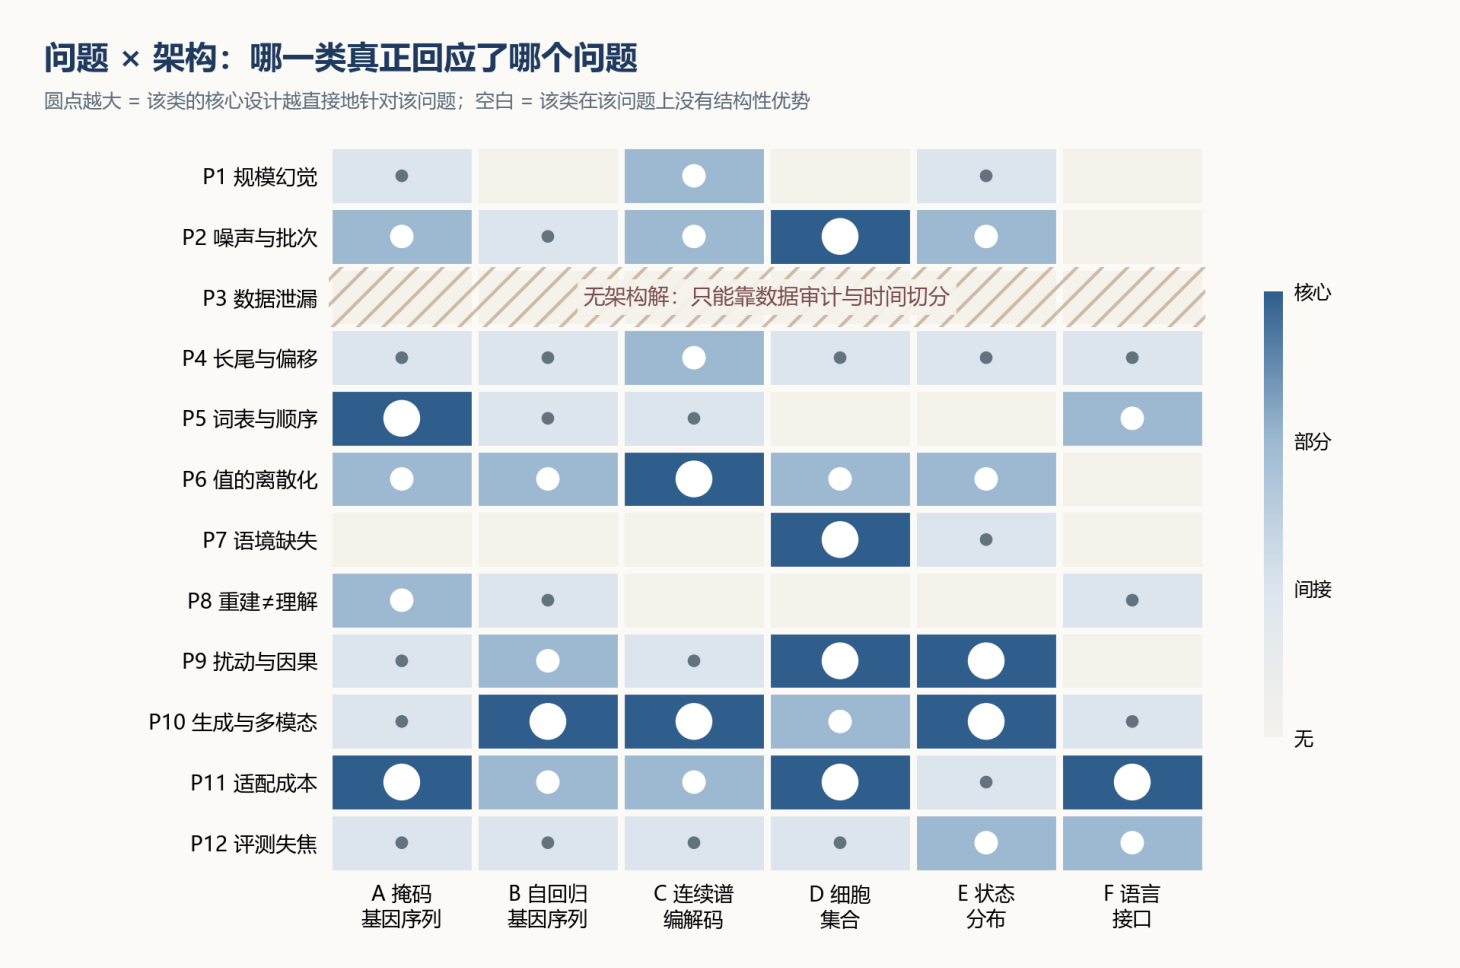
GRN 引导基因排序 + Mamba。

代价

单物种；复现少。

先验结构化的最新形态

哪一类真正回应了哪个问题



两个立刻可见的结论

P3 整行为空：数据泄漏没有架构解，只能靠时间切分与审计。

P11 几乎每列都有点：适配是工程问题，所有类都能用冻结、 LoRA 、小模型缓解。

目标层的问题（ P8–P10 ）集中在 D/E 类，因为只有它们换了损失函数。

空白不等于无关，而是“没有结构性优势”。

三项被确认的负面结论，四项仍然成立的优势

零样本不敌基线

Geneformer ASW 0.38–0.52；
PBMC 上 L1 逻辑回归胜 scBERT

扰动打不过 additive

Norman 双扰动上所有模型误差
高于“两个单扰动相加”

排名随数据集翻转

scEval 8 类任务 × 10 个模型：
没有任何模型全面领先

但四条优势仍然成立

- **微调后 OOD 泛化**
  样本越少，优势越明显
- **嵌入可作特征**
  优于均值与随机嵌入
- **预训练确有贡献**
  去预训练显著变差
- **域匹配 > 规模**
  Replogle 线性模型胜通用大模型

结论： scFM 不是“无用”，而是“被误用”。当成开箱即用的通用智能会失望；当成高质量初始化 + 迁移学习起点，它已在多个场景证明价值。

从任务出发，而不是从模型出发

从任务出发的选型路径

先判断任务落在哪一层，再看该层的结构性代价你是否能接受——而不是先问「哪个模型最强」



注：① 任何任务都应先跑强基线（HVG、Harmony、scVI、逻辑回归、additive）；② A 类在零样本上最容易被简单基线追平，微调后才有稳定优势。

三条通用规则

① 先跑强基线： HVG / Harmony / scVI / 逻辑回归 / additive 。

② 零样本与微调分开报告。

③ 扰动任务必须报告 DES/PDS ，而不是 MSE 。

用法不是“照着选”，而是“先排除”：先判断任务落在哪一层，再排除结构性代价不可接受的大类。

2026–2028： 五条可观察的判断

数据	观测 atlas 接近饱和，扰动数据决定上限	信号：扰动数据成本、跨实验室标准
目标	从重建转向分布 / 转移，集合级损失成为标配	信号：新论文是否默认报告分布指标
表示	词表无关的基因身份成为默认	信号：新模型是否还依赖固定词表
架构	通用底座 + 领域适配器，不会有一个主干通吃	信号：是否出现模型卡与适配器市场
评测	从排行榜转向“能否替代一次实验”	信号： VCC 是否成为年度惯例

三条值得走的路，一条不建议的路

做数据

高质量扰动数据的生产成本、元数据标准化、跨实验室去重，是最难被追平的壁垒。

做目标

分布级损失、因果识别、可识别性约束，才是 P8–P10 的真正解法。

做评测

时间切分、逐细胞审计、任务化指标、失败案例披露——不产生引用，但决定判断力。

不建议 再训一个同质的大模型。除非你有别人没有的数据，或者别人没有的算力栈。

如果只有一句话

先用强基线把任务做到 80 分，再问 scFM 能不能把最后 20 分补上。

补不上，不是模型不好，是任务不需要它。

THANK YOU

讨论与提问

报告全文：单细胞大模型 _ 问题与架构 _ 调研报告（DOCX / PDF， 50 页）

2026 年 10 月 26 日