RESEARCH REPORT • 2026

单细胞大模型
问题、方案与架构

十二个可验证问题 · 六个架构大类 · 二十七个模型的设计取舍

从“把 BERT 搬到细胞”到“用分布预测干预”：一次以代价为中心的技术盘点

版　　本	v1.0（汇报版）
完成时间	2026 年 10 月 26 日
覆盖范围	2021–2026 年公开的单细胞基础模型、评测与批评性研究
资料口径	论文原文、预印本、官方仓库与模型卡；厂商口径单独标注
引用数量	27 款模型 · 29 张表 · 47 条来源

说明：本报告区分“论文/官方数据”与“厂商宣称”，凡属后者均在正文标注；未标注者可在附录 C 找到来源。报告不构成投资建议。

摘要

十二个问题、六个大类与二十七个模型

这份报告不按“模型年表”组织，而按两个更稳定的坐标来组织：模型要解决什么问题，以及它把什么当作建模的第一性对象。前者解释“为什么每个模型都长得不一样”，后者解释“为什么它们最终会收敛到少数几种结构”。

核心判断

一、问题是分层的，而且会向下游传导。 十二个问题分布在数据、表示、目标、适配与评价四层。修好一层，代价往往以另一种形式出现在下一层：把表达值离散化，换来的是与语言模型词表的兼容，代价是幅值信息；把细胞当成集合来预测，换来的是对噪声的鲁棒，代价是单细胞分辨率。理解这条链，比记住任何一个模型的分数都重要。

二、最硬的问题不在模型侧。 数据泄漏（P3）没有架构解，只能靠时间切分与逐细胞审计；数据规模饱和（P1）说明“再大一倍”不再是有效策略；噪声与批次（P2）本质上是测量问题。三者共同构成了比参数量更硬的约束。

三、六个架构大类，是建模对象与学习信号的六种可行组合。 建模对象是基因、细胞、表达谱整体、状态分布与自然语言；学习信号是掩码重建、似然生成与对齐/预测。六个大类不是六个“流派”，而是六组被数据形态逼出来的取舍。主干网络（Transformer、Performer、RetNet、Mamba）是正交的工程选择，不决定模型学什么。

四、每一类都有结构性代价，没有免费午餐。 秩编码丢绝对幅值，硬分箱丢序，连续投影怕噪声，细胞为 token 丢基因间关系，集合预测丢单细胞分辨率，扩散模型丢可解释性，文本接口丢定量精度。选型不是找“最强”，而是找“代价可以接受”。

五、2026 年的前沿不是“更大”，而是“换监督信号”。 2021–2024 年的主线是把 BERT/GPT 的配方搬到转录组；2025–2026 年的新模型几乎都在做同一件事：从“重建自己的表达”转向“预测干预后的分布”。State 用 256 个细胞的集合与 MMD 损失，AlphaCell 用最优传输流匹配，Lingshu-Cell 用条件离散扩散，CellOS 用 JEPA 在隐空间预测。这是一次从表示学习到世界模型的迁移。

六、评测仍停在“重建指标”，与“干预正确性”错位。 多数基准用 MSE、Pearson 或聚类一致性打分，而模型真正要回答的是“敲掉这个基因之后，哪些基因会变”。在 Norman 双扰动上，所有被测

模型的误差都高于“两个单扰动相加”的朴素基线，而真正有信息的交互只占 4.2%。这不是模型不够大，是指标没有对准问题。

七、zero-shot 的叙事已经破产，但微调与特征提取的价值仍然成立。 多项独立评测显示，零样本嵌入常常不如 HVG、Harmony、逻辑回归；但同一批研究也确认：预训练优于随机初始化，微调后在分布外数据上仍有增益，且样本越少优势越明显。正确的用法是“高质量初始化 + 轻量适配”，不是“开箱即用的通用智能”。

八、最值得下注的三个方向。 词表无关的基因身份（UCE、TranscriptFormer、scPRINT 用蛋白语言模型替代固定词表）、分布级/集合级的学习目标（State 的集合损失、AlphaCell 的流匹配）、以及把先验变成结构而不是特征（GeneCompass 的知识拼接、RegFormer 的调控排序、CellVQ 的本体矩阵）。三者分别对应 P5、P9、P8 三个最难的问题。

一句话结论 单细胞大模型已经完成了“范式验证”，还没有完成“价值验证”。它现在缺的不是参数，而是三样东西：能检验干预的评测、能持续产生扰动数据的闭环、以及把结构性代价讲清楚的选型语言。本报告试图提供第三种。

报告结构

第 1 章交代范围、分析框架与资料口径。第 2 章把问题拆成十二个可验证的条目，每个条目给出机理、证据、各模型的解法与验收判据。第 3 章给出架构分类学：先定义分类的两个坐标，再逐类拆解其归纳偏置与共同天花板。第 4 章逐个模型讲“独特之处”，并给出二十七款模型的速查表。第 5 章把问题与架构交叉，给出选型路径与四种反模式。第 6 章做现实检验：哪些结论站得住，哪些还没有被证明。第 7 章给出五条判断与三组建议。

如果只有十分钟：读摘要的八条判断、图 1 的问题地图、图 3 的架构分类、第 5 章的选型矩阵。如果要做技术选型：加读第 2 章的判据框、第 4 章的逐模型点评、第 6 章的八问清单。

3.905 亿
公开报道中最大的预训练语料（厂商口径）

12B
公开报道中最大的参数量（MoE，厂商口径）

1%–10%
预训练数据即进入下游性能平台期

4.2%
扰动数据中可检出真实基因交互的比例

目　录

摘要 i

第 1 章　研究范围与分析框架 1

1.1　定义与边界 1

1.2　分析框架：一条管线、两个坐标、四个解剖位 1

1.3　资料、口径与覆盖范围 2

第 2 章　问题图谱：十二个可验证的问题 3

2.1　P1　规模幻觉：更多数据没有换来更强模型 3

2.2　P2　噪声与批次：模型学到的可能是平台，不是生物学 4

2.3　P3　数据泄漏：零样本成绩被预训练污染抬高 5

2.4　P4　长尾与偏移：总体 97.5%，稀有类仍然失败 6

2.5　P5　词表与顺序：基因不是词，细胞不是句子 7

2.6　P6　值的离散化：分箱丢了什么 8

2.7　P7　语境缺失：细胞不是孤岛 10

2.8　P8　重建不等于理解：注意力不是基因调控网络 10

2.9　P9　扰动与因果：打不过加法基线 11

2.10　P10　生成与多模态：从描述到干预 12

2.11　P11　适配成本：最后一公里 13

2.12　P12　评测失焦：指标与生物学脱节 14

2.13　十二条问题的相互位置 15

第 3 章　架构分类学：六个大类 16

3.1　分类原则：建模单元 × 学习信号 16

3.2　A 类　掩码基因序列：看一半，猜一半 17

3.3　B 类　自回归基因序列：顺着往下写 18

3.4　C 类　连续谱编解码：压成向量，再还原 19

3.5　D 类　细胞集合模型：细胞看细胞 20

3.6　E 类　状态分布模型：学分布，不学点 20

3.7　F 类　语言接口模型：把细胞翻译成人话 21

3.8　主干是正交维度：能读多长、多快，不决定学什么 22

3.9 混血与边界：分类是为了预测代价，不是为了贴标签 22

第 4 章 逐模型：独特之处与代价 23

4.1 A 类：八个模型的独特之处 24

4.2 B 类：三个模型的独特之处 27

4.3 C 类：四个模型的独特之处 28

4.4 D 类：四个模型的独特之处 29

4.5 E 类：四个模型的独特之处 30

4.6 F 类：四个模型的独特之处 31

4.7 边界之外：五款值得知道的模型 32

4.8 三个被高估、三个被低估 32

第 5 章 交叉矩阵：哪类架构回应了哪个问题 33

5.1 覆盖矩阵怎么读 33

5.2 五条规律 34

5.3 四种反模式 34

5.4 从任务出发的选型路径 35

第 6 章 现实检验：哪些结论站得住 37

6.1 独立评测的证据总表 37

6.2 仍然成立的四条优势 38

6.3 三个还没有被证明的承诺 38

6.4 一张八问验收清单 39

第 7 章 判断与建议 40

7.1 五条判断（2026–2028） 40

7.2 给研究团队：三条值得走的路 40

7.3 给选型者：三张表 41

7.4 五个开放问题 41

附 录 术语、资源与来源 42

A 术语表 42

B 可复现资源 43

C 主要来源 43

页码为正文页码；图表编号在全书内连续。

第 1 章

研究范围与分析框架

> 在讨论“哪个模型更强”之前，需要先约定三件事：什么算单细胞大模型、用什么框架拆解它、以及本报告的数字从哪里来。

1.1 定义与边界

单细胞基础模型（single-cell foundation model，scFM）指：在千万到亿级单细胞组学数据上以自监督方式预训练、可通过微调或提示迁移到多种下游任务的深度神经网络。它的核心隐喻是“细胞即句子，基因即词”，但这个隐喻只在部分模型里成立——有的模型把细胞当词，有的把整条表达谱当向量，有的干脆把细胞当分布。

它与任务专用工具的区别不在规模，而在承诺：Seurat、Harmony、scVI、CellTypist 是“一个任务一个模型、一组假设”；scFM 承诺“一个主干、多种任务”，预训练学到的是可迁移的基因共表达语法。这个承诺在 2023–2024 年被广泛接受，在 2025–2026 年受到系统性质疑（第 6 章）。

本报告讨论二十七款模型，选取标准是：有论文、预印本或官方模型卡可查，且代表了某一种架构选择。纯商业 API 且无技术细节的模型只在产业语境中提及。**报告不评估“谁最强”**——不同模型的训练语料、评测集与任务定义都不同，跨论文的分数不可直接比较；报告评估的是“每种设计换来了什么、付出了什么”。

1.2 分析框架：一条管线、两个坐标、四个解剖位

拆解一个 scFM，最有效的方式不是看它的名字，而是沿着数据管线问四个问题。这四个问题构成本报告反复使用的“解剖位”：

① Tokenizer（怎么读） 把稀疏计数变成 token 序列：秩、硬分箱、软分箱、连续投影、分布参数，还是细胞级码字。它决定模型保留了多少定量信息、能覆盖多少基因。

② Backbone（用什么算） 标准 Transformer、Performer 的线性注意力、RetNet、Mamba、Flowformer，或扩散/流匹配的去噪网络。它决定能读多长、多快、多省显存。

③ Objective（学什么） 掩码重建、自回归似然、对比对齐、分布参数回归、集合距离、流匹配。它决定模型能力的上限——这是六个大类真正的分界线。

④ Interface（怎么用） 输出是细胞嵌入、基因嵌入与注意力、生成谱，还是自然语言；适配是全参微调、LoRA、冻结探针还是提示。它决定落地成本。

沿着管线，问题自然分成四层：**数据层**（模型吃什么）、**表示层**（模型怎么读）、**目标层**（模型学什么）、**适配与评价层**（模型怎么用、怎么判）。第十二个问题（评测失焦）横跨后两层，因为它既影响适配，也影响我们对前十一件事的判断。

第二个坐标用于架构分类。**建模单元**回答“一次前向传播里，第一性对象是什么”：基因、细胞、整条表达谱、状态分布，还是自然语言。**学习信号**回答“监督从哪里来”：重建自己、最大化似然、对齐另一模态，还是在隐空间做预测。两个坐标的可行组合只有六个，这就是第 3 章的六个大类。主干网络不参与分类，因为同一个 Mamba 既可以做掩码基因模型（RegFormer），也可以做状态转移模型（AlphaCell）。

1.3 资料、口径与覆盖范围

资料以论文原文、预印本、官方仓库与模型卡为准；厂商口径（如 CellOS 的 12B 参数、3.905 亿细胞、Pearson_edist 0.619）单独标注，未做独立复现。细胞计数口径差异很大——是否去重、是否质控后、是否含多物种——跨模型比较只作数量级参考。

其中十七款模型（scBERT、Geneformer、scGPT、scFoundation、UCE、CellFM、TranscriptFormer、State、CellPLM、Nicheformer、GeneCompass、scMulan、scPRINT、CAPTAIN、CellVQ、CellWhisperer、Tahoe-100M）的架构参数经过官方源码核对，包括层数、维度、分箱数、掩码比例、损失权重与词表大小；这些数字与论文正文偶有出入时，以代码为准并在第 4 章注明。信息截至 2026 年 10 月。

表 1 本报告覆盖的模型与架构类别

类别	建模单元 / 学习信号	模型	数量
A 掩码基因序列	基因 / 掩码重建	scBERT、Geneformer、GeneCompass、Nicheformer、UCE、CellFM、scPRINT、RegFormer	8
B 自回归基因序列	基因 / 似然生成	scGPT、TranscriptFormer、scMulan	3
C 连续谱编解码	表达谱 / 重建或量化	scFoundation、xTrimoGene、CellVQ、CAPTAIN	4
D 细胞集合模型	细胞或集合 / 集合建模	CellPLM、State、tGPT、Tahoe-x1	4
E 状态分布模型	状态分布 / 生成与预测	Lingshu-Cell、AlphaCell、CellOS、scDiffformer	4
F 语言接口模型	自然语言 / 对齐	Cell2Sentence、GenePT、LangCell、CellWhisperer	4

注：表中的“建模单元 / 学习信号”是分类依据，不代表模型的全部能力；跨类混血（如 RegFormer 用 Mamba 主干做 A 类目标）在 §3.8 讨论。

第 2 章

问题图谱：十二个可验证的问题

> 这一章不罗列“挑战”这类空话。每个问题都必须满足三个条件：能被观察、有可引用的数字、能追溯到数据或架构的具体机制。

单细胞大模型的问题清单可以列得很长，但真正独立的只有十二个。它们分布在四个层：数据层决定模型能学到什么，表示层决定模型能看见什么，目标层决定模型被奖励什么，适配与评价层决定模型最终被如何使用、如何判断。图 1 给出全局位置，本章逐条展开。



图 1 单细胞大模型的十二个可验证问题：按管线四层归置

图中箭头表示问题的传导方向：上游的取舍会以下游代价的形式出现。例如 P6 的离散化是为了兼容语言模型词表，代价转嫁给 P8（重建目标与生物学理解错位）。

2.1 P1 规模幻觉：更多数据没有换来更强模型

> 预训练语料从三千万涨到近四亿，下游任务的增益却在 1%–10% 的数据处就停了。单细胞领域目前没有可用的数据 scaling law。

语言模型的 scaling law 成立，有一个常被忽略的前提：下一个词提供了近乎无限的新监督，语料越多，新组合越多。单细胞的自监督目标是重建自己，新增细胞如果与已有细胞同分布，只增加冗余，不增加信息。更硬的是维度约束：输入被基因数锁死（人类约两万），细胞类型数远小于细胞数，观测落在低维流形上。于是“更多细胞”很快退化为“同一流形的更多采样”。

2026 年 6 月的一项系统研究把这件事量化了：2,220 万细胞、400 个模型、6,400 次训练，性能在只用 1%–10% 预训练数据时就进入平台期，某些任务上简单基线（HVG、Harmony）与复杂 Transformer 持平甚至更好。这与 scFoundation 报告的“loss 随 FLOPs 幂律下降”并不矛盾——能 scale 的是预训练损失，不是下游能力。

表 2　对 P1 的代表性回应

模型 / 工作	做法	机制	代价或边界
scFoundation	把 scaling 做在预训练损失上	300 万 / 1,000 万 / 1 亿参数三档，报告 loss 随 FLOPs 的幂律	证明“能 scale”，未证明“scale 有用”
CellFM	把稠密参数量推到 8 亿	40 层 ERetNet、1.02 亿人类细胞、32 张昇腾 910	单物种；参数量与下游增益未解耦
UCE	换多样性而不是数量	8 物种、300+ 数据集、无固定基因词表	零样本强，定量任务弱
TranscriptFormer	换进化跨度	12 物种、15.3 亿年、247,388 个基因词表	计算贵；物种仍偏脊椎动物
CellOS	换稀疏容量	3.905 亿细胞、12B MoE（厂商口径）	未开源，无独立复现
scBaseCount	换数据工程	用 AI agent 统一清洗约 2 亿细胞、统一元数据	不产出模型，但决定所有模型的上限

判据　要求一条“下游指标—预训练 token 数”的曲线，且测试集按时间切分。曲线要同时给出饱和点与边际增益。拿不出这条曲线时，“更大”只是叙事，不是证据。

2.2　P2　噪声与批次：模型学到的可能是平台，不是生物学

> 单细胞数据里最强的信号常常是技术性的：测序深度、平台、批次、解离方式。模型一旦走捷径，学到的是“这台机器”，不是“这个细胞”。

零值在 scRNA-seq 里是二义的：它可能表示“这个基因不表达”，也可能表示“表达了但没测到”。此外还有环境 RNA、双细胞、解离应激反应。批次效应的量级可以与真实生物效应相当，而模型没有任何先验知道“哪些差异是技术造成的”。这就是 shortcut learning 的温床：分类任务里，模型只要认出数据集编号，就能拿到很高的准确率。

更麻烦的是指标背离。Kedzierska 等的零样本评测发现，scGPT 的批次整合在多个数据集上不合格，但同一批实验里的 ASW（平均轮廓系数）仍然好看——因为 ASW 同时被细胞类型可分性与批次混合度影响，两者可以互相抵消。scContam 进一步证明，数据集级的 ASW 比较会被标注协议系统性混淆。换句话说，**你以为在测“整合得好不好”，实际可能在测“标注得粗不粗”**。

表 3　对 P2 的代表性回应

模型	做法	机制	代价或边界
scGPT	条件 token 加到每个基因位	批次、模态作为可学习嵌入，与基因、表达值逐元素相加	推理时必须给定协变量；新批次仍是分布外
Geneformer	先除基因中位表达，再排序	去量纲、把管家基因压到后面、突出转录因子	排序对 dropout 敏感，丢一个计数会整条平移
scFoundation	末尾拼 T/S 两个深度 token	把目标与输入总计数写成可参与注意力的位置，配 RDA 旋钮	深度外推依赖训练覆盖
UCE	按表达量加权、有放回抽 1,024 个基因	深度被编码成“出现频率”，而不是另一路数值	抽样随机；复现需固定种子
CellPLM	批次标签只进解码器	逼隐空间与批次无关，重建时才用批次信息	只在训练分布内成立
Nicheformer	除以技术特异的非零均值	在排序前扣掉平台差异	需要技术标签；新平台仍失配
scPRINT	泊松下采样 + dropout 模拟重测序	学“从稀疏还原稠密”，而不是遮 token	假设噪声模型正确
State	集合级损失（MMD / 能量距离）	把细胞异质性与技术噪声一起吸收进分布	丢单细胞分辨率

判据　必须做两组对照：同一生物学、不同批次；同一批次、不同生物学。两组同时报告 iLISI（批次混合）与生物保守性（NMI/ARI、标记基因保留率），再做一次噪声注入（如 20% 高斯噪声或计数下采样），看性能掉多少。只报一组，结论不可信。

2.3　P3　数据泄漏：零样本成绩被预训练污染抬高

> 这是十二个问题里唯一没有架构解的：模型越好，越容易把预训练时见过的细胞“认出来”，而评测恰恰用这些细胞。

公共图谱既是训练语料，又是评测集。模型方通常不公开逐细胞训练清单，评测方也无法确认测试集是否被见过。于是“零样本”在信息论上接近“近似检索”：模型并不需要理解生物学，只需要把见过的嵌入取出来。这在方法学上叫“双重 dipping”——同一批细胞既塑造了预训练表征，又充当了零样本评测集。

2026 年的一项审计用 MinHash 逐细胞比对，给出了目前最硬的数字：PBMC 3k 有 80.4% 的细胞、人胰岛图谱有 77.0% 的细胞与 Genecorpus-30M 显著重叠（$p<0.05$）；而截止日之后发布的 AIDA v2 与 Tahoe-100M 重叠率为 0%。被污染细胞的嵌入在同供体、同细胞类型内显著更“紧”（置换检验 p=0.030 / 0.014 / <0.002）——这正是记忆的指纹。

表 4　对 P3 的工程性缓解（没有模型解）

手段	做法	有效性	局限
时间切分	只评测预训练截止日之后发布的数据集	最硬，可直接排除记忆	需要模型方公布截止日；新数据少
逐细胞指纹	MinHash / 局部敏感哈希比对训练语料	可量化污染比例	依赖语料公开；算力开销大
成员推断	用损失或嵌入距离判断样本是否被训练过	可发现隐性记忆	假阳性率难控
数据卡规范	公开语料清单、去重方法、许可证	低成本、可审计	目前无强制力
后截止评测池	Tahoe-100M、AIDA v2 等作为公共测试床	天然防泄漏	只覆盖部分任务与组织

判据　看三件事：论文是否给出预训练截止日；是否公布逐细胞语料清单或指纹；零样本结果是否只来自截止日之后的数据。三者缺一，把结论降级为“域内性能”。

2.4　P4　长尾与偏移：总体 97.5%，稀有类仍然失败

> 稀有细胞往往是疾病的关键——干细胞、罕见免疫亚群、微小转移灶。但模型与指标都偏向常见类型。

细胞类型分布接近幂律：少数类型占绝大多数细胞，长尾类型可能只有几十个细胞。更糟的是，长尾类型的标记基因往往表达量低，而 HVG 选择、top-k 截断、2,048 token 上限这些常规操作，恰好优先丢掉低表达基因。跨物种与跨 panel 时，词表与分布同时偏移，失败会叠加。

2026 年的一项受控实验做了 162 次训练（3 种骨架 × 3 个数据集 × 6 种长尾损失 × 3 个种子），总体准确率可达 97.5%，但稀有类召回率系统性失败，且失败主要由数据集结构决定，而不是预训练。这解释了为什么“换损失函数”几乎没有效果：信息在截断那一步就已经丢了。另一项评测显示，只有改用 macro-F1，scBERT 在难分 CD8 亚群上的劣势才暴露出来。

表 5　对 P4 的代表性回应

模型	做法	机制	代价或边界
TranscriptFormer	全基因词表（247,388）	输出头覆盖所有基因，不依赖 HVG 预选	输出 softmax 巨大；计算贵
Lingshu-Cell	约 18,000 基因全量建模	离散扩散不预选 HVG	采样成本高；预印本
AlphaCell	19,253 个 HGNC 基因全量输入	Mamba + Transformer 压到连续隐流形	1.2B 解码器；预印本
UCE	无基因词表	蛋白嵌入让未见基因也能有表示	二分类目标，丢幅值
Geneformer	秩截断到 2,048	按表达量排序，截掉的是最不表达的一端	低表达但关键的调控基因可能被截掉
长尾损失	重采样、重加权、focal loss	在 162 次受控实验中被系统比较	几乎无效：失败由数据结构决定

判据　要求 per-class recall 与稀有类的外部验证集，而不是总体 accuracy；跨 panel 实验要报告“测试基因中有多少比例出现在预训练词表里”。

2.5　P5　词表与顺序：基因不是词，细胞不是句子

> 基因没有自然顺序，词表随物种与平台变化，新基因无法表示。所有“把细胞当句子”的模型，都必须先回答这个问题。

自然语言里，词的身份由词表给定，顺序由语法给定。基因两者都没有：人类基因可以用 Ensembl ID 固定，但小鼠、斑马鱼、植物各有自己的词表；测序 panel 可以只覆盖 1,000 个基因；新发现的转录本不在任何词表里。顺序更是人为的——按染色体排、按表达量排、按调控关系排，都是归纳偏置，不是事实。

领域里出现过四种回答。第一种是**学一个位置嵌入**：每个基因一个向量，等价于“基因身份证”，scGPT 与 scFoundation 都这么做；好处是简单，代价是词表封闭。第二种是**用表达量排序当顺序**：Geneformer 的 rank value encoding，顺序本身携带“强弱”语义，代价是丢绝对幅值且对 dropout 敏感。第三种是**用蛋白序列当身份**：UCE 与 TranscriptFormer 用 ESM-2 的蛋白嵌入替代基因 ID，词表可以无限扩展，代价是预计算表巨大、且同一基因在不同物种得到不同向量。第四种是**用调控关系排序**：RegFormer 用 GRN 引导基因顺序，把“谁调控谁”变成序列先验，代价是先验质量决定上限。

表 6　基因身份与顺序的四种解法

解法	代表	机制	代价
可学习位置嵌入	scGPT、scFoundation、CellVQ	每个基因一个 512 维向量，随词表扩展	词表封闭；新基因需重训或扩表
表达量排序	Geneformer、Nicheformer、CellFM（top-k）	细胞内排序，名次即语义	丢绝对量；dropout 导致整条平移
蛋白语言模型身份	UCE、TranscriptFormer、scPRINT	ESM-2 蛋白嵌入，基因名不再必需	5,120 维表常驻显存；物种间向量不同
调控/本体先验	RegFormer（GRN 排序）、GeneCompass（同源映射）、CellVQ（GO 矩阵）	把先验结构写进输入或顺序	先验质量与覆盖决定上限
文本身份	GenePT、Cell2Sentence、LangCell	基因名/描述经 LLM 编码	分词与命名规范问题；定量精度低

判据　能否嵌入训练时未见的基因或物种；换一套基因 panel 后性能保持率是多少；词表扩展是否需要重训。三个问题答不上来，跨物种能力就是营销词。

2.6　P6　值的离散化：分箱丢了什么

把连续表达切成 bin，是把回归问题变成分类问题的代价。这个代价在分布偏移时才会暴露。

Transformer 并不排斥连续值——连续标量完全可以过 MLP 再加到基因嵌入上。离散化的真正动机是复用交叉熵目标、复用语言模型词表、以及量化自带的 regularization。但它引入五类可分离的损失：bin 内的幅值损失（同一个 bin 的所有值被折叠成一个点）、序损失（bin 编号被当作无序类别）、有效码率损失（零膨胀让绝大多数概率质量挤在最低几个 bin，名义 5.6 bit 实际远低）、边界不可迁移（边界由训练集统计定死，换平台就失配）、以及目标错配（预训练预测 bin，下游要 log fold-change）。

2026 年最大规模的对照实验给出了明确排序：在 1,000 万细胞、100 个数据集上从头训练八种配置，**soft binning > 连续编码 ≈ log 分箱 > 硬分箱**；最佳配置（可学习基因嵌入 + soft binning）macro-F1 为 0.860，最差配置（ESM-2 + log 分箱）为 0.547。同一实验还有一个更重要的结论：基因侧编码的影响远大于表达值侧——这提醒所有做 value encoder 改进的人，必须先固定基因侧再做消融。

表 7　表达值编码的六条路线

路线	代表	做法	关键代价
硬分箱	scBERT（7 档）、scGPT（每细胞 51 档）	分位数切段，bin 编号查表	幅值与序都受损；边界随细胞漂移
秩编码	Geneformer、Nicheformer	只保留名次	丢绝对幅值；dropout 敏感
软分箱	scFoundation、CellVQ、State（10 箱）	标量 → bin 权重 → 加权词向量	可微、保序，但多一层超参
连续投影	CellFM、CellPLM、CAPTAIN	标量直接过 MLP	保留幅值，怕噪声与尺度漂移
分布参数	scPRINT（ZINB）、TranscriptFormer（ZTP）	输出 μ/θ/π 或零截断泊松	假设强；训练不稳定
细胞级量化	CellVQ（2^16 码本）、RVQ / CellTok	整细胞压成码字	面向生成；丢基因级分辨率

图 2 把六种编码放在同一条光谱上：左端把表达压成序，右端把表达压成分布或码字。越往右信息越完整，但与离散词表和交叉熵目标的距离越远。

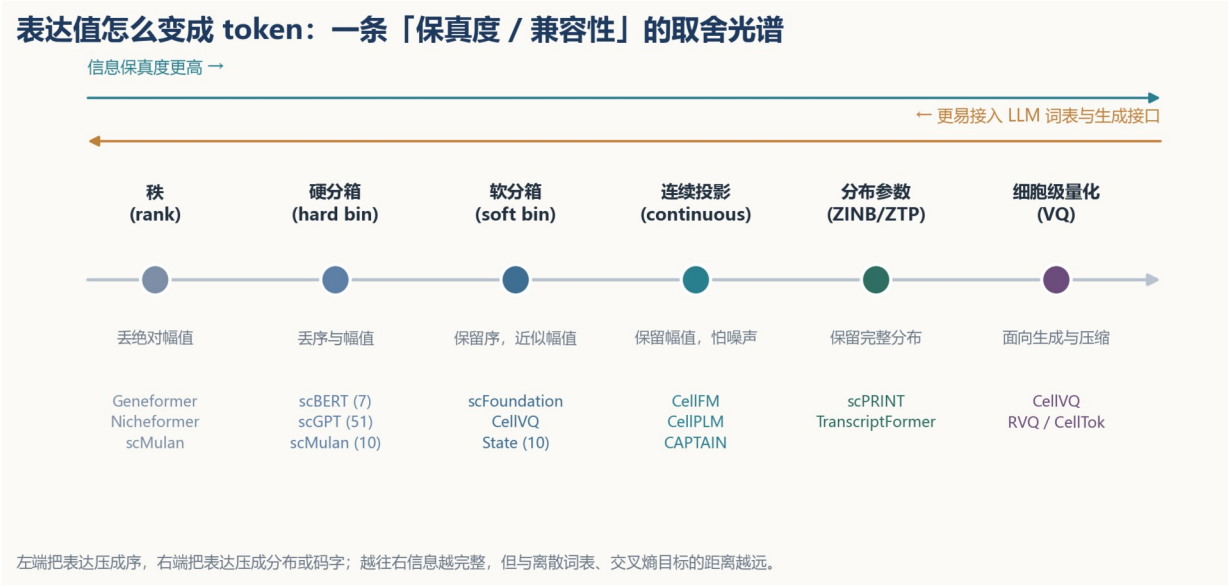


图 2　表达值编码的取舍光谱：从秩到细胞级量化

越往右信息越完整，但与离散词表和交叉熵目标的距离越远。图中括号内的数字是该模型的分箱数（scBERT 7、scGPT 51、State 10）。

判据　在跨数据集与逆扰动任务上比较，而不是同分布测试；报告差异表达端的误差（log fold-change 的相关性、DE 基因重叠），而不只是重建 MSE。

2.7 P7 语境缺失：细胞不是孤岛

> 解离测序把组织打散成独立细胞，而生物学发生在细胞之间：邻接、信号、 niche、组织结构。

主流 scFM 的预训练假设是“细胞独立同分布”：每个细胞一条序列，互不相见。这个假设在注释任务上问题不大，但在组织生物学、细胞通讯、微环境相关任务上直接失效。空间转录组提供了位置，但分辨率与基因 panel 往往不如解离数据；把两者放在一起训练，是 2024–2026 年的一条主线。

Nicheformer 的立论最直接：只在解离数据上训练的模型学不会空间微环境，而联合训练后可以把空间信息迁移回普通 scRNA-seq，做空间组成预测与空间标签预测。CellPLM 则把“切片”当成句子、细胞当成词，让同一张切片里的细胞互相提供上下文。但 2026 年 7 月的统一评测给这股热潮泼了冷水：在六个代表性模型上，没有模型在所有空间任务上领先；空间/图模型更擅长保留组织结构，表达模型更擅长细胞身份。

表 8 对 P7 的代表性回应

模型	建模单元	机制	代价
CellPLM	细胞为 token	切片内 N 个细胞做 Flowformer 注意力；SRT 用 2D 正弦位置编码	基因间关系被压成加权和；推理需邻域
State（ST）	256 个细胞的集合	无位置编码的集合编码器，输出扰动后的分布	不做空间；集合丢单细胞分辨率
Nicheformer	基因序列 + 空间上下文	解离与空间联合预训练，预测空间语境	空间 panel 有限；排序丢幅值
tGPT	细胞为 token	把细胞序列当文本做下一细胞预测	顺序人为；单细胞分辨率下降
PULSAR	多细胞组织语境	显式建模 cell–cell interaction 与组织上下文	预印本；评测有限

判据 空间任务的指标应是邻域一致性、空间标签预测、组成反卷积，而不是细胞类型准确率；同时报告“去掉空间坐标后性能掉多少”，以证明模型真的用了语境。

2.8 P8 重建不等于理解：注意力不是基因调控网络

> 掩码重建的最优解是“学共表达”，不是“学调控”。注意力权重是模型内部的路由，不是因果关系。

掩码语言模型在文本上有效，是因为“预测被遮的词”逼近了语法与语义。在单细胞上，预测被遮的基因只需要共表达——A 与 B 一起高表达，模型就能从 A 推 B，不需要知道是谁调控谁。共表达是相关，GRN 是有向、条件特异、稀疏的图。重建损失不惩罚“相关但错误”的边，因此注意力图与真实调控网络的重叠往往有限。

领域里有两条应对路线。第一条是**把先验收进结构**：GeneCompass 把 GRN、启动子、基因家族、共表达四类知识拼进输入；RegFormer 用 GRN 引导基因排序；CellVQ 用 GO 本体矩阵做位置先验。第二条是**把 GRN 当成第一目标**：scPRINT 的输出端不是重建值，而是每个基因的 ZINB 参数，并把注意力矩阵直接当作基因网络输出、用公开 GRN 基准评测。两条路线都比“事后解释注意力”更可信，但都受限于先验或真值的质量。

表 9　对 P8 的代表性回应

模型	路线	机制	边界
GeneCompass	先验注入	GRN / 启动子 / 基因家族 / 共表达四路拼接后投影	先验覆盖与质量决定上限
RegFormer	先验排序	GRN 层级引导基因顺序 + Mamba	人类单物种；独立复现少
scPRINT	GRN 为首要输出	双向 Transformer + ZINB，注意力即网络	注意力≠因果；真值本身有争议
CellVQ	本体先验	19,266×19,266 可训练 GO 矩阵（占总参数 73%）	参数效率极低；可解释性有限
Geneformer	in silico 扰动	删基因/改秩次，观察嵌入位移	相关性推断，非因果
scGPT	注意力 + 任务头	GRN 任务用注意力做边权重	注意力头不稳定，需扰动验证

> **判据**　与 ChIP-seq / Perturb-seq 的重叠率；held-out 转录因子的靶基因预测；注意力头消融后性能是否真的下降。三项都没有，就不要把注意力图当网络发表。

2.9　P9　扰动与因果：打不过加法基线

> 给定起始状态与干预，预测全转录组响应——这是当前最热也最难的问题。结论先说：纯端到端还没有赢过加法基线。

扰动的效应量通常很小，细胞间的异质性很大，技术噪声叠加其上。逐细胞回归会把异质性与噪声一起拟合，模型学到的是“平均细胞”，而不是“扰动效应”。更根本的是信号稀疏：在

Norman 双扰动数据上，FDR 5% 下 124,000 个基因对里只有 5,035 个（4.2%）是真实交互。也就是说，96% 的“交互预测”没有真值可学。

这正是 State 的设计动机：不预测单个细胞，而是预测 256 个细胞的集合分布，用 MMD/能量距离做损失。这样细胞异质性 H 与技术噪声 ε 被吸收进分布，模型只需要对准扰动效应 T。Arc 报告在 Tahoe-100M 上效应区分度提升 30% 以上、DEG 识别准确率翻倍（论文口径）。另一条路线是换生成范式：AlphaCell 用最优传输条件流匹配建模状态转移，Lingshu-Cell 用离散扩散做条件生成，CellOS 用 JEPA 在隐空间预测。它们的共同点是**不再复述输入**。

表 10　对 P9 的代表性回应

模型	学习信号	机制	代价
State	集合分布	256 细胞集合 + MMD/能量距离；SE 学表征、ST 学变换	需扰动数据；丢单细胞分辨率
scGPT	掩码生成	把被敲除基因设为未知，用已知基因外推	逐细胞目标；对分布偏移敏感
scFoundation	重建 + 深度扰动	RDA 模拟测序深度；掩码基因预测	非因果；需微调
AlphaCell	流匹配	OT-CFM 在 32×128 隐流形上建模状态演化	预印本；1.2B 解码器成本
Lingshu-Cell	条件扩散	离散扩散，按细胞类型/供体 × 扰动条件生成	采样慢；预印本
xTrimoSCPerturb	混合特征	改进 scFoundation + DEG 频率/平均表达统计特征	VCC 冠军方案；场景特定
线性 / additive	无	两个单扰动响应相加	最强基线；交互预测接近“无变化”

> **判据**　必须报告 DES（差异表达签名）、PDS（扰动区分度）、MAE，且分开报告“见过的扰动”与“未见的扰动”；对照必须包含 additive 与“预测无变化”两个朴素基线。只报 MSE 的扰动论文，结论不可采信。

2.10　P10　生成与多模态：从描述到干预

从“描述细胞”到“生成细胞”是一次目标函数的更换，不只是加一个解码头。

生成全转录组很难，因为要同时建模两万个相关维度、零膨胀、以及条件（细胞类型、供体、扰动）。多模态更难：RNA + 蛋白的 CITE-seq 数据量远小于纯 RNA，RNA + ATAC 的配对更少，空间数据的 panel 有限。现实中的多模态任务往往不是“融合”，而是“补全”——给定 RNA 预测蛋白，或给定解离数据预测空间位置。

CAPTAIN 是目前把蛋白模态做得最实的一个：426 万个共测细胞、382 种表面蛋白，蛋白 token 作为 query、RNA 嵌入作为 key/value 做交叉注意力，损失由 RNA 重建、蛋白 MSE、蛋白分位数三部分按 0.2/0.6/0.2 加权。它证明了“跨模态预训练”可行，但也暴露了边界：382 种蛋白的面板仍然很窄，物种被写死为人和鼠。多组学整合的系统评测（SCMBench，23 种方法）给出的结论更冷静：基础模型在多组学整合上不如领域专用方法。

表 11　对 P10 的代表性回应

模型	任务	机制	代价
scMulan	条件生成 / 注释 / 整合	细胞句子 + 实体/数值双头，改句尾任务词即换任务	10 档离散值；decoder-only 长序列
Lingshu-Cell	条件生成	离散扩散，覆盖约 18,000 基因	采样成本；预印本
AlphaCell	状态生成	全基因输入 + 流匹配 + 1.2B 解码器	解码器巨大；可解释性弱
scFoundation	重建 / 补全	非对称编解码，只编码非零位	固定 19,264 基因；MSE 被高表达主导
CAPTAIN	RNA → 蛋白	蛋白 query 交叉注意力到 RNA 上下文；分位数头	382 蛋白；物种写死
Nicheformer	解离 → 空间	空间语境预测 + 联合预训练	空间 panel 有限

判据　生成任务看分布距离与下游 DE 保真度，而不是单细胞 MSE；补全任务看“缺失模态”的校准（分位数覆盖）；多模态看“去掉一个模态后性能掉多少”。

2.11　P11　适配成本：最后一公里

基础模型的最后一公里不是精度，而是“能不能在别人的数据和预算上跑起来”。

预训练要数十张 GPU、数周；微调要调参经验，且对随机种子与超参高度敏感——Boiarsky 等发现 scBERT 的微调结果在种子间波动显著，去掉预训练也没有统计差异（p=0.34/0.59）。许可则是另一道门槛：Apache-2.0、MIT、GPL-3.0、CC BY-NC-ND、无 LICENSE 并存，很多模型在法律上不能商用。

工程上的解法已经比较成熟：冻结主干 + 线性探针（UCE、CellPLM、SCimilarity）、LoRA（CellFM）、轻量适配器（CellWhisperer 只训适配器与文本塔）、小模型（Geneformer 10M 参数，单卡可跑）、蒸馏与量化。这些手段能把“能不能用”变成“好不好用”，但不能把零样本变成万能。

表 12 降低适配成本的四条路径

路径	代表	做法	适用 / 代价
冻结 + 探针	UCE、CellPLM、SCimilarity	不更新主干，只训线性头	最省算力；上限受嵌入质量限制
参数高效微调	CellFM（LoRA）、scGPT（部分层解冻）	只更新低秩矩阵或最后几层	接近全参效果；仍需调参
适配器 / 双塔	CellWhisperer（Geneformer 冻结 + BioBERT）	只训模态接头	适合跨模态；精度受冻结塔限制
小模型 / 蒸馏	Geneformer（约 1,000 万参数）	用更小模型匹配数据规模	容量有限；跨域能力弱

> **判据** 用 10% 标注数据做微调，报告相对强基线的增益、调参预算（试了多少组超参）、以及单卡能否跑通。三项都过关，才叫“可用”。

2.12 P12 评测失焦：指标与生物学脱节

> MSE 被近零差异基因稀释，benchmark 饱和，排行榜不可比——评测已经成为独立的技术问题。

在扰动预测里，绝大多数基因的差异接近零，L2 与 Pearson delta 会被这些近零值主导：一个模型即使完全没学到交互，也能拿到“接近”的分数。更严重的是任务定义不一致：同样是“细胞注释”，有的用训练集内随机划分，有的用跨数据集；同样是“零样本”，有的排除了预训练重叠，有的没有。于是排行榜上的名次会随预处理、tokenization、指标而翻转。

2026 年 ICML 的一篇立场论文把这种现象命名为“可识别性失败”：benchmark 饱和不是因为能力到顶，而是因为指标无法区分“真会”与“记住”。对应的解法不是再刷一个榜，而是换任务化评测：VCC 用“能否替代一次 Perturb-seq 实验”定义任务，Cell_Eval 用七项指标覆盖 DES/PDS/MAE/Pearson/Spearman/AUPRC，scEval 把超参与训练稳定性列为核心维度。

表 13 评测体系的四层证据

层级	代表	回答的问题	局限
零样本	Kedzierska 2025、PertEval 2025	不微调能不能用	易被泄漏污染；强基线常常胜出
微调 / 少样本	scEval 2026、低监督评测 2026	给了标签能提升多少	超参与划分影响大
任务化	VCC 2025、Cell_Eval	能否替代一次实验	任务窄；成本高
审计	污染审计 2026、scContam	成绩是否可信	依赖语料公开

> **判据** 预注册指标；时间切分；盲测；公开复现包（种子、超参、算力、失败案例）。四条缺一，排行榜只能当参考，不能当结论。

2.13 十二条问题的相互位置

把十二个问题放回管线，会发现一个不舒服的事实：**只有 P3 与 P12 完全不在模型侧，而它们恰好决定了我们对其他十个问题的判断是否可信**。P1、P2、P4 是数据基础设施问题；P5–P8 是表示与目标的设计问题；P9、P10 是目标函数的换代问题；P11 是工程与许可问题。

表 14 十二条问题的责任归属与成熟度

问题	层	主要责任方	当前最好解法	成熟度
P1 规模幻觉	数据	数据联盟 / 模型方	多样性优先 + 数据选择	已识别，未解决
P2 噪声与批次	数据	测量 / 模型方	显式协变量 + 噪声建模	部分解决
P3 数据泄漏	数据	社区 / 评测方	时间切分 + 指纹审计	有解，执行不足
P4 长尾与偏移	数据	模型方 / 评测方	全基因词表 + 分层指标	部分解决
P5 词表与顺序	表示	模型方	蛋白语言模型身份	接近解决
P6 值的离散化	表示	模型方	软分箱 / 分布头	接近解决
P7 语境缺失	表示	模型方	细胞集合 / 空间联合预训练	早期
P8 重建≠理解	目标	模型方	先验注入 + 因果验证	早期
P9 扰动与因果	目标	模型方 + 湿实验	集合分布 / 流匹配 + 混合特征	早期，未证明
P10 生成与多模态	目标	模型方	条件扩散 / 跨模态注意力	早期
P11 适配成本	适配	工程 / 许可	冻结探针 / LoRA / 小模型	部分解决
P12 评测失焦	评价	评测方 / 期刊	任务化评测 + 预注册	有共识，缺标准

注：“成熟度”是作者依据公开证据的判断：已识别但无解、部分解决、接近解决、有解但执行不足、早期。

下一章转入架构。需要提醒的是：架构只能回答 P5–P10 的一部分，对 P1–P4 与 P11–P12 几乎没有直接作用。把架构当成万能药，是这个领域最常见的误配。

第 3 章

架构分类学：六个大类

> 分类的价值不在于贴标签，而在于预测代价。知道一个模型属于哪一类，就能在读论文之前大致说出它会强在哪、弱在哪、以及在什么数据上会失效。

3.1 分类原则：建模单元 × 学习信号

最常见的分类方式是按主干网络分：Transformer、Performer、RetNet、Mamba、扩散。这种分法对工程有用，对理解无用——同一个 Mamba 可以出现在两类完全不同的模型里（RegFormer 用它做掩码基因建模，AlphaCell 用它做状态转移编码），而它们的失败模式毫无共同点。

本报告用两个坐标分类。**横轴是建模单元**：一次前向传播里，模型把什么当作第一性对象——基因、细胞、整条表达谱、状态分布，还是自然语言。**纵轴是学习信号**：监督从哪里来——重建被遮住的部分、最大化序列似然、对齐另一个模态、还是在隐空间预测下一状态。两个坐标的可行组合只有六个，这就是六个大类。主干网络是第三个、正交的维度，单独在 §3.7 讨论。

图 3 把六个大类画成一棵树。需要强调的是，树上的位置由“第一性对象 + 学习信号”决定，而不是由主干决定；同一个模型可以同时挂在两个枝上（§3.9）。



图 3 六个架构大类：建模单元与学习信号的可行组合

表 15 六个大类在四个解剖位上的取值

类别	Tokenizer	Backbone	Objective	Interface
A 掩码基因序列	秩 / 硬分箱 / 软分箱 / 连续 / 蛋白身份	双向 Transformer、Performer、RetNet、Mamba	掩码重建（值或身份）	细胞/基因嵌入、注意力
B 自回归基因序列	表达值分箱 + 基因身份	因果或块掩码 Transformer	序列似然（含计数分布）	生成谱、条件生成
C 连续谱编解码	全基因向量 + 深度 token / 码本	非对称编解码、VQ、交叉注意力	重建（MSE / 分布）	去噪、补全、跨模态
D 细胞集合模型	细胞级向量（基因嵌入加权和）	集合/图注意力、线性注意力	集合距离、对比、下一细胞	扰动分布、细胞检索
E 状态分布模型	全基因或隐变量	扩散、流匹配、JEPA	去噪/流/隐空间预测	条件生成、状态转移
F 语言接口模型	基因名文本 / 自然语言描述	LLM、双塔对比	对比对齐、下一词	检索、零样本注释、对话

3.2 A 类　掩码基因序列：看一半，猜一半

这是最早、也最多的一类。它把细胞写成一条基因 token 序列，随机遮住一部分，让模型从上下文猜回来。形式化地：给定表达向量 x 与选中的基因集合 S，遮住子集 M⊂S，最小化 $\Sigma_{i\in M} \ell(f_\theta(x)_i, x_i)$。BERT 的配方几乎可以原样复用，所以 2021–2023 年的模型大多落在这里。

它的归纳偏置是“共表达即语法”：如果两个基因总是一起出现，模型就能互相推断。这个偏置在注释、检索、基因功能预测上很有效，因为这些都是“共表达足够”的任务。但同一偏置也决定了它的天花板——它只需要学相关，不需要学因果。

A 类内部的差异几乎全部来自 tokenizer，而不是主干。硬分箱（scBERT）最简单，但丢幅值与序；秩编码（Geneformer）抗深度差异，但丢绝对量；连续标量（CellFM）保留幅值，但怕噪声；蛋白身份（UCE）把词表打开，但把定量信息压成二分类；分布头（scPRINT）保留完整分布，但训练更难。**换句话说，A 类的竞争史就是一部 tokenizer 迭代史。**

表 16　A 类的七个变体

变体	代表	关键设计	换来了什么 / 付出了什么
硬分箱 + Performer	scBERT	16,906 基因、7 档、gene2vec 身份、无位置编码	首次证明 BERT 可行 / 200 维窄、词表封闭
秩编码 + 窄 BERT	Geneformer	除以基因中位表达后排序，2,048 token，6 层 256 维	抗深度、参数极省 / 丢幅值、截断丢低表达
知识拼接	GeneCompass	GRN/启动子/家族/共表达四路拼成 3,841 维再投影	先验可解释 / 首层参数大、依赖先验质量
蛋白身份	UCE	ESM-2 嵌入替代基因 ID，按表达加权抽 1,024 基因	词表无限、跨物种 / 表巨大、二分类目标
连续标量 + 线性注意力	CellFM	2,048 基因、MLP 投影标量、40 层 ERetNet	8 亿参数、长序列省算力 / 单物种、无生成
分布头 + 重测序去噪	scPRINT	ZINB 输出、泊松下采样、注意力即 GRN	概率输出、GRN 首选 / 2,200 基因上限
GRN 排序 + 状态空间	RegFormer	调控层级引导顺序 + Mamba	长序列、先验结构化 / 单物种、复现少

A 类的共同天花板　目标只奖励“重建自己”，不奖励“干预正确”。因此在零样本嵌入任务上，它最容易被 HVG + 逻辑回归追平；它的价值主要在微调后的域内任务，以及作为下游模型的初始化。

3.3　B 类　自回归基因序列：顺着往下写

B 类把细胞建模成一个概率序列：$p(x)=\prod_j p(g_j, c_j \mid g_{<j}, c_{<j})$。每一步先选“下一个基因是谁”，再决定“它有多少计数”。与 A 类的关键差别不是“能不能生成”，而是**训练信号是似然，不是重建**：模型必须给整个联合分布分配概率质量，而不能只对被遮的位置负责。

这带来两个能力：条件生成（给定前一半基因，补全后一半；给定对照细胞，生成扰动后细胞）与不确定性（计数分布自带方差）。也带来两个代价：推理必须逐 token 进行，成本随基因数线性增长；基因没有自然顺序，必须人为定义或随机打乱，前者引入顺序伪影，后者让同一份表达谱有多种等价写法。

表 17 B 类的三种写法

模型	序列怎么定义	学习信号	独特之处 / 代价
scGPT	1 个 CLS + 1,200 个 HVG，块状掩码	掩码值预测 + 细胞对比 + 条件 token	待预测基因只能看已知基因，天然支持“敲除后外推” / 每细胞分箱边界漂移
TranscriptFormer	2,047 个基因随机排列 + 检测 token	基因 softmax + 零截断泊松计数	计数进入注意力分数（log1p 偏置），似然覆盖全部基因 / 247k 输出头、自回归推理慢
scMulan	基因/元数据/任务词组成的“细胞句子”	实体预测 + 数值预测双头	元数据即 prompt，一个模型多任务 / 10 档离散值、decoder-only 长序列

B 类的共同天花板 似然目标要求模型对“所有可能的细胞”分配概率，但真实数据只覆盖极小的流形；模型很容易把概率质量堆在训练分布附近，对分布外扰动过度自信。这是所有生成式 scFM 在 VCC 上失分的主因。

3.4 C 类 连续谱编解码：压成向量，再还原

C 类不把细胞拆成基因 token，而是把整条表达谱当作一个对象：编码器把它压成向量 z，解码器再从 z 还原全部基因。形式化地：z=E(x_{nonzero})，x̂=D(z)，损失只在被遮位置或全部位置上计算。它的优势是显式建模“整谱”，适合去噪、补全、跨平台迁移；代价是基因间关系被压进一个向量，基因级的分辨率与可解释性下降。

三个子型值得区分。**非对称稀疏编解码**（scFoundation）只把非零位送进编码器，把 90% 的零挡在外面，计算省一个量级；**离散瓶颈**（CellVQ）把细胞压成码本里的一个整数，换取“细胞语言”的接口；**跨模态编解码**（CAPTAIN）让蛋白 token 去查询 RNA 上下文，把“补全缺失模态”变成主要任务。

表 18 C 类的三个子型

子型	代表	关键机制	代价
非对称稀疏编解码	scFoundation、xTrimoGene	只编码非零位；末尾拼 T/S 深度 token；软分箱；30% 掩码 MSE	固定 19,264 基因；MSE 被高表达主导
离散瓶颈 / 量化	CellVQ	12 层编码 + 6 层 Performer 解码；2^16 码本；32 维码字	32 维瓶颈；码本坍塌风险
跨模态编解码	CAPTAIN	蛋白 token 作 query、RNA 作 key/value；RNA/蛋白/分位数三损失	382 蛋白面板；物种写死为 2

C 类的共同天花板 重建损失对高表达基因敏感、对低表达基因几乎无约束；而生物学信号往往在低表达端（转

录因子、稀有标记）。这就是为什么“重建得像”不等于“下游有用”。

3.5 D 类 细胞集合模型：细胞看细胞

D 类把建模单元从基因换成细胞。每个细胞先压成一个向量（通常是基因嵌入按表达量加权求和），然后让同一张切片、同一组样本或同一批扰动里的细胞互相注意。形式化地：e_i=W^T x_i，H=Transformer({e_i})，输出是细胞的表示或细胞集合的分布。

它解决的是“细胞不是孤岛”这个根本问题：同一组织里的细胞共享微环境，同一扰动下的细胞共享处理条件。代价也很直接：基因间关系在第一步加权求和时就被抹掉了，模型只能通过细胞间的差异间接恢复；推理时需要邻域或切片，单细胞场景不适用。

表 19 D 类的四种写法

模型	集合的定义	关键机制	代价
CellPLM	一张切片内的 N 个细胞	稀疏矩阵乘得细胞向量；4 层 Flowformer；16 分量高斯混合	基因关系被压平；需切片上下文
State	256 个对照细胞 + 扰动条件	SE 学表征（1.67 亿细胞）、ST 学变换（1 亿扰动细胞）；MMD/能量距离	不做空间；集合丢单细胞分辨率
tGPT	组织内的细胞序列	下一细胞预测，细胞为 token	顺序人为；分辨率下降
Tahoe-x1	药物扰动下的细胞群	每细胞 1,024 token；大规模药物×细胞系矩阵	依赖 Tahoe-100M 数据；泛化待验证

D 类的共同天花板 集合级目标天然牺牲单细胞分辨率：它能告诉你“扰动后这群细胞整体往哪走”，但不能告诉你“某一个细胞会怎样”。前者对药物筛选够用，后者对精准医学不够。

3.6 E 类 状态分布模型：学分布，不学点

E 类是 2025–2026 年最新、也最值得关注的一类。它不把细胞当成一个点，而把细胞状态当成一个分布，把扰动当成分布之间的变换。学习信号不再是“重建这个细胞”，而是“把起始分布搬运到终止分布”：扩散模型学去噪路径，流匹配学速度场，JEPA 在隐空间预测另一视角的表示。

这批模型的共同主张是：单细胞观测里的异质性 H 与技术噪声 ε 不应该被拟合，而应该被边缘化。只要预测出的分布与真实分布接近，H 就被保留而不是被抹平。这是对 P2 与 P9 的直接回应，也是对“逐细胞 MSE”的正面否定。

表 20　E 类的四条路线

模型	生成机制	条件方式	代价
Lingshu-Cell	掩码离散扩散	细胞类型/供体 × 扰动条件；约 18,000 基因	采样慢；预印本
AlphaCell	最优传输条件流匹配（OT-CFM）	全基因 → 32×128 隐流形 → 1.2B 解码器	解码器巨大；可解释性弱
CellOS	LLM-JEPA 双视角联合嵌入预测	表达视角 + 群体感知视角；12B MoE	厂商口径；未开源
scDifformer	预训练 + 扩散后训练 + 微调	把扩散作为后训练阶段，不换主干	细节披露有限

E 类的共同天花板　评测还没跟上。现有基准大多用 MSE/Pearson 打点预测，而 E 类输出的是分布；用点指标评分布模型，等于用尺子量温度。Cell_Eval 与 VCC 是少数尝试，但仍不成熟。

3.7　F 类　语言接口模型：把细胞翻译成人话

F 类不追求“更好的细胞表示”，而追求“细胞与语言的共用坐标系”。两条路径：一条把细胞序列化成基因名文本，直接交给 LLM（Cell2Sentence）；另一条用对比学习把表达谱与文本描述对齐（CellWhisperer、LangCell）。GenePT 是极端案例：不训练任何表达模型，只用 ChatGPT 给基因描述做嵌入，再把细胞表示为基因嵌入的加权和。

它的价值在冷启动与可解释性：用户可以用自然语言查询细胞、给 UMAP 上色、零样本注释新类型。代价是定量精度——文本塔读到的是“描述”，不是“计数”；对比学习能对齐语义，但不能恢复幅值。

表 21　F 类的四种写法

模型	接口	关键机制	代价
Cell2Sentence	细胞 → 基因名句子	按表达排序的基因名序列，微调 GPT-2	丢幅值；长序列；基因名分词
GenePT	基因 → 文本嵌入	ChatGPT 描述嵌入，细胞为加权和	不学表达；文本质量决定上限
LangCell	细胞 ↔ 文本对比	细胞-文本配对预训练	配对数据稀缺；语义对齐≠定量
CellWhisperer	检索 / 对话	Geneformer 冻结 + BioBERT；108 万对；2,048 维共享空间	caption 噪声；检索不是生成

F 类的共同天花板　语言能表达“这是什么细胞”，但很难表达“表达量是多少、扰动后变化多少”。它最适合做入口（检索、注释、解释），不适合做定量预测的终点。

3.8 主干是正交维度：能读多长、多快，不决定学什么

把主干单列，是因为它经常被误当成分类依据。事实上，主干只回答三个工程问题：能读多长的序列、每层多贵、能不能并行。它不改变学习信号，因此也不改变模型的失败模式。

表 22 六种主干：复杂度、使用者与代价

主干	复杂度	代表模型	优势	代价
标准 Transformer	$O(N^2)$	Geneformer、scGPT、TranscriptFormer、GeneCompass	生态成熟、表达力强	2,048 token 已接近显存上限
Performer（FAVOR+）	O(N)	scBERT、scFoundation、CellVQ 解码器	可读 1.9 万基因全长	核近似误差；数值不稳
RetNet	O(N)	CellFM	线性注意力 + 并行训练	门控核需调参；生态少
Mamba / SSM	O(N)	RegFormer、AlphaCell	长序列、显存友好	选择性扫描实现复杂；长程依赖弱
Flowformer	O(N)	CellPLM	切片内上万细胞可行	近似注意力；实现少
扩散 / 流匹配网络	O(T·N)	Lingshu-Cell、AlphaCell、scDiffformer	建模分布与转移	采样慢；训练不稳定

3.9 混血与边界：分类是为了预测代价，不是为了贴标签

现实中的模型经常跨类。RegFormer 是 A 类的目标（掩码基因建模）加 Mamba 主干；CAPTAIN 是 C 类的编解码加跨模态注意力；scGPT 是 B 类的生成目标加块状掩码；CellVQ 是 C 类的自编码器加离散瓶颈；State 是 D 类的集合编码加 E 类的分布损失。把它们硬塞进一个格子，会丢失最重要的信息。

本报告的处理方式是：**按“主要目标”归类，按“机制”标注混血**。分类的作用是让你在拿到一个新模型时，先问三个问题：它的第一性对象是什么？它的损失在奖励什么？它的结构性代价是什么？三个问题答完，你不需要读完整篇论文，就能判断它适不适合你的任务。

> **一个反例** 把 CellVQ 归为“生成模型”是常见的误读。它的主目标是“把细胞压成可检索的码字”，生成只是解码器的副产物；它的 73% 参数花在 GO 本体矩阵上，说明它本质上是“本体先验 + 量化检索”。归类错了，代价就会估错。

第 4 章

逐模型：独特之处与代价

> 这一章不重复论文摘要，只回答一个问题：这个模型做了什么别人没做的事，为此付出了什么代价。

先给速查表。表中的“语料”与“参数”尽量采用论文或官方模型卡的口径；不同论文的细胞计数方式不同（是否去重、是否质控后、是否含多物种），跨行比较只作数量级参考。许可一栏区分代码许可与权重许可，二者不一致时以更严格者为准。

表 23　二十七款单细胞大模型速查表

模型	类	首曝	机构	预训练语料	参数	模态	许可
scBERT	A	2021.12	腾讯 AI Lab	110 万（PanglaoDB）	未公开	RNA	GPL-3.0
Geneformer	A	2022.08	Gladstone/UCSF	2,990 万（V2 9,500 万）	10M / 106M	RNA	开源*
scGPT	B	2023.04	多伦多/Vector	1,030 万（全量 3,300 万）	53M	RNA+ATAC	MIT
scFoundation	C	2023.05	清华/百图	5,000 万	100M	RNA	Apache-2.0
UCE	A	2023.11	Stanford	3,600 万 / 8 物种	650M	RNA	MIT
xTrimoGene	C	2023.11	百图/清华	>5,000 万	未公开	RNA	API
Cell2Sentence	F	2023.09	Princeton 等	—	GPT-2 级	RNA+文本	开源
GenePT	F	2023.09	Stanford	无需训练	0	RNA+文本	开源
scMulan	B	2024.01	清华大学	约 1,000 万	368.8M	RNA	CC BY-NC-ND
CellPLM	D	2024.03	MSU 等	1,140 万	82.4M	RNA+空间	BSD-2
scPRINT	A	2024.05	Mila 等	5,408 万	2M–100M	RNA	GPL-3.0
Nicheformer	A	2024.07	Helmholtz	1.1 亿（5,700 万解离）	49.3M	RNA+空间	BSD-3
GeneCompass	A	2024.10	中科院	1.0177 亿（人+鼠）	>100M	RNA	无许可
TranscriptFormer	B	2025.04	CZI	1.12 亿 / 12 物种	444M 可训	RNA	MIT
CellFM	A	2025.05	中山大学/华为	1.02 亿	800M	RNA	Other
State	D	2025.06	Arc Institute	1.67 亿 + 1 亿扰动	未公开	RNA+扰动	非商用
Tahoe-x1	D	2025.12	Tahoe Therapeutics	9,560 万（Tahoe-100M）	未公开	RNA+扰动	Apache-2.0
CellVQ	C	2025.11	华大研究院等	6,800 万	511M	RNA	见论文
CellWhisperer	F	2025.11	CeMM	108 万对（RNA-文本）	未公开	RNA+文本	—
LangCell	F	2024.05	清华等	—	—	RNA+文本	开源
AlphaCell	E	2026.03	同济 DELTA	未公开	1.2B 解码器	RNA	预印本
CAPTAIN	C	2026.05	湖南大学等	426 万（CITE-seq）	未公开	RNA+蛋白	见论文

模型	类	首曝	机构	预训练语料	参数	模态	许可
RegFormer	A	2026.06	华大研究院	2,500 万 / 45 组织	未公开	RNA	见论文
scDifformer	E	2026.07	之江/华大	未公开	未公开	RNA+空间	CC BY-NC
CellOS	E	2026.07	百曜科技	3.905 亿（厂商口径）	12B MoE	RNA	未开源
Lingshu-Cell	E	2026.08	阿里达摩院	未公开	未公开	RNA	预印本
tGPT	D	2022	同济大学	2,200 万	未公开	RNA	开源

注：* Geneformer 的代码与权重许可在不同版本中不完全一致，商用前需逐一核对。“无许可”指仓库中没有 LICENSE 文件，法律上默认保留所有权利。未公开项标注“未公开”，未做推测。

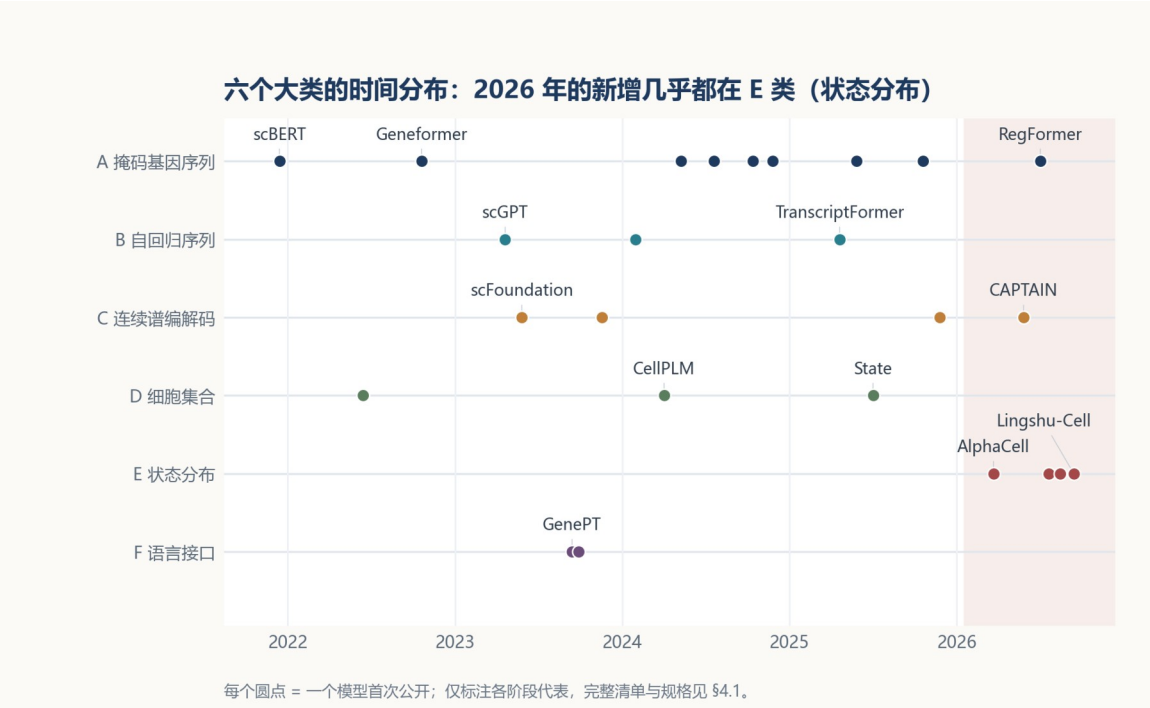


图 4 六个大类的时间分布：2026 年的新增几乎都在 E 类（状态分布）

按首次公开时间近似归位；每个圆点是一个模型，标注的是各阶段代表。完整规格见上表。

4.1 A 类：八个模型的独特之处

4.1.1 scBERT：第一个把 BERT 搬到转录组

独特设计：用 gene2vec 的基因身份向量替代 BERT 的位置编码。这个替换很聪明——基因没有顺序，但基因之间有功能相似性，gene2vec 恰好提供了“相对位置”。序列长达 16,907 个位置，标准注意力装不下，于是用 Performer 的线性注意力（FAVOR+）把 $O(N^2)$ 降到 $O(N)$。预训练只遮非零表达（15%），避免模型把“零”学成默认答案。

代价：200 维的模型宽度是被 gene2vec 的维度定死的，容量偏小；词表固定为 16,906 个基因；Performer 的核近似有误差。后续评测显示，PBMC 上 L1 逻辑回归在 accuracy 与 macro-F1 上都胜过它，去掉预训练也没有统计差异。它的历史意义大于实用价值。

4.1.2 Geneformer：用“排行榜”代替表达值

独特设计：rank value encoding。先把每个细胞的总计数拉到 10,000，再逐基因除以它在 3,000 万细胞里的中位表达，最后只取非零基因、按数值降序排成 2,048 个 token。除中位表达这一步是关键：它把 ubiquitously 高表达的管家基因压到后面，把“平时不表达、一旦表达就决定身份”的转录因子顶到前面。模型只有 6 层、4 头、256 维、约 1,000 万参数——刻意做小，以匹配数据规模。

代价：绝对幅值完全丢失，两个排序相同的细胞得到同一条序列；dropout 掉一个计数会让整条排名平移；2,048 截断会切掉 7% 细胞的尾部。它的 in silico 扰动（删基因、改秩次）是相关性推断，不是因果。但在数据稀缺的网络生物学任务上，它是第一个证明“迁移学习有效”的模型。

4.1.3 GeneCompass：把四类生物先验拼进输入

独特设计：五路拼接再投影，而不是逐元素相加。每个基因位置把基因 ID（768 维）、表达值（1 维）、GRN 嵌入（768）、启动子嵌入（768）、基因家族嵌入（768）、共表达嵌入（768）沿特征维拼成 3,841 维，再投影回 768。拼接保留了“这一维来自哪一路”的身份，代价是首层参数从 768^2 涨到 $3{,}841\times768$。跨物种用同源索引：鼠基因先映射到人同源 ID，再查同一套知识表；物种 token 放在第 0 位。

代价：知识质量决定上限；只有人和鼠两个物种；仓库无 LICENSE，商用有法律风险。但它是少数做了湿实验闭环的模型——用预测的候选基因诱导 hESC 向生殖腺方向分化，这在这类论文里并不常见。

4.1.4 Nicheformer：同时学解离与空间

独特设计：在排序前多除一次“技术特异的非零均值”——每个基因在同类技术里的平均非零表达。空间数据的 panel 小、预处理不同，若用全局均值，平台差异会被当成生物学差异写进排名。序列前加三个上下文 token（物种、技术、模态），并用可学习的位置嵌入（因为名次本身携带强度语义）。预训练 1.1 亿细胞，其中 5,300 万是空间细胞。

代价：空间数据以 targeted panel 为主，不等于所有空间平台；空间标签覆盖有限；排序仍丢幅值。它的价值在于证明“只在解离数据上训练的模型学不会空间微环境”，并展示把空间信息迁移回普通 scRNA-seq 的路径。

4.1.5 UCE：没有基因词表的通用嵌入

独特设计：基因身份来自 ESM-2 蛋白嵌入（5,120 维压到 1,280），不是学出来的词表。细胞表示是“按表达量加权、有放回抽 1,024 个基因”的多重集，再按染色体分组、组内按基因组位置排序，加上染色体起止 token 与 CLS。因为基因身份由蛋白序列决定，新物种只要有氨基酸序列就能嵌入——这是它零样本跨物种的根本原因。

代价：每次抽样都不同，复现需固定种子；145,469×5,120 的嵌入表要常驻显存；预训练目标是“表达/不表达”二分类，定量信息被压掉。它是“通用坐标系”的最佳代表，但不是定量任务的最佳选择。

4.1.6 CellFM：8 亿参数的国产算力路线

独特设计：用 RetNet 的线性注意力替代标准 Transformer，40 层、48 头、1,536 维，序列 2,048 个基因 + CLS；每个位置只带基因 ID 与一个连续标量，标量过 MLP 投到 1,536 维，不再分箱。训练在 MindSpore + 32 张昇腾 910 上完成，是“非 NVIDIA 栈”的少数公开案例。

代价：单物种（人类）；800M 参数与下游增益之间没有解耦证据；许可标注为“Other”，商用需逐一确认。它的意义更多在工程侧——证明国产算力可以训练亿级参数的单细胞模型。

4.1.7 scPRINT：把基因网络当作第一目标

独特设计：输出端不是重建值，而是每个基因的 ZINB 参数（μ、θ、π）；训练不是遮 token，而是用泊松下采样 + dropout 重新模拟一次测序，让模型学“从稀疏还原稠密”。基因 token 由三路相加：ESM-2 蛋白嵌入、表达量 MLP、基因组位置正弦编码。注意力矩阵直接当作基因网络输出，并用公开 GRN 基准评测。

代价：2,200 个基因的上下文上限；80B token 的训练成本不低；注意力是否等于调控仍有争议。但它是少数把“可解释输出”当成主任务而不是副产品的模型。

4.1.8 RegFormer：GRN 引导的基因排序 + Mamba

独特设计：用基因调控层级决定基因顺序，把“谁调控谁”变成序列先验；双嵌入（表达值 + 基因 token）后接 Mamba 状态空间，把长基因序列的复杂度降到线性。2,500 万人类细胞、45 种组织，任务覆盖聚类、整合、注释、GRN 重建、扰动与药敏。

代价：人类单物种；GRN 先验的质量决定上限；2026 年新刊，独立复现还少，“全面优于”是作者口径。它代表了“先验结构化”这条路线在 2026 年的最新形态。

4.2 B 类：三个模型的独特之处

4.2.1 scGPT：块状掩码让“敲除”变成一次前向

独特设计：注意力掩码不是 GPT 的因果掩码，也不是 BERT 的随机遮挡，而是按“CLS / 已知基因 / 待预测基因”分组的块状掩码：待预测基因只能看 CLS 与已知基因，已知基因之间互相可见。于是“预测未知”变成“用已知外推未知”，而不是“抄自己”。这解释了它为什么能做扰动预测——把被敲掉的基因设为未知即可。预训练目标是 GEP（掩码值预测）+ GEPC（细胞级对比）+ ECS（条件重构），条件 token 把批次与模态加到每个位置。

代价：每个细胞的分箱边界不同，“bin 3”在不同数据集里含义不同；1,200 个 HVG 限制了基因覆盖；zero-shot 在多项独立评测中不敌简单基线。它仍是生态最完整的模型之一（教程、微调 recipe、社区），但“基础模型”的光环需要打折。

4.2.2 TranscriptFormer：用计数分布做跨物种生成

独特设计：自回归分解为“先选基因、再定计数”：p(g_j, c_j | 前序)，输出基因 softmax 头与零截断泊松（ZTP）头。计数不是被动输入，而是进入注意力分数：score + log1p(count)，并用 tanh 软截断防止超高表达基因主导 softmax。基因身份用冻结的 ESM-2 蛋白嵌入，词表 247,388 个基因，覆盖 12 个物种、15.3 亿年进化跨度。

代价：247k 输出头很宽；自回归推理慢；随机排列意味着同一表达谱有多种写法，训练必须靠打乱让模型对排列不敏感。它是目前“生成式 + 跨物种”结合得最好的模型，也是最贵的之一。

4.2.3 scMulan：元数据也是一句话

独特设计：把细胞写成“（实体, 数值）二元组”的句子：基因词是（基因名, 1–10 档表达量），元数据词是（器官/细胞类型/性别/平台, 0），任务词是（<cell type annotation>, 0）。模型是

decoder-only、无位置编码、句内随机打乱；输出端两个头：EP 判断“下一个实体是谁”，VP 给每个候选实体一个连续数值。改句尾的任务词，就切换注释、整合、生成。

代价：10 档离散表达值损失精度；decoder-only 在长句子上成本高；预印本，1,000 万细胞在今天不算大。但它是“元数据感知 + 多任务提示”这条路线最完整的实现。

4.3 C 类：四个模型的独特之处

4.3.1 scFoundation：把 90% 的零挡在编码器外

独特设计：非对称编解码。编码器只接收“非零且未被遮”的位置（约全长的 10%），解码器接收全部 19,266 个位置（19,264 基因 + T/S 两个深度 token）。表达值用可学习的软分箱：标量先过 Linear(1→bin_num)、LeakyReLU、再过一个线性层，softmax 成权重，与桶向量表加权求和——没有硬边界。位置嵌入 19,267×512，损失只在被遮的 30% 位置上按 MSE 计算。

代价：固定 19,264 个人类基因；MSE 被高表达基因主导；RDA 的深度缩放因子是超参。它的 scaling law 是预训练损失层面的，不能直接推下游。但“非对称稀疏”这个设计非常务实，后续不少模型沿用。

4.3.2 xTrimoGene：把稀疏性做成商业 API

独特设计：与 scFoundation 同源的非对称思路，但更早把“稀疏编码 + 读深感知”产品化，通过 BioMap API 提供扰动、药敏、注释服务，不开源。

代价：不可审计、不可本地部署；技术细节披露有限。它代表了“模型即服务”的路线，在药企场景有现实需求，但对学术复现不友好。

4.3.3 CellVQ：把一个细胞压成一个整数

独特设计：12 层 Transformer 编码 + 6 层 Performer 解码，SoftCVQ 把细胞压成 2^16 码本里的一个码字（32 维），同时输出 831 种细胞类型、377 种组织、150 种疾病等属性。位置先验不是外部 GO 矩阵，而是一张 19,266×19,266 的可训练单位阵——这张表本身就有 3.71 亿参数，占总参数的 73%。

代价：32 维瓶颈限制了表达细节；码本坍塌风险；参数效率极低。它的价值在于“细胞级离散码”这个接口——一旦细胞变成整数，就可以像词一样被检索、被语言模型消费。

4.3.4 CAPTAIN：让蛋白去“读”RNA

独特设计：交叉注意力的方向是这张图的灵魂：蛋白 token 是 query，RNA 嵌入是 key/value。每个蛋白根据自己的 token 向量，去 3,001 个基因位置里加权取信息；输出是每个蛋白的丰度与四个分位点（0.1/0.25/0.75/0.9），损失权重 0.2/0.6/0.2。RNA 侧从 scGPT 权重初始化，物种用两张独立的 gene2vec 表，训练时人和鼠必须分开组 batch。

代价：382 种蛋白的面板仍窄；物种写死为 2；蛋白数据远少于 RNA。但它是 CITE-seq 规模化预训练的第一个严肃尝试，把“补全缺失模态”变成了可训练的目标。

4.4 D 类：四个模型的独特之处

4.4.1 CellPLM：把切片写成一串细胞

独特设计：细胞是 token，不是基因。先用稀疏矩阵乘把每个细胞的基因嵌入按表达量加权求和，得到 1,024 维细胞向量；再让 4 层 Flowformer 在同一张切片的 N 个细胞之间做线性复杂度注意力；隐空间是 16 分量高斯混合，批次标签只进解码器。空间转录组用 2D 正弦位置编码，普通 scRNA-seq 用一个共享向量顶上。

代价：基因间关系在加权求和时被抹平；推理需要切片或邻域；公开代码里位置编码被旁路（pe = 0），与论文不完全一致。它的工程价值很高——推理快、显存友好、适合“冻结嵌入 + 轻量头”。

4.4.2 State：预测 256 个细胞，而不是 1 个

独特设计：两个模块、两种数据。SE 在 1.67 亿观测细胞上学稳健表征（top 2,048 基因 + CLS + 数据集 token + 10 箱软分箱）；ST 在 1 亿多扰动细胞上学“对照 → 扰动”的变换：256 个对照细胞过 MLP 到 768 维，加上同一个扰动的嵌入，送进 8 层双向 Transformer（无位置编码、无 CLS），损失是集合之间的 MMD/能量距离。

代价：非商用许可；集合预测丢单细胞分辨率；依赖大规模扰动数据。但它是第一个把“分布级损失”做成主流的模型，也是 VCC 之后最常被引用的扰动基线。

4.4.3 tGPT：把细胞当词

独特设计：与“基因即词”相反，tGPT 把每个细胞压成一条按表达排序的基因列表，再把细胞序列当作文本做下一细胞预测。它是最早的“细胞级语言模型”，能生成细胞轨迹。

代价：单细胞分辨率下降；细胞顺序人为；后续基准表现参差。它的历史价值在于提示了一个方向：建模单元可以是细胞，而不必是基因。

4.4.4 Tahoe-x1：药物扰动矩阵上的基础模型

独特设计：建立在 Tahoe-100M 之上——50 个细胞系混在一孔、加一种药，用孔内条码与单细胞 SNP 两套正交编码拆开，产出 9,560 万细胞 × 62,710 基因、52,886 个“细胞系 - 药物 - 剂量”条件。模型把每个细胞写成 1,024 个 token，直接学扰动响应。

代价：强依赖自有数据；跨实验室泛化待验证；药物与细胞系的覆盖仍有偏。它的价值在于证明“数据生产管线本身就是模型能力的一部分”。

4.5 E 类：四个模型的独特之处

4.5.1 Lingshu-Cell：把转录组当离散分布去噪

独特设计：掩码离散扩散。不预选 HVG，覆盖约 18,000 个基因；训练时把表达谱当作离散 token 加噪、去噪，推理时按“细胞类型/供体 × 扰动”条件生成。它不重建某一个细胞，而是学“这个条件下的表达分布”。

代价：采样慢；预印本，独立复现少；“VCC 领先”是作者口径。但它是 E 类里最彻底“换目标函数”的一个。

4.5.2 AlphaCell：在隐流形上做最优传输

独特设计：19,253 个 HGNC 基因全量输入，Mamba + Transformer 压到 32×128 的连续隐流形，再用 OT-CFM（最优传输条件流匹配）建模扰动后的状态演化；1.2B MoE 解码器保证“隐空间任意点都能翻回真实表达谱”。它把自己定位成“世界模型”：学的是状态转移算子。

代价：解码器巨大；可解释性弱；预印本。它代表了“连续时间生成”这条路线。

4.5.3 CellOS：JEPA 的双视角

独特设计：不重建输入，而是在隐空间做联合嵌入预测：一个视角是表达谱，另一个是“群体感知”视角，模型学的是两个视角表示之间的一致性。Dense-to-MoE 扩到 12B，语料 3.905 亿细胞（厂商口径）。

代价：未开源、无独立复现；MoE 推理成本高；Pearson_edist 0.619 对 0.373 的对比是厂商口径。它值得关注的是“JEPA 用于细胞”这个思路，而不是具体数字。

4.5.4 scDifformer：把扩散当后训练

独特设计：不换主干，而是在预训练之后加一个扩散后训练阶段，再做任务微调。三步范式（预训练—扩散后训练—微调）把扩散的生成能力“嫁接”到已有表征上，同时用于空间反卷积。

代价：细节披露有限；三步流程的调参复杂度高。但它是“务实改良”的代表——不追求新架构，只改训练流程。

4.6 F 类：四个模型的独特之处

4.6.1 Cell2Sentence：细胞就是一句话

独特设计：把细胞按表达量排序，取前若干基因的**名字**拼成自然语言句子，直接微调 GPT-2。不需要新词表、不需要改架构，复用 LLM 的语义先验。可用于细胞生成、补全、注释。

代价：表达幅值丢失；基因名分词不稳定；长序列。它的价值是“零改造”的思路——任何 LLM 都能尝试。

4.6.2 GenePT：不训练模型，只问 ChatGPT

独特设计：用 ChatGPT 给每个基因的描述做文本嵌入，细胞表示就是基因嵌入按表达的加权和。没有 GPU、没有预训练，却在不少任务上“简单但难打败”。

代价：完全不学表达感知的表示；文本质量决定上限；无法做生成。它是对“必须训练大模型”这个假设的最有力反例。

4.6.3 LangCell：细胞与文本的对比对齐

独特设计：细胞-文本配对预训练，用自然语言描述细胞身份，做零样本/文本引导的注释。

代价：配对数据稀缺；语义对齐不等于定量理解。它属于 F 类里“对齐派”，与 CellWhisperer 同路。

4.6.4 CellWhisperer：给 UMAP 上色的一句话

独特设计：CLIP 式双塔：表达谱走 Geneformer（全程冻结），文本走 BioBERT，各接一个适配器压到 2,048 维，用 108 万对“转录组 - 文本”做对比学习。文本不是原始元数据，而是用

GPT-4 把表格重写成有生物学信息量的句子。检索就是一次点积，所以“用一个词给整张 UMAP 上色”在数学上是余弦相似度。

代价：caption 由模型生成，元数据缺失时会“补全”，标签噪声从第一天进入监督；检索不是生成；基因表达塔被冻结，无法为对齐调整。但它是“自然语言接口”最落地的实现，零样本检索 AUROC 0.927。

4.7 边界之外：五款值得知道的模型

表 24 未单列但值得关注的模型

模型	定位	一句话
SCimilarity	细胞检索	2,340 万细胞、412 项研究的度量学习，跨研究找“相似细胞”，不开箱即用的生成
PULSAR	多细胞组织语境	显式建模 cell–cell interaction 与组织上下文，预印本
Atacformer	scATAC 专用	以 peak 而非基因为 token，覆盖约 1 万个 scATAC 实验
AIDO.Cell	规模化研究	系统研究 300 万 – 6.5 亿参数与转录组尺度上下文的影响
scPlantLLM	植物专用	植物单细胞整合、注释、GRN，说明通用人/鼠模型迁移有限

4.8 三个被高估、三个被低估

被高估的三件事：第一，参数量。8 亿与 1 亿的差别，在下游任务上经常小于超参选择的差别。第二，zero-shot。多项独立评测显示它常常不如 HVG + 逻辑回归，而“零样本”成绩还可能被预训练污染抬高。第三，注意力即解释。注意力权重是路由，不是因果；把它当 GRN 发表，是这三年最常见的过度声明。

被低估的三件事：第一，tokenizer。同分布评测时换 tokenizer 几乎没差别，一旦跨组织、跨物种、跨 panel、逆扰动，它就成了决定性因素。第二，数据配比与去重。它不产生论文，但决定所有模型的上限。第三，评测协议与强基线。一个诚实的基线表，比一个新架构更能推动领域。

第 5 章

交叉矩阵：哪类架构回应了哪个问题

> 把第二章的十二个问题与第三章的六个大类放进同一张表，会看到一条清晰的边界：越靠近数据层，架构越无能为力；越靠近目标层，换损失比换主干更有效。

5.1 覆盖矩阵怎么读

图 5 的每一行是一个问题，每一列是一个架构大类。圆点越大，表示该类的核心设计越直接地针对该问题；空白表示该类在这个问题上没有结构性优势，而不是“完全没提”。判定依据是各模型公开的机制与评测，不是论文里的自述。

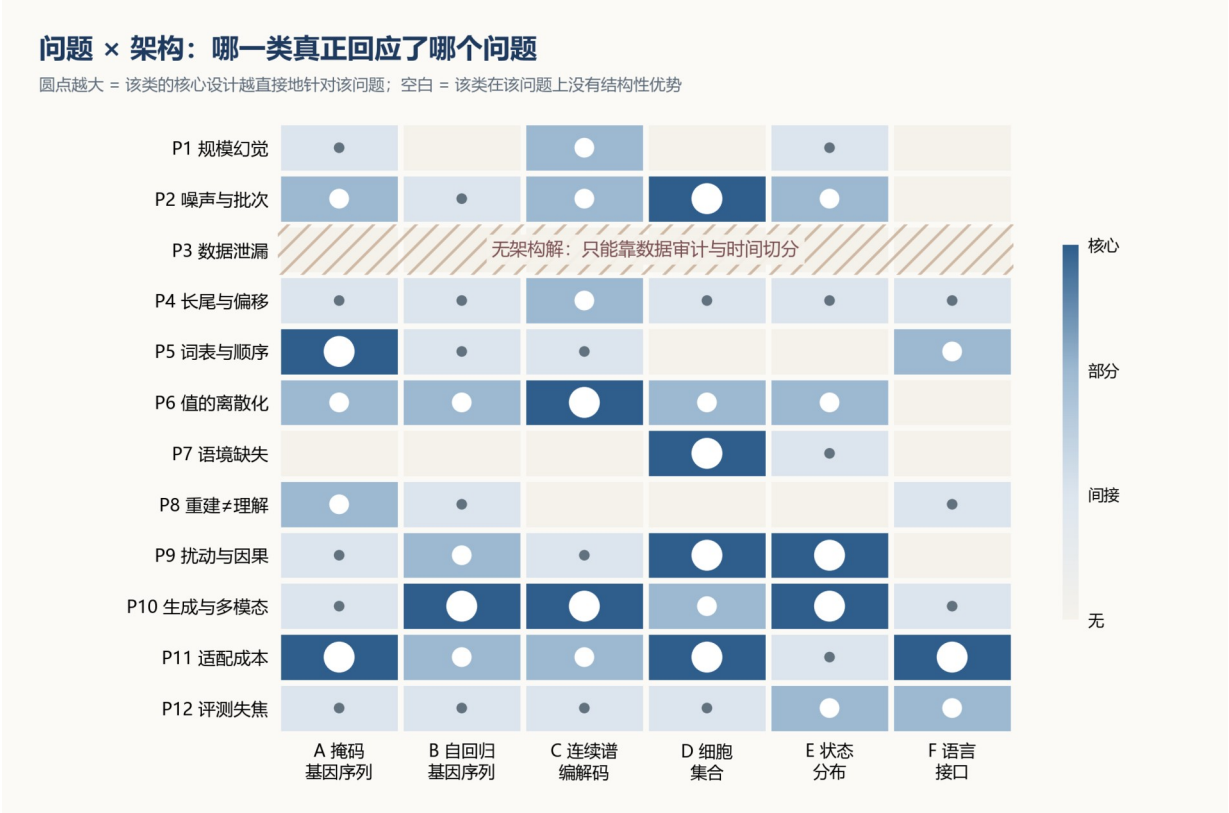


图 5　问题 × 架构覆盖矩阵（作者依据机制与公开评测判定）

空白不等于无关：例如 A 类也会报告批次整合指标，但它的结构里没有专门处理批次的机制。矩阵衡量的是“结构性回应”，不是“是否提及”。

两个立刻可见的结论。第一，**P3（数据泄漏）整行为空**——没有任何架构能解决它，只能靠数据审计与时间切分。第二，**P11（适配成本）几乎每列都有点**——因为适配是工程问题，所有类都可以通过冻结、LoRA、小模型来缓解，区别只在程度。

5.2 五条规律

规律一：越靠近数据层，架构越无能为力。 P1、P2、P3、P4 四个问题里，只有 P2 有真正的架构解（显式协变量、噪声建模、集合损失），其余三个只能靠数据工程与评测制度。把希望寄托在“更大的模型”上，是这类问题最常见的误配。

规律二：表示层的问题，被“词表无关 + 软编码”缓解得最好。 P5 与 P6 是过去两年进步最快的两个问题。蛋白语言模型让基因身份不再依赖固定词表；软分箱与分布头让表达值不再被硬边界切断。这两项改进的成本都不高，收益却跨任务可见。

规律三：目标层的问题，必须换损失，不能换主干。 P8、P9、P10 三个问题的共同点是“奖励函数错了”。把 Transformer 换成 Mamba、把 12 层加到 40 层，都不会让模型从“重建”转向“预测干预”。State 的集合损失、AlphaCell 的流匹配、Lingshu 的条件扩散，都是从损失入手。

规律四：D 类与 E 类在扰动上领先，代价是分辨率与可解释性。 集合/分布级模型天然适合“扰动后这群细胞往哪走”，但不回答“某一个细胞会怎样”；扩散/流匹配模型能给出分布，却很难解释“为什么这个基因变了”。这不是实现缺陷，是建模单元决定的。

规律五：F 类在检索、注释、冷启动上最强，在定量任务上最弱。 语言接口把“细胞是什么”变成了可查询的语义，但它读不到“多少”。用 CellWhisperer 做注释、做检索、做解释是合适的；用它做扰动预测或剂量响应，是用错了工具。

5.3 四种反模式

反模式一：用 zero-shot 分数选型。 零样本成绩既受预训练污染影响，也与下游分布强相关；同一模型在不同数据集上的排名可以翻转。正确做法是用自己的 10% 标注做微调，再比。

反模式二：用 MSE 选扰动模型。 MSE 被近零差异基因稀释，一个“预测无变化”的模型也能拿到不错的分。必须看 DES/PDS 与 DE 基因重叠。

反模式三：用大模型做小任务。 注释一个 5 万细胞的数据集，逻辑回归 + 标记基因往往够用；上 8 亿参数模型，收益可能小于调参成本。

反模式四：忽略许可。 代码许可、权重许可、论文许可、数据许可四者可能不一致；CC BY-NC-ND 不能商用，无 LICENSE 默认保留所有权利，GPL-3.0 可能传染整个软件栈。这是尽职调查项，不是法务细节。

5.4 从任务出发的选型路径

图 6 给出一个从任务出发的路径。它的用法不是“照着选”，而是“先排除”：先判断任务落在哪一层，再排除结构性代价不可接受的大类，最后才在剩下的类里挑模型。



图 6 任务 → 架构大类 → 代表模型的选型路径

表 25　选型矩阵：任务、首选类、代表模型与必跑基线

任务	首选类	代表模型	必跑基线	验收指标
细胞类型注释	A / D	CellFM、Geneformer、CellPLM	CellTypist、逻辑回归、Seurat	macro-F1、per-class recall
批次整合	A（辅以显式协变量）	scGPT、Geneformer	Harmony、scVI	iLISI + 生物保守性
跨物种 / 跨平台	A（无词表）	UCE、TranscriptFormer	HVG + Harmony	未见物种/平台的嵌入一致性
扰动 / 虚拟细胞	D / E	State、Lingshu-Cell、AlphaCell	additive、无变化、GEARS	DES、PDS、MAE（分见/未见）
药物响应	C / D	scFoundation、State	线性回归、scDrugMap 基线	跨细胞系 AUROC、校准
生成 / 补全	B / C / E	scMulan、scFoundation、CAPTAIN	均值填充、kNN	分布距离、DE 保真、分位数覆盖
空间转录组	D（空间变体）	Nicheformer、CellPLM	Novae、scGPT-spatial	邻域一致性、空间标签
GRN / 可解释	A（先验或分布头）	scPRINT、RegFormer、GeneCompass	GENIE3、SCENIC	ChIP/Perturb-seq 重叠

注：“必跑基线”不是可选项。多项评测显示，基线跑不过时，换更大的模型通常也不会赢。

第 6 章

现实检验：哪些结论站得住

> 这一章只做一件事：把“模型方自述”与“独立评测”分开，看哪些结论在多次复现后仍然成立。

6.1 独立评测的证据总表

下表只收录有明确实验设计、可查数字的评测。它们的共同点是：都跑了强基线，都报告了失败案例，且多数在多个数据集上重复。

表 26 十三项独立评测的核心结论

研究	规模	核心结论
scEval（Adv Sci 2026）	8 类任务 × 10 个 scFM	scGPT、Geneformer、CellFM 居前，但没有任何模型在所有任务上稳定优于任务专用方法
Kedzierska 等（Genome Biol 2025）	5 数据集零样本	Geneformer ASW 仅 0.38–0.52，HVG 基线除 PBMC 外全部胜出；scGPT 中位 ASW 0.53 ≈ scVI 0.54；批次整合不合格
Boiarsky 等（Nat Mach Intell 2024）	PBMC 68,450 细胞	L1 逻辑回归在 accuracy 与 macro-F1 上均胜 scBERT；scBERT 去预训练无显著差异（p=0.34/0.59）
Ahlmann-Eltze 等（Nat Methods 2025）	Norman 双扰动	所有被测模型误差均高于 additive 基线；交互预测无一优于“无变化”；真实交互仅 4.2%
PertEval-scFM（ICML 2025）	标准化扰动评测	零样本 scFM 嵌入对简单基线提升有限，分布偏移下尤甚
Wu 等（Genome Biol 2025）	6 个 scFM × 12 指标	没有单一 scFM 全面领先；资源受限时简单模型更易适配
低监督评测（2026）	7 个 FM × 3 个经典表示	CellPLM 聚类/注释/批次最好，scMulan 扰动最好，PCA 重建最好；仅 1/7 在聚类上超过最强基线
SCMBench（Nat Commun 2026）	23 种多组学整合方法	基础模型在多组学整合上不如领域专用模型
scDrugMap（Nat Commun 2025）	8 个 FM + 2 个 LLM	合并数据 scFoundation 最强，跨数据微调 UCE 最好，零样本 scGPT 最高
污染审计（arXiv 2026）	MinHash 逐细胞比对	PBMC 3k 80.4%、人胰岛 77.0% 与 Genecorpus-30M 重叠；截止日后数据集 0%
稀有类研究（arXiv 2026）	162 次受控训练	总体准确率 97.5%，稀有类召回系统性失败，且由数据结构而非预训练决定
VCC 2025（Arc）	300+ 队伍	扰动模型未在所有指标上稳定超过朴素基线；冠军方案是深度学习 + 统计特征混合
饱和立场论文（ICML 2026）	立场论文	benchmark 饱和是可识别性失败，不是能力到顶

6.2 仍然成立的四条优势

在大量负面证据里，有四条优势被反复确认，值得作为选型的正面依据。

① 微调后的分布外泛化。 scGPT 在多发性硬化数据上优于逻辑回归，且训练样本越少优势越大；scFoundation 在多个任务上稳定靠前；Steiner 等在三个任务上发现，用 OOD 数据微调后仍可泛化。

② 嵌入作为特征有效。 scGPT/scFoundation 的基因嵌入加线性解码，优于均值基线与随机嵌入；虽然不优于“用训练数据学到的嵌入”，但在标注稀缺时是实用的初始化。

③ 预训练确有贡献。 预训练模型普遍优于随机初始化；scGPT 去掉预训练会显著变差。这与“零样本不强”并不矛盾——预训练的价值体现在微调起点，而不是开箱即用。

④ 数据域匹配优于规模。 用 Replogle 扰动数据预训练的线性模型，稳定优于通用大模型。这条最反直觉，也最重要：模型的“见过同类数据”比“参数更多”更能决定下游表现。

6.3 三个还没有被证明的承诺

第一，**零样本通用性**。跨数据集、跨平台、跨物种的零样本嵌入，在受控评测中很少稳定超过强基线。UCE 与 TranscriptFormer 是例外，但它们的优势集中在“把不同来源放进同一坐标系”，而不是“替代专用工具”。

第二，**跨数据集稳健性**。同一模型在不同数据集上的排名会翻转；预处理、tokenization、指标的选择都能改变结论。这意味着“论文里的 SOTA”不能直接迁移到你的数据。

第三，**稀有类可靠性**。总体指标好看与稀有类可用是两件事。稀有类失败主要由数据结构决定，换损失函数、换主干都难以根治。

6.4 一张八问验收清单

表 27 评估一个 scFM 是否适合你的任务

问题	为什么要问	不合格的信号
1. 任务是哪一层？	注释/整合/扰动/生成的最优类完全不同	用同一个模型打所有任务
2. 强基线跑了吗？	HVG、Harmony、scVI、逻辑回归、additive	只与随机初始化比
3. 测试集在预训练里吗？	泄漏会系统性抬高零样本	无截止日、无语料清单
4. 零样本还是微调？	两者结论经常相反	把微调成绩说成零样本
5. 指标对生物学有意义吗？	MSE 会被近零差异稀释	只报 MSE/Pearson
6. 稀有类表现如何？	总体准确率会掩盖长尾失败	只报 accuracy
7. 许可允许商用吗？	代码/权重/论文/数据许可可能不一致	CC BY-NC-ND 或无机 LICENSE
8. 能复现吗？	种子、超参、算力、失败案例	无代码、无种子、无失败分析

第 7 章

判断与建议

> 下面五条判断不是预测“哪个模型会赢”，而是判断“哪些条件一旦成立，格局会变”。每条都给出可观察的信号。

7.1 五条判断（2026–2028）

判断一：观测数据接近饱和，扰动数据决定上限。 公开 atlas 已达亿级，继续堆观测数据的边际收益在下降；真正稀缺的是同一细胞类型、同一平台、带对照的扰动数据。可观察信号：扰动数据成本是否降到“每细胞美分”；是否出现跨实验室的扰动数据标准；药企是否愿意用内部 Perturb-seq 换模型。

判断二：目标函数从“重建”转向“分布/转移”，集合级损失会成为标配。 State 的 MMD、AlphaCell 的 flow、Lingshu 的条件扩散、CellOS 的 JEPA，都在做同一件事。可观察信号：新论文是否默认报告分布指标；是否出现统一的“状态转移”基准；逐细胞 MSE 是否被审稿人要求替换。

判断三：词表无关的基因身份会成为默认。 蛋白语言模型让新基因、新物种、新 panel 不再需要重训词表。可观察信号：新模型是否还依赖固定基因词表；跨物种评测是否成为常规项；ESM-2 类嵌入是否成为标准组件。

判断四：通用底座 + 领域适配器，不会有一个主干通吃。 通用表征（UCE、TranscriptFormer、SCimilarity）+ 生成/模拟器（State、Lingshu、AlphaCell）+ 领域适配器（LoRA、蒸馏）+ 文本接口（CellWhisperer），四层分工。可观察信号：是否出现模型卡与适配器市场；是否出现跨模型的统一 tokenization。

判断五：评测从排行榜转向“能否替代一次实验”。 VCC 已经把任务定义成“能否替代一次 Perturb-seq”，Cell_Eval 用七项指标覆盖 DES/PDS。可观察信号：VCC 是否成为年度惯例；期刊是否要求提交基准报告；是否出现第三方审计。

7.2 给研究团队：三条值得走的路

路线一：做数据，而不是做模型。 高质量扰动数据的生产成本、元数据标准化、跨实验室去重，是当前最硬的瓶颈，也是最难被追平的壁垒。一个 1,000 万细胞的干净扰动数据集，价值高于一个 10 亿参数的模型。

路线二：做目标，而不是做主干。 分布级损失、因果识别、可识别性约束，是 P8–P10 的真正解法。把 Mamba 换成 RetNet 不会让模型更懂干预；把 MSE 换成集合距离或流匹配会。

路线三：做评测，而不是做榜单。 时间切分、逐细胞审计、任务化指标、失败案例披露——这些工作不产生引用，但决定了整个领域的判断力。

不建议：再训一个同质的大模型。除非你有别人没有的数据，或者别人没有的算力栈，否则在 2026 年做“更大的 scGPT”是边际收益最低的选择。

7.3 给选型者：三张表

第一张是第 5 章的选型矩阵：先确定任务落在哪一层，再选类。第二张是代价表（第 3 章的六类天花板）：确认你能接受该类丢掉的东西——分辨率、可解释性、定量精度，还是跨物种能力。第三张是第 6 章的八问清单：八问全部过关，才进入试点。

如果只有一句话：**先用强基线把任务做到 80 分，再问 scFM 能不能把最后 20 分补上**。补不上，不是模型不好，是任务不需要它。

7.4 五个开放问题

- **没有干预数据，能否学因果？** 目前的答案是“只能学到相关的近似”。工具变量、孟德尔随机化、跨物种保守性，都是可能的突破口。
- **“细胞状态”的度量是什么？** 现在的嵌入空间由模型定义，换一个模型就换一个坐标系。需要一个与模型无关、可跨数据集比较的状态度量。
- **全基因与 HVG 的信息论权衡是什么？** 全基因覆盖稀有标记，但计算与噪声成本高；HVG 高效，但会丢信号。这个权衡目前只有经验，没有理论。
- **生成模型的可识别性如何保证？** 扩散/流匹配可以生成“像”的细胞，但无法保证学到的是真实的因果机制。可识别性是生成式虚拟细胞的核心难题。
- **跨物种的“同源”到什么粒度？** 基因同源不等于细胞类型同源，更不等于调控网络同源。跨物种迁移的理论边界仍未厘清。

附 录

术语、资源与来源

A 术语表

表 28 本报告使用的核心术语

术语	英文 / 缩写	含义
单细胞基础模型	scFM	在千万到亿级单细胞数据上自监督预训练、可迁移到多任务的模型
标记基因	marker gene	在特定细胞类型中高表达、可用于注释的基因
高变基因	HVG	在细胞间方差大的基因，常用于降维与建模
零膨胀	zero-inflation	scRNA-seq 中大量零值，既可能是不表达，也可能是未检出
双细胞	doublet	两个细胞被同一液滴捕获，形成混合表达谱
环境 RNA	ambient RNA	裂解细胞释放、污染其他液滴的游离 RNA
批次效应	batch effect	由实验批次、平台、操作者引起的系统性技术差异
掩码建模	masked modeling	遮住部分输入、让模型预测被遮部分的自监督目标
秩编码	rank value encoding	按表达量排序、以名次作为 token 的编码方式
软分箱	soft binning	把连续值映射为多个 bin 的权重，而非硬指派
零膨胀负二项	ZINB	同时建模过零与计数的概率分布，输出 μ、θ、π
零截断泊松	ZTP	在正值上归一化的泊松分布，用于计数生成
集合距离	MMD / energy distance	衡量两个细胞集合分布差异的指标
流匹配	flow matching	学习从噪声到数据的连续时间速度场
联合嵌入预测	JEPA	在隐空间预测另一视角的表示，而非重建输入
专家混合	MoE	多个专家网络 + 门控，稀疏激活以扩大容量
差异表达签名	DES	扰动后显著变化的基因集合
扰动区分度	PDS	模型区分不同扰动的能力指标
双 dipping	double dipping	同一批数据既用于预训练又用于评测
可识别性	identifiability	模型能否从数据中唯一确定目标机制

B 可复现资源

表 29 主要模型的代码与权重入口

模型	仓库 / 入口	许可	备注
scBERT	github.com/TencentAILabHealthcare/scBERT	GPL-3.0	2023 年底后基本停更
Geneformer	huggingface.co/ctheodoris/Geneformer	版本不一	V1 10M / V2 106M
scGPT	github.com/bowang-lab/scGPT	MIT	教程与微调 recipe 完整
scFoundation	github.com/biomap-research/scFoundation	Apache-2.0	含 API
UCE	github.com/snap-stanford/UCE	MIT	需 ESM-2 嵌入表
CellFM	github.com/biomed-AI/CellFM	Other	MindSpore
GeneCompass	github.com/xCompass-AI/GeneCompass	无 LICENSE	商用需谨慎
CellPLM	github.com/OmicsML/CellPLM	BSD-2	ICLR 2024
Nicheformer	github.com/theislab/nicheformer	BSD-3	空间 + 解离
State	github.com/ArcInstitute/state	CC BY-NC-SA	非商用
TranscriptFormer	github.com/czi-ai/transcriptformer	MIT	12 物种
scPRINT	github.com/cantinilab/scPRINT	GPL-3.0	含 GRN 基准

C 主要来源

以下按主题分组。模型类条目给出论文或预印本标识；评测类条目给出期刊与 DOI；厂商口径的条目单独标注。信息截至 2026 年 10 月。

> **引用说明** 标注“Anonymous”的条目为预印本阶段、作者名单尚未最终确认的工作，引用时请以正式发表版本为准；标注“厂商口径”的数字未经独立复现，不应作为选型依据。

模型原文

[1] Yang F, et al. scBERT as a large-scale pretrained deep language model for cell type annotation of single-cell RNA-seq data. Nature Machine Intelligence, 2022. doi:10.1038/s42256-022-00534-z

[2] Theodoris CV, et al. Transfer learning enables predictions in network biology. Nature, 2023. doi:10.1038/s41586-023-06139-9

[3] Cui H, et al. scGPT: toward building a foundation model for single-cell multi-omics using generative AI. Nature Methods, 2024. doi:10.1038/s41592-024-02201-0

[4] Hao M, et al. Large-scale foundation model on single-cell transcriptomics. Nature Methods, 2024. doi:10.1038/s41592-024-02305-7

[5] Rosen Y, et al. Universal Cell Embeddings: a foundation model for cell biology. bioRxiv, 2023. doi:10.1101/2023.11.28.568809；期刊版 Nature, 2026.

[6] Yang X, et al. GeneCompass: deciphering universal gene regulatory mechanisms with a knowledge-informed cross-species foundation model. Cell Research, 2024. doi:10.1038/s41422-024-01034-y

[7] Schäfer P, et al. Nicheformer: a foundation model for single-cell and spatial omics. Nature Methods, 2025. doi:10.1038/s41592-025-02814-z

[8] Kalfon J, et al. scPRINT: pretraining on 50 million cells allows robust gene network predictions. Nature Communications, 2025. doi:10.1038/s41467-025-58699-1

[9] Kalfon J, et al. scPRINT-2: a 350-million-cell foundation model across 16 species. bioRxiv, 2025. doi:10.64898/2025.12.11.693702

[10] Wu H, et al. CellFM: a large-scale foundation model pre-trained on 100 million human single-cell transcriptomes. Nature Communications, 2025. doi:10.1038/s41467-025-59926-5

[11] Chen J, et al. TranscriptFormer: a generative foundation model for cross-species transcriptomics. Science, 2026；预印本 CZI, 2025.

[12] Arc Institute. State: a model of cellular state transition. Cell, 2026；预印本 2025.

[13] Wen H, et al. CellPLM: pre-training of cell language model beyond single cells. ICLR, 2024. doi:10.1101/2023.10.03.560734

[14] Bian H, et al. scMulan: a multitask generative pre-trained language model for single-cell biology. bioRxiv, 2024. doi:10.1101/2024.01.25.577152

[15] Anonymous. CAPTAIN: a multimodal foundation model for RNA and surface proteins. Nature Communications, 2026. doi:10.1038/s41467-026-72882-y

[16] Fang S, et al. RegFormer: a single-cell foundation model powered by gene regulatory hierarchies. Nature Communications, 2026. doi:10.1038/s41467-026-72198-x

[17] Anonymous. CellVQ: vector-quantized cell language model. Nature Communications, 2026. doi:10.1038/s41467-026-70071-5

[18] Anonymous. CellWhisperer: a multimodal foundation model for cell biology. Nature Biotechnology, 2025. doi:10.1038/s41587-025-02857-9

[19] Levine L, et al. Cell2Sentence: teaching large language models the language of biology. bioRxiv, 2023. doi:10.1101/2023.09.11.557287

[20] Chen Y, Zou J. GenePT: a simple but hard-to-beat foundation model for gene-level tasks. NeurIPS, 2023. PMC10614824.

[21] Anonymous. LangCell: language-cell pre-training for cell identity. arXiv:2405.06708, 2024.

[22] Heinlein L, et al. Universal cell embeddings enable cross-study cell retrieval. Nature, 2024.

[23] Shen H, et al. tGPT: generative pretrained transformer for single-cell transcriptomics. iScience, 2023.

[24] Anonymous. xTrimoGene: an efficient and scalable representation learner for single-cell RNA-seq. NeurIPS, 2023. arXiv:2311.15156.

[25] Anonymous. scDiffformer: diffusion post-training for single-cell foundation models. Nucleic Acids Research, 2026. doi:10.1093/nar/gkag706

[26] 阿里达摩院. Lingshu-Cell: masked discrete diffusion for transcriptome generation. 技术报告, 2026-08.

[27] 同济大学 DELTA Lab. AlphaCell: a world model for cellular state transition. 预印本, 2026-03.

[28] 百曜科技. CellOS: a 12B MoE foundation model for virtual cell. 技术报告, 2026-07（厂商口径）.

评测、批评与方法

[29] Liu T, et al. Evaluating the utilities of foundation models in single-cell data analysis. Advanced Science, 2026. doi:10.1002/advs.202514490

[30] Kedzierska KZ, et al. Zero-shot evaluation reveals limitations of single-cell foundation models. Genome Biology, 2025. doi:10.1186/s13059-025-03574-x

[31] Boiarsky R, et al. Deeper evaluation of a single-cell foundation model. Nature Machine Intelligence, 2024. doi:10.1038/s42256-024-00949-w

[32] Ahlmann-Eltze C, Huber W, Anders S. Deep-learning-based gene perturbation effect prediction does not yet outperform simple linear baselines. Nature Methods, 2025. doi:10.1038/s41592-025-02772-6

[33] Wenteler A, et al. PertEval-scFM: benchmarking single-cell foundation models for perturbation effect prediction. ICML, 2025. PMLR 267:66633–66677.

[34] Wu J, et al. Biology-driven insights into the power of single-cell foundation models. Genome Biology, 2025. doi:10.1186/s13059-025-03781-6

[35] Ali S. Auditing pretraining contamination in single-cell foundation model benchmarks. arXiv:2607.20572, 2026.

[36] Dong Z, Zhong J. Rethinking class imbalance for single-cell foundation models. arXiv:2609.23325, 2026.

[37] Steiner N, et al. A systematic evaluation of single-cell foundation models on cell-type classification. WSDM, 2025. doi:10.1145/3701551.3708811

[38] Anonymous. SCMBench: a comprehensive benchmark for single-cell multi-omics integration. Nature Communications, 2026. doi:10.1038/s41467-026-72570-x

[39] Anonymous. scDrugMap: benchmarking foundation models for drug response prediction. Nature Communications, 2025. doi:10.1038/s41467-025-67481-2

[40] Arc Institute. Virtual Cell Challenge 2025: results and lessons. 2025. arcinstitute.org/news/virtual-cell-challenge-2025-wrap-up

[41] Anonymous. Position: saturation in single-cell foundation model benchmarks signals identifiability failure, not solved capability. ICML, 2026.

[42] Bunne C, et al. How to build the virtual cell with artificial intelligence. Cell, 2024. doi:10.1016/j.cell.2024.11.015

[43] Lopez R, et al. Deep generative modeling for single-cell transcriptomics. Nature Methods, 2018. doi:10.1038/s41592-018-0229-2

[44] Choromanski K, et al. Rethinking attention with Performers. ICLR, 2021. arXiv:2009.14794.

[45] Anonymous. HEIMDALL: modular decomposition of single-cell tokenizers. 2026.

[46] Anonymous. A large-scale controlled study of expression value encoding in single-cell foundation models. 2026.