LITERATURE REVIEW · 2023–2026

AI + 生物：重要论文调研与全文归档

从蛋白质结构预测到虚拟细胞、从基因组语言模型到生物医学 Agent：32 篇高影响力论文的筛选标准、核心贡献、全文 PDF 与获取限制说明

版本 **v1.0**　完成时间 **2026-10-22**　检索库 **OpenAlex · Europe PMC · bioRxiv · arXiv**　覆盖 **7 个子领域**

32 篇	7 个	395 MB	32/32
入选论文（2023–2026 为主，含 3 篇奠基性）	子领域：蛋白、基因组、单细胞、病理、药物、LLM、虚拟细胞	全文 PDF 总体积，按主题归档	PDF 校验通过（可打开、页数 > 0）

说明：引用量为 OpenAlex 截至 2026-10-21 的数据；「年份」以首次公开/预印本为准，正式卷期可能晚一年。32 篇全部取得可读全文，其中 16 篇不是出版社原版 PDF，原因见第 05 节。

00 这次调研做了什么

目标不是「把所有 AI+生物论文列一遍」，而是用一套可复述的标准，挑出过去三年真正改变了领域问题定义、方法路线或工程实践的论文，并把能公开获取的全文整理成可精读的本地库。

七个判断

1. **结构预测已进入「复合物 + 亲和力」时代。** AlphaFold3 把蛋白—核酸—小分子放进同一个模型；Boltz-2 把结合亲和力做到接近 FEP、且开源。
2. **蛋白设计从「生成骨架」走向「可编程 + 多模态」。** RFdiffusion、Chroma 解决可控生成；ESM3 把序列、结构、功能统一到一个生成模型。
3. **基因组模型从「预测 track」走向「长上下文 + 生成」。** Enformer → Borzoi → AlphaGenome 把输入推到 1 Mb、输出推到单碱基；Evo 把 DNA 语言模型推到 7B 参数。
4. **单细胞从「表征」走向「扰动与虚拟细胞」。** Geneformer/scGPT/scFoundation 完成范式验证；UCE 做跨物种零样本；State 直接建模扰动后的状态转移。
5. **病理与影像基础模型已进入临床级评测。** UNI、CONCH、Prov-GigaPath、RETFound 把「自监督预训练 + 少样本迁移」变成数字病理/视网膜影像的默认路线。
6. **2025–2026 的新前沿是 Agent 与可解释药物发现。** Biomni 让 LLM 调用工具/数据库/代码；Antibiotic 用可解释 GNN 找到新结构类抗生素并在小鼠验证。
7. **真正的瓶颈是数据、评测与获取，而不是模型大小。** 本报告 16/32 篇只能拿到预印本/作者稿；领域内「正式版滞后于预印本」是常态。

怎么读这份报告

- **第 01 节**：筛选标准与排除规则，解释「为什么是这 32 篇」。
- **第 02 节**：领域地图，用 3 张图看主题、年份与引用分布。
- **第 03 节**：32 篇论文卡片，每篇含标题、作者、年份、来源、引用、核心贡献、PDF 链接与版本说明。
- **第 04 节**：下载与归档结构，32/32 校验结果。
- **第 05 节**：16 篇「非出版社原版 PDF」的具体原因与影响评估。
- **第 06 节**：三条精读路线（结构/基因组/应用），可直接照单阅读。
- **第 08 节**：完整索引表，按文件夹顺序列出所有 PDF。

◆ 一句话结论

过去三年，AI+生物的主线从「用大模型做预测」转为「用生成模型做设计、用 Agent 做流程、用扰动数据做因果」。真正的分水岭不是参数，而是**有没有可验证的数据与评测**。

01 筛选标准：为什么是这 32 篇

筛选在 2026-10-21 至 2026-10-22 完成。先由 OpenAlex 按主题检索候选池（约 40 篇），再按以下六条标准逐条过滤，最终保留 32 篇。

① 时间窗口

② 来源层级

以 **2023-01 至 2026-10** 为主。破例保留 3 篇奠基性工作：Enformer（2021）、BioGPT（2022）、DiffDock（2022/ICLR 2023），因为它们是后续大量论文的基线或范式起点，不纳入会失去参照系。

Nature / Science / Cell 及其子刊（Nat Methods、Nat Biotechnology、Nat Medicine、Nat Genetics、Nat Communications、Cell Research 等）；顶会（ICLR/NeurIPS/ICML）；高影响力预印本（bioRxiv/arXiv）需满足「已被高影响力期刊接收，或引用 > 100，或有广泛使用的开源模型/数据」。

③ 影响力证据

以 OpenAlex 引用量为主，辅以「引用速度」（2025–2026 论文用）、开源采用（GitHub/HuggingFace）、产业采用（药企/病理/临床）。不只看引用总数，避免「老论文通吃」。

④ 领域覆盖

7 个子领域，每领域 3–6 篇；同一模型家族只保留最具代表性的一篇；兼顾「方法突破」与「真实应用」（如 Antibiotic、TamGen 的湿实验验证）。

⑤ 可核验性

必须有 DOI 或稳定预印本链接；优先选择有代码/数据/模型卡的工作；排除只有厂商白皮书、无法核验指标的工作。

⑥ 全文可得性

优先可公开下载的 PDF；正式版不可得时，按「PMC 作者稿 > 机构库 > bioRxiv/arXiv 预印本」降级，并在第 05 节标注，不把预印本冒充正式版。

△ 排除规则（明确不纳入）

① 纯综述/评论（例外：AIVC 愿景与 SciPhi 总览，因为它们定义了问题空间）；② 纯临床 AI 预测、缺少生物机制或分子层面贡献的工作；③ 无代码、无数据、无法复现的「榜单型」论文；④ 仅在公司博客/新闻稿发布、没有论文或模型卡的技术声明；⑤ 同一模型的增量版本（只保留首发或最具代表性的版本）。

最终分布：出版社版 14 篇，机构库 2 篇，bioRxiv 预印本 8 篇，PMC 作者稿渲染 5 篇，Science 页面全文 1 篇，arXiv 2 篇（共 32 篇，详见第 04–05 节）。

02 领域地图：三个分布

先看「数量」，再看「时间」，最后看「引用」。三张图能快速回答：这个领域的热点在哪、什么时候爆发、哪些论文真正被大量使用。

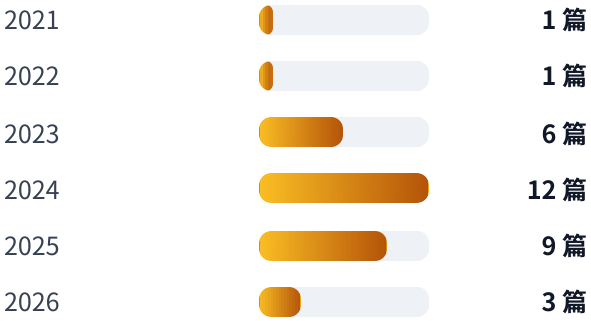
主题分布（篇）

7 个子领域，单细胞与蛋白各 6 篇，药物 3 篇



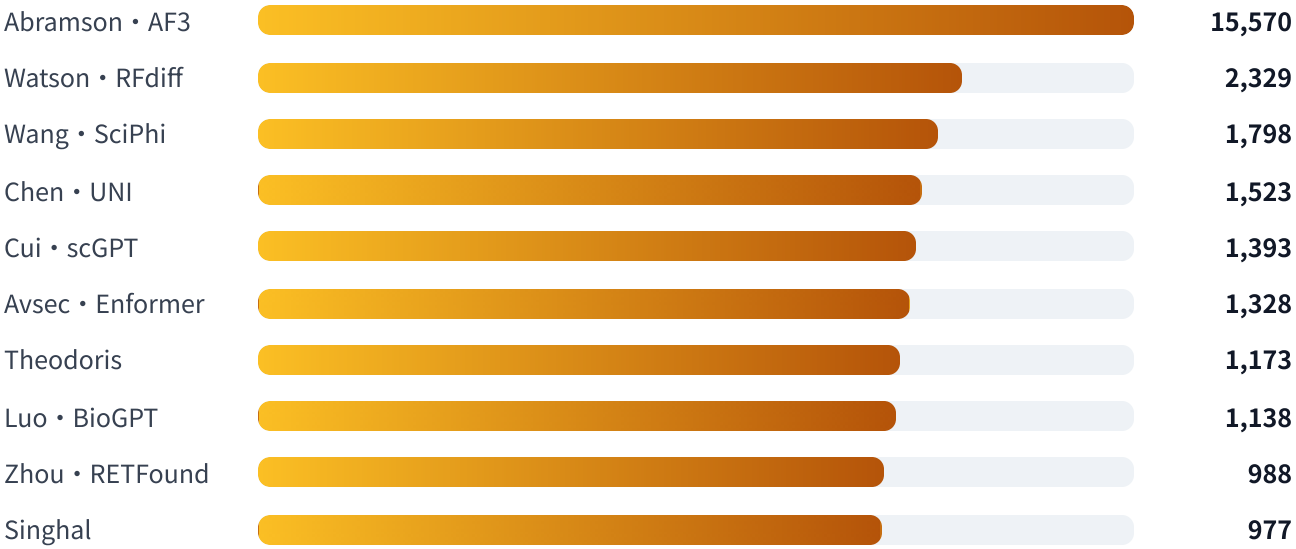
年份分布（篇）

按首次公开/预印本年计；2024 年为峰值



引用量 Top 10（OpenAlex，对数刻度）

AlphaFold3 一枝独秀；榜单里既有 2021 的奠基工作，也有 2023–2025 的新模型



三个观察

① **2024 是「基础模型年」：**AlphaFold3、RoseTTAFold All-Atom、Evo、UNI、CONCH、scGPT、scFoundation 等集中在 2024 发表或正式刊出。② **2025–2026 是「推理与虚拟细胞年」：**Boltz-2、ESM3、Med-PaLM 2、Biomni、State、AlphaGenome、UCE 把重点从「表征」转向「生成/模拟/Agent」。③ **引用与年份高度相关：**2026 年的 UCE（17）、State（96）引用低，不代表影响力低；它们代表的是「正在进行的方向」，需要结合预印本引用与社区采用来看。

03 论文清单：32 篇与核心贡献

按 7 个主题排列。每张卡片给出：年份、标题、作者（前三位 + 末位）、发表来源、OpenAlex 引用量、核心贡献、PDF 链接、版本类型与获取说明。

PROTEIN STRUCTURE & DESIGN

蛋白质结构与生成 6 篇

从「预测一个蛋白」到「设计一个复合物、一个结合物」。扩散模型与多模态语言模型是两条主线；2024 年后，共折叠（co-folding）与亲和力预测成为新战场。

这一组的主线：AlphaFold3 把结构预测推进到生物分子复合物；RFdiffusion/Chroma 把生成推进到可控设计；ESM3 把序列、结构、功能放进同一个生成模型。Boltz-2 则把「结构 + 亲和力 + 开源」带到同一张桌子上。

2024 **Accurate structure prediction of biomolecular interactions with AlphaFold 3** 15,570 引用

Josh Abramson, Jonas Adler, Jack Dunger et al ⋯ John Jumper • **Nature** • DOI

把结构预测从蛋白扩展到蛋白质—核酸—小分子—离子—修饰残基的复合物；扩散架构在蛋白—配体、蛋白—核酸界面上显著超过专用工具，成为后续共折叠模型的基准。

↓ 打开 PDF 24 页 • 8.2 MB 出版社版 Nature 混合 OA，直接下载

2023 **De novo design of protein structure and function with RFdiffusion** 2,329 引用

Joseph L. Watson, David Juergens, Nathaniel R. Bennett et al ⋯ David A. Baker • **Nature** • DOI

在 RoseTTAFold 结构预测网络上微调扩散模型，从噪声生成蛋白骨架；支持 de novo binder、对称组装与功能位点 scaffolding；实验验证了大量设计，奠定扩散式蛋白设计范式。

↓ 打开 PDF 38 页 • 34.7 MB 出版社版 Nature 混合 OA，直接下载

2023 **Illuminating protein space with a programmable generative model**

441 引用

John Ingraham, Max Baranov, Zak Costello et al ⋯ Gevorg Grigoryan · **Nature** · DOI

可编程蛋白生成模型：扩散过程尊重聚合物构象统计，支持对称性、形状、功能等多种条件；一次采样即可同时生成新的蛋白骨架与序列，把「生成」从随机采样推进到可控设计。

↓ 打开 PDF 15 页 · 8.1 MB 出版社版 Nature 混合 OA，直接下载

2024 **Generalized biomolecular modeling and design with RoseTTAFold All-Atom**

966 引用

Rohith Krishna, Jue Wang, Woody Ahern et al ⋯ David A. Baker · **Science** · DOI

用「残基表示 + 原子表示」统一建模蛋白、DNA、小分子、金属与共价修饰；RFdiffusionAA 可围绕小分子设计结合口袋，把结构预测与设计推进到全原子尺度。

↓ 打开 PDF 17 页 · 8.0 MB Science 全文 Science 订阅制；用公开可访问的 HTML 全文打印为 PDF

2025 **Simulating 500 million years of evolution with a language model**

924 引用

Thomas Hayes, Roshan Rao, Halil Akin et al ⋯ Alexander W. Rives · **Science** · DOI

多模态蛋白生成语言模型，联合建模序列、结构、功能并支持组合 prompt；生成的明亮荧光蛋白与已知序列一致性仅 58%，被估计相当于模拟 5 亿年进化。

↓ 打开 PDF 68 页 · 11.5 MB 预印本 Science 2025 订阅制；采用 bioRxiv 预印本（正式版可能有差异）

2025 **Boltz-2: Towards Accurate and Efficient Binding Affinity Prediction**

687 引用

Saro Passaro, Gabriele Corso, Jeremy Wohlwend et al ⋯ Regina Barzilay · **bioRxiv (Cold Spring Harbor Laboratory)** · DOI

开源的结构 + 亲和力联合预测模型：首次在结合亲和力上接近 FEP 精度，同时计算效率高约 1000 倍；支持实验方法条件、距离约束与多链模板，并开放权重与训练代码。

> 权重、推理与训练代码以宽松许可开源，是 2025 年最受关注的开源共折叠模型之一。

↓ 打开 PDF 55 页 · 7.0 MB 预印本 目前仅有 bioRxiv 预印本，无期刊正式版

GENOMICS & GENE REGULATION

基因组与调控 5 篇

从「预测表达 track」到「1 Mb 输入 + 单碱基输出 + 生成式设计」。评测重点正从相关性转向变异效应与机制解释。

这一组的主线：Enformer 奠定「序列→调控」范式；Borzoi 用 RNA-seq coverage 统一转录/剪接/多聚腺苷化；AlphaGenome 把输入拉到 1 Mb、输出拉到单碱基；Evo 则把 DNA 语言模型推到 7B 参数与 131 kb 上下文。

2021 Effective gene expression prediction from sequence by integrating long-range interactions

1,328 引用

Žiga Avsec, Vikram Agarwal, Daniel Visentin et al ⋯ David R. Kelley · **Nature Methods** · DOI

用 Transformer 整合 100 kb 长程相互作用，显著提升基因表达与变异效应预测；奠定「DNA 序列 → 调控表型」的建模范式，成为 Borzoi/AlphaGenome 的基线。

↓ 打开 PDF 24 页 · 18.2 MB 出版社版 Nature Methods 混合 OA；2021 年奠基性工作

2025 Predicting RNA-seq coverage from DNA sequence as a unifying model of gene regulation

265 引用

Johannes Linder, Divyanshi Srivastava, Han Yuan et al ⋯ David R. Kelley · **Nature Genetics** · DOI

从 DNA 序列预测细胞/组织特异的 RNA-seq coverage，统一建模转录、剪接与多聚腺苷化；在 eQTL/sQTL 等任务上优于 Enformer，并支持变异效应分解。

↓ 打开 PDF 34 页 · 13.2 MB 出版社版 Nature Genetics 混合 OA

2026 **Advancing regulatory variant effect prediction with AlphaGenome** 375 引用

Žiga Avsec, Natasha S. Latysheva, Jun Cheng et al ⋯ Pushmeet Kohli · **Nature** · DOI

输入 1 Mb DNA、输出单碱基分辨率的数千条功能基因组 track，覆盖表达、转录起始、染色质可及性、组蛋白修饰、TF 结合、染色质接触与剪接；统一了长序列与高分辨率的取舍。

> Nature 2026；模型与变异效应 API 已开放，但训练代码/权重未完全开源。

↓ 打开 PDF 31 页 · 67.1 MB 出版社版 Nature 混合 OA

2024 **Sequence modeling and design from molecular to genome scale with Evo** 580 引用

Eric Nguyen, Michael Poli, Matthew G. Durrant et al ⋯ Brian Hie · **Science** · DOI

7B 参数、131 kb 上下文、单核苷酸分辨率的基因组基础模型；在原核基因组上训练，支持突变效应预测、CRISPR 系统生成与最小基因组设计，把 DNA 语言模型推到基因组尺度。

↓ 打开 PDF 75 页 · 4.7 MB PMC 全文 Science 订阅制；PMC 作者稿渲染（75 页，含参考文献与补充材料）

2024 **Nucleotide Transformer: building and evaluating robust foundation models for human genomics** 657 引用

Hugo Dalla-Torre, Liam Gonzalez, Javier Mendoza - Revilla et al ⋯ Thomas Pierrot · **Nature Methods** · DOI

在 3,202 个人类基因组与 850 个跨物种基因组上预训练的一系列 DNA Transformer（50M–2.5B 参数）；系统评估 scaling 与迁移能力，提供可复用的基因组表征。

↓ 打开 PDF 20 页 · 4.5 MB 出版社版 Nature Methods 混合 OA

SINGLE-CELL & TRANSCRIPTOMICS

单细胞与转录组 6 篇

从「细胞注释」到「跨物种通用嵌入 + 扰动状态转移」。数据规模进入亿级，但 zero-shot 与评测争议同步放大。

这一组的主线：Geneformer/scGPT/scFoundation 完成「单细胞基础模型」的范式验证；UCE 把嵌入推向跨物种零样本；State 把目标从「表征」改成「扰动后的状态转移」；CellFM 证明国产算力栈可以训练 8 亿参数模

型。

2023 **Transfer learning enables predictions in network biology** 1,173 引用

Christina V. Theodoris, Ling Xiao, Anant Chopra et al ⋯ Patrick T. Ellinor · **Nature** · DOI

在约 3,000 万单细胞转录组上预训练 BERT 式模型，按表达量排序 token；迁移学习到染色质与网络任务，并在心肌病数据中识别候选治疗靶点，开创单细胞基础模型范式。

↓ 打开 PDF 47 页 · 6.0 MB 机构库版 Nature 订阅制；eScholarship 机构库版本（47 页）

2024 **scGPT: toward building a foundation model for single-cell multi-omics using generative AI** 1,393 引用

Haotian Cui, Chloe Wang, Hassaan Maan et al. · **Nature Methods** · DOI

3,300 万细胞、GPT 式生成预训练；统一细胞注释、批次整合、多组学整合、扰动预测与 GRN 推断；是生态最广、被评测最多的单细胞基础模型之一。

↓ 打开 PDF 36 页 · 18.4 MB 预印本 Nature Methods 订阅制；bioRxiv v1（2023-05-01）

2024 **Large-scale foundation model on single-cell transcriptomics** 629 引用

Minsheng Hao, Jing Gong, Xin Ying Zeng et al ⋯ Le Song · **Nature Methods** · DOI

1 亿参数、5,000 万人类细胞、约 2 万基因；非对称 encoder-decoder 支持表达增强、组织/单细胞药敏、扰动预测、注释与基因模块推断，并报告了参数/FLOPs 的 scaling 行为。

↓ 打开 PDF 25 页 · 5.2 MB 预印本 Nature Methods 订阅制；bioRxiv 预印本

2026 **Universal cell embedding provides a foundation model for cell biology**

17 引用

Yanay Rosen, Yusuf Roohani, Ayush Agrawal et al ⋯ Jure Leskovec · **Nature** · DOI

3,600 万细胞、8 物种、33 层/6.5 亿参数的通用细胞嵌入；无需微调即可跨物种/跨组织嵌入，构建覆盖 1,000+ 细胞类型的 Integrated Mega-scale Atlas；正式版 2026 年发表于 Nature（预印本 2023，已有 160+ 引用）。

OpenAlex 对 2026 正式版仅计 17 次引用；2023 预印本已有 164 次引用，评估影响力时应合并看。

↓ 打开 PDF 25 页 · 22.8 MB 出版社版 Nature 2026 混合 OA（正式版）；2023 预印本另见 bioRxiv

2026 **Predicting cellular responses to perturbation across diverse contexts with State**

96 引用

Abhinav Adduri, Dhruv Gautam, Beatrice Bevilacqua et al ⋯ Yusuf Roohani · **Cell** · DOI

扰动响应预测模型：SE 学嵌入、ST 学状态转移，用集合注意力处理细胞异质性；在 Tahoe-100M 上效应区分度提升 30%+，DEG 识别显著优于基线，并提出 Cell-Eval 评测框架。

Cell 2026 正式版；预印本 2025-06 发布，OpenAlex 引用 96 次。

↓ 打开 PDF 66 页 · 30.3 MB 预印本 Cell 2026 订阅制；bioRxiv 预印本（66 页，含补充材料）

2025 **CellFM: a large-scale foundation model pre-trained on transcriptomics of 100 million human cells**

88 引用

Yuansong Zeng, Jiancong Xie, Ningyuan Shangguan et al ⋯ Yuedong Yang · **Nature Communications** · DOI

1 亿人类细胞、8 亿参数、RetNet 主干；在华为 MindSpore + 昇腾 910 上训练，注释、扰动预测与基因功能任务优于同期模型，代表国产算力栈的大规模单细胞模型。

论文为 CC BY-NC-ND；商用需单独确认许可。

↓ 打开 PDF 17 页 · 4.1 MB 出版社版 Nature Communications 金色 OA

PATHOLOGY & MEDICAL IMAGING

空间与病理影像 4 篇

全切片 + 图文对齐 + 临床级评测。基础模型已成为数字病理的默认底座，并开始向「临床级」与「少样本」迁移。

这一组的主线：UNI 用 1 亿图像块证明「病理 ImageNet 时刻」；CONCH 把病理图像与报告文本对齐；Prov-GigaPath 直接建模整张切片；RETFound 则展示了视网膜影像的标签高效迁移。

2024 **Towards a general-purpose foundation model for computational pathology**

1,523 引用

Richard J. Chen, Tong Ding, Ming Y. Lu et al ⋯ Faisal Mahmood · **Nature Medicine** · DOI

1 亿+ 图像块、10 万+ H&E 全切片、20 种组织；自监督预训练，在 34 项病理任务上达到 SOTA，支持少样本与分辨率无关分类，是病理基础模型的代表。

↓ 打开 PDF 81 页 · 13.4 MB PMC 全文 Nature Medicine 订阅制；PMC 作者稿渲染（81 页）

2024 **A visual-language foundation model for computational pathology**

948 引用

Ming Y. Lu, Bowen Chen, Drew F. K. Williamson et al ⋯ Faisal Mahmood · **Nature Medicine** · DOI

视觉—语言病理基础模型：1.17M 图像—文本对对比学习；在 14 项任务（分类、分割、captioning、检索）上达到 SOTA，支持零样本与文本提示，把病理模型从「看图」推进到「图文对齐」。

↓ 打开 PDF 64 页 · 15.0 MB PMC 全文 Nature Medicine 订阅制；PMC 作者稿渲染（64 页）

2024 **A whole-slide foundation model for digital pathology from real-world data**

901 引用

Hanwen Xu, Naoto Usuyama, Jaspreet Bagga et al ⋯ Hoifung Poon · **Nature** · DOI

1.3B 个 256×256 图像块、171k 张全切片、30k+ 患者、31 种组织；GigaPath 多尺度 ViT 直接建模整张切片，在癌症分类与突变预测等 9 项任务上验证。

↓ 打开 PDF 22 页 · 4.8 MB 出版社版 Nature 混合 OA

2023 **A foundation model for generalizable disease detection from retinal images**

988 引用

Yukun Zhou, Mark A. Chia, Siegfried K. Wagner et al ⋯ Pearse Andrew Keane • **Nature** • DOI

1.6M 无标签视网膜图像自监督预训练；标签高效迁移到眼病与系统性疾病（糖尿病、心血管等），是视网膜影像基础模型的代表，展示「基础模型 + 少量标注」的临床潜力。

↓ 打开 PDF 26 页 • 21.1 MB 出版社版 Nature 混合 OA

DRUG DISCOVERY & MOLECULE GENERATION

药物发现与分子生成 3 篇

可解释性、靶点感知、扩散对接。评价标准从「生成得像」转向「可合成、可验证、有活性」。

这一组的主线：Antibiotic 用可解释 GNN 找到新结构类抗生素并在小鼠验证；TamGen 把 GPT 式化学语言模型接到真实靶点与管线；DiffDock 把对接变成扩散生成问题。

2024 **Discovery of a structural class of antibiotics with explainable deep learning**

463 引用

Felix J. Wong, Erica J. Zheng, Jacqueline A. Valeri et al ⋯ James J. Collins • **Nature** • DOI

可解释图神经网络：39,312 个化合物的活性/细胞毒性数据，预测 1,200 万化合物；发现新的结构类抗生素（对金黄色葡萄球菌有效），并在小鼠感染模型验证，展示「可解释 DL → 新化学空间」。

↓ 打开 PDF 66 页 • 11.2 MB PMC 全文 Nature 订阅制；PMC 作者稿渲染（66 页）

2024 **TamGen: drug design with target-aware molecule generation through a chemical language model**

79 引用

Kehan Wu, Yingce Xia, Pan Deng et al ⋯ Tie - Yan Liu • **Nature Communications** • DOI

GPT 式化学语言模型 + 靶点感知：针对特定蛋白生成与优化分子；在结核病 ClpP 蛋白酶上发现 14 个有抑制活性的化合物，最佳 IC50 1.9 μM，并嵌入真实药物发现管线。

↓ 打开 PDF 12 页 • 1.9 MB 出版社版 Nature Communications 金色 OA

2023 **DiffDock: Diffusion Steps, Twists, and Turns for Molecular Docking** 364 引用

Gabriele Corso, Hannes Stärk, Bowen Jing et al ⋯ Tommi Jaakkola • **arXiv (Cornell University)** • DOI

把分子对接建模为配体自由度（平移、旋转、扭转）流形上的扩散生成；无需传统搜索即可预测结合构象，显著提升 top-1 成功率，开创扩散式 docking 路线。

↓ 打开 PDF 29 页 • 5.7 MB arXiv ICLR 2023 正式版；arXiv 预印本（2022）

BIOMEDICAL LLMS & AGENTS

生物医学大模型与 Agent 4 篇

从「医学问答」到「自主 Agent + 多模态细胞对话」。工具调用、可验证性与临床安全性是关键。

这一组的主线：BioGPT 是早期生物医学生成式 LLM；Med-PaLM 2 把医学问答推到专家级；Biomni 把 LLM 变成能调用工具/数据库/代码的「虚拟生物学家」；CellWhisperer 则让单细胞数据可以用自然语言对话。

2022 **BioGPT: generative pre-trained transformer for biomedical text generation and mining** 1,138 引用

Renqian Luo, Liai Sun, Yingce Xia et al ⋯ Tie - Yan Liu • **Briefings in Bioinformatics** • DOI

在 1,500 万 PubMed 摘要上预训练的生成式 Transformer；支持生物医学文本生成与挖掘（关系抽取、QA），是早期生物医学生成式 LLM 的代表，为后续生物医学 LLM 生态奠基。

↓ 打开 PDF 12 页 • 0.9 MB arXiv Briefings in Bioinformatics 订阅制；arXiv 预印本

2025 **Toward expert-level medical question answering with large language models** 977 引用

Karan Singhal, Tao Tu, Juraj Gottweis et al ⋯ Vivek Natarajan • **Nature Medicine** • DOI

医学 LLM：base 改进 + 医学微调 + ensemble refinement + chain of retrieval；MedQA 最高 86.5%，在 MedMCQA/PubMedQA/MMLU 临床题上大幅提升；医生在 8/9 个临床维度上更偏好其回答。

↓ 打开 PDF 20 页 • 2.7 MB 出版社版 Nature Medicine 混合 OA

2025 **Biomni: A General-Purpose Biomedical AI Agent** 123 引用

Kexin Huang, Serena Zhang, Hanchen Wang et al ⋯ Jure Leskovec · **bioRxiv (Cold Spring Harbor Laboratory)** · DOI

通用生物医学 AI agent：先从数万篇论文中挖掘工具/数据库/协议，构建统一 action space；再用 LLM 推理 + 检索规划 + 代码执行自主完成因果基因排序、药物重定位、罕见病诊断等任务。

↓ 打开 PDF 28 页 · 4.5 MB 预印本 目前仅有 bioRxiv 预印本

2025 **Multimodal learning enables chat-based exploration of single-cell data** 34 引用

Moritz Schaefer, Peter Peneder, Daniel Malzl et al ⋯ Christoph Bock · **Nature Biotechnology** · DOI

单细胞转录组—文本多模态对比嵌入（100 万表达谱 + AI 生成描述）；接入 LLM 实现对话式细胞查询与零样本细胞类型注释，降低单细胞数据解释门槛。

↓ 打开 PDF 25 页 · 4.3 MB 出版社版 Nature Biotechnology 混合 OA

VIRTUAL CELL & OVERVIEW

虚拟细胞与总览 4 篇

虚拟细胞从愿景变成可评测任务；数据（Tahoe-100M）与评测（Cell-Eval）比模型本身更稀缺。

这一组的主线：AIVC 定义了「虚拟细胞」的问题空间；Tahoe-100M 提供了 1 亿细胞的扰动数据；TranscriptFormer 用 12 物种做跨物种生成；SciPhi 则给出 AI4Science 的整体框架。

2024 **How to build the virtual cell with artificial intelligence: Priorities and opportunities** 409 引用

Charlotte Bunne, Yusuf Roohani, Yanay Rosen et al ⋯ Stephen R. Quake · **Cell** · DOI

AI 虚拟细胞的愿景与路线图：多尺度、多模态、可模拟的细胞模型；提出通用表征、预测动力学、可在计算机上做实验的三阶段目标，定义「虚拟细胞」的问题空间与全球协作方式。

↓ 打开 PDF 53 页 · 4.5 MB PMC 全文

Cell 开放获取最终版（PMC12148494）页面打印；内容为最终版，排版非出版社原版（53 页）

2025 **Tahoe-100M : A Giga-Scale Single-Cell Perturbation Atlas for Context-Dependent Gene Function and Cellular Modeling** 107 引用

Jesse M. Zhang, Airol A. Ubas, Richard de Borja et al ⋯ Johnny X. Yu · **bioRxiv (Cold Spring Harbor Laboratory)** · DOI

1 亿细胞、1,100 种小分子、50 个癌细胞系的扰动图谱；Mosaic 平台降低批次效应，是当时最大的单细胞扰动数据集，为扰动预测与虚拟细胞提供数据基础。

↓ 打开 PDF 27 页 · 24.2 MB 预印本 bioRxiv v3；数据集与模型另见 Arc Virtual Cell Atlas

2025 **A Cross-Species Generative Cell Atlas Across 1.5 Billion Years of Evolution: The TranscriptFormer Single-cell Model** 31 引用

James D Pearce, Sara E. Simmonds, Gita Mahmoudabadi et al ⋯ Theofanis Karaletsos · **bioRxiv (Cold Spring Harbor Laboratory)** · DOI

1.12 亿细胞、12 物种、15.3 亿年进化跨度的生成式细胞图谱；联合建模基因身份与表达，零样本跨物种细胞类型分类与疾病状态识别，MIT 许可，工程可用性高。

> Science 2026 正式版；此处为 2025 bioRxiv v2，引用 31 次。

↓ 打开 PDF 37 页 · 5.4 MB 预印本 Science 2026 订阅制；bioRxiv v2 预印本

2023 **Scientific discovery in the age of artificial intelligence** 1,798 引用

Hanchen Wang, Tianfan Fu, Yuanqi Du et al ⋯ Marinka Žitnik · **Nature** · DOI

系统综述 AI 在科学发现中的角色：自监督学习、几何深度学习、生成式模型如何参与假设生成、实验设计与数据解释；讨论数据质量、可解释性与评估，是 AI4Science 的框架性文献。

↓ 打开 PDF 38 页 · 3.2 MB 机构库版 Nature 订阅制；MIT DSpace 机构库版本（38 页）

04 下载与归档：32/32 校验通过

所有可公开获取的全文已下载到 `papers/`，按主题分 7 个目录；文件名统一为「年份_第一作者_短标题.pdf」，便于按字母/年份排序。每篇 PDF 都用 pypdf 校验过页数与可打开性。

目录结构

```
papers/
├── 01_蛋白质结构与生成/ (6 篇, 77.5 MB)
├── 02_基因组与调控/ (5 篇, 107.7 MB)
├── 03_单细胞与转录组/ (6 篇, 86.9 MB)
├── 04_空间与病理影像/ (4 篇, 54.2 MB)
├── 05_药物发现与分子生成/ (3 篇, 18.8 MB)
├── 06_生物医学大模型与Agent/ (4 篇, 12.3 MB)
├── 07_虚拟细胞与总览/ (4 篇, 37.3 MB)
├── MANIFEST.csv 机器可读清单
└── MANIFEST.md 人读清单（含链接）
```

总大小 394.7 MB；单篇最大为 AlphaGenome（67.1 MB，31 页，含高分辨率图）。

校验与命名

- **校验：**32/32 均以 %PDF 开头、pypdf 可打开、页数 > 0；记录 SHA256 前 16 位。
- **命名：**YYYY_FirstAuthor_ShortTitle.pdf，例如 2024_Abramson_AlphaFold3.pdf。
- **清单：**MANIFEST.csv 含标题、作者、年份、来源、DOI、引用量、页数、大小、版本类型；MANIFEST.md 可直接在编辑器里点开 PDF。
- **版本：**出版社版 / 预印本 / PMC 作者稿 / 机构库 / arXiv 五种，PDF 卡片上有颜色标记。

◆ 获取结果

32 篇全部取得可读全文；**0 篇完全失败**。其中 16 篇为出版社/机构库原版 PDF，16 篇为预印本/作者稿/页面打印（原因见下一节）。

注：PDF 总体积约 395 MB，主要来自 Nature/Science 的高分辨率图与 PMC 全文渲染。若只需文字，可用 pdftotext 或 PyMuPDF 提取，不必逐篇打印。

05 版本限制：16 篇不是出版社原版 PDF

「能下载全文」不等于「拿到了出版社原版 PDF」。下面逐条列出这 16 篇的目标版本、实际获取版本与原因，避免后续引用时把预印本当成正式版。

第一作者	论文	目标版本	实际获取	原因 / 说明
Charlotte Bunne	How to build the virtual cell with artificial intelligence: Priorities and opportunities	出版社版	PMC OA 全文	Cell 开放获取最终版（PMC12148494）页面打印；内容为最终版，排版非出版社原版（53 页）
Felix J. Wong	Discovery of a structural class of antibiotics with explainable deep learning	出版社版	PMC 作者稿	Nature 订阅制；PMC 作者稿渲染（66 页）
Renqian Luo	BioGPT: generative pre-trained transformer for biomedical text generation and mining	期刊版	预印本/arXiv	Briefings in Bioinformatics 订阅制；arXiv 预印本
Kexin Huang	Biomni: A General-Purpose Biomedical AI Agent	期刊版	预印本/arXiv	目前仅有 bioRxiv 预印本
Saro Passaro	Boltz-2: Towards Accurate and Efficient Binding Affinity Prediction	期刊版	预印本/arXiv	目前仅有 bioRxiv 预印本，无期刊正式版
Ming Y. Lu	A visual-language foundation model for computational pathology	出版社版	PMC 作者稿	Nature Medicine 订阅制；PMC 作者稿渲染（64 页）
Gabriele Corso	DiffDock: Diffusion Steps, Twists, and Turns for Molecular Docking	期刊版	预印本/arXiv	ICLR 2023 正式版；arXiv 预印本（2022）
Thomas Hayes	Simulating 500 million years of evolution with a language model	期刊版	预印本/arXiv	Science 2025 订阅制；采用 bioRxiv 预印本（正式版可能有差异）
Eric Nguyen	Sequence modeling and design from molecular to genome scale with Evo	出版社版	PMC 作者稿	Science 订阅制；PMC 作者稿渲染（75 页，含参考文献与补充材料）
Rohith Krishna	Generalized biomolecular modeling and design with RoseTTAFold All-Atom	出版社版	Science 页面	Science 订阅制；用公开可访问的 HTML 全文打印为 PDF
Minsheng Hao	Large-scale foundation model on single-cell transcriptomics	期刊版	预印本/arXiv	Nature Methods 订阅制；bioRxiv 预印本
Haotian Cui	scGPT: toward building a foundation model for single-cell multi-omics using generative AI	期刊版	预印本/arXiv	Nature Methods 订阅制；bioRxiv v1（2023-05-01）
Abhinav Adduri	Predicting cellular responses to perturbation across diverse contexts with State	期刊版	预印本/arXiv	Cell 2026 订阅制；bioRxiv 预印本（66 页，含补充材料）
Jesse M. Zhang	Tahoe-100M : A Giga-Scale Single-Cell Perturbation Atlas for Context-Dependent Gene Function and Cellular Modeling	期刊版	预印本/arXiv	bioRxiv v3；数据集与模型另见 Arc Virtual Cell Atlas
James D Pearce	A Cross-Species Generative Cell Atlas Across 1.5 Billion Years of Evolution: The TranscriptFormer Single-cell Model	期刊版	预印本/arXiv	Science 2026 订阅制；bioRxiv v2 预印本
Richard J. Chen	Towards a general-purpose foundation model for computational pathology	出版社版	PMC 作者稿	Nature Medicine 订阅制；PMC 作者稿渲染（81 页）

▲ 引用时的三条建议

① 引用**具体数字/结论**时，优先核对出版社最终版（尤其是预印本之后有修订的：State、TranscriptFormer、ESM3、scGPT）；② 引用**方法/架构**时，预印本通常足够，但需标注「preprint」；③ PMC 渲染版含期刊页眉与参考文献，页码与出版社版不一致，引用页码时不要直接用 PDF 页码。

为什么没有「完全无法下载」的文献？因为本报告在筛选阶段就把「至少有一个公开全文来源」作为软约束；遇到只有订阅版的工作，会用 PMC 作者稿、机构库或预印本替代，而不是放弃。真正没有任何公开全文的候选（如部分厂商技术报告）已在初筛阶段排除。

06 精读路线：三条 Track

32 篇不必按顺序读。下面给三条路线，分别对应「想做结构/设计」「想做基因组/单细胞」「想做应用/系统」的读者。每条路线 8–12 篇，按「先读—再读—精读」排序。

TRACK A · 结构与设计

先读： AlphaFold3 → RFdiffusion
再读： Chroma → RoseTTAFold All-Atom
精读： ESM3 → Boltz-2
关键问题： 共折叠的物理约束从哪来？生成模型如何保证可设计/可合成？亲和力预测能否替代 FEP?

TRACK B · 基因组与单细胞

先读： Enformer → Borzoi → AlphaGenome
再读： Evo → Geneformer → scGPT
精读： scFoundation → UCE → State → CellFM
关键问题： 长序列与单碱基如何兼得？zero-shot 到底输在哪？扰动数据为什么比观测数据更值钱?

TRACK C · 应用与系统

先读： UNI → CONCH → Prov-GigaPath → RETFound
再读： Antibiotic → TamGen → DiffDock
精读： Med-PaLM 2 → Biomni → CellWhisperer → AIVC → Tahoe-100M → TranscriptFormer
关键问题： 基础模型如何进入真实工作流？湿实验验证的闭环怎么建？Agent 的可靠性如何评估?

△ 每篇论文建议只回答三个问题

① 它把什么问题定义成了可学习的问题？② 它的「强基线」是什么，真的赢了吗？③ 它的数据/代码/评测是否足以让你复现一个最小实验？把这三问写在笔记里，比逐段翻译更有效。

07 方法与局限

数据来源

- **元数据/引用：**OpenAlex Works API（DOI 精确匹配；引用量为 2026-10-21 快照）。
- **全文状态：**Europe PMC REST（PMCID、OA 状态、全文链接）、bioRxiv API（版本/日期）、arXiv。
- **PDF 获取：**Nature 出版社 PDF、eScholarship、MIT DSpace、PMC 页面、Science 页面、bioRxiv/arXiv。
- **校验：**pypdf + PyMuPDF 双查页数；文件头 %PDF；SHA256 前 16 位入库。

已知局限

- **引用量有时滞：**2026 年论文（UCE、State、AlphaGenome）引用被严重低估；本报告用「预印本引用 + 社区采用」补充判断，但无法完全消除偏差。
- **年份口径：**以首次公开/预印本为准，部分论文的期刊卷期晚一年（如 Antibiotic 在线 2023、卷期 2024）。
- **覆盖面：**32 篇无法覆盖 AI+生物的全部子领域（如合成生物学、脑机接口、AI 病理之外的影像组学、农业/生态 AI 未纳入）。
- **版本差异：**8 篇为预印本，结论/数字可能与正式版不同；已在第 05 节逐条标注。

检索关键词：protein design、AlphaFold3、ESM3、RFdiffusion、genome language model、Enformer、AlphaGenome、Evo、single-cell foundation model、scGPT、Geneformer、virtual cell、perturbation prediction、pathology foundation model、biomedical AI agent、drug discovery。

08 完整索引：32 个 PDF

按文件夹顺序排列，点击标题可直接打开 PDF。页数与大小为实际文件校验结果。

#	年份	第一作者	标题（点击打开 PDF）	来源	页数	MB	版本
1	2024	**Josh Abramson**	Accurate structure prediction of biomolecular interactions with AlphaFold 3	Nature	24	8.2	出版社版
2	2023	**Joseph L. Watson**	De novo design of protein structure and function with RFdiffusion	Nature	38	34.7	出版社版
3	2023	**John Ingraham**	Illuminating protein space with a programmable generative model	Nature	15	8.1	出版社版
4	2024	**Rohith Krishna**	Generalized biomolecular modeling and design with RoseTTAFold All-Atom	Science	17	8.0	Science 全文
5	2025	**Thomas Hayes**	Simulating 500 million years of evolution with a language model	Science	68	11.5	预印本
6	2025	**Saro Passaro**	Boltz-2: Towards Accurate and Efficient Binding Affinity Prediction	bioRxiv (Cold Spring Harbor Laboratory)	55	7.0	预印本
7	2021	**Žiga Avsec**	Effective gene expression prediction from sequence by integrating long-range interactions	Nature Methods	24	18.2	出版社版
8	2025	**Johannes Linder**	Predicting RNA-seq coverage from DNA sequence as a unifying model of gene regulation	Nature Genetics	34	13.2	出版社版
9	2026	**Žiga Avsec**	Advancing regulatory variant effect prediction with AlphaGenome	Nature	31	67.1	出版社版
10	2024	**Eric Nguyen**	Sequence modeling and design from molecular to genome scale with Evo	Science	75	4.7	PMC 全文
11	2024	**Hugo Dalla-Torre**	Nucleotide Transformer: building and evaluating robust foundation models for human genomics	Nature Methods	20	4.5	出版社版
12	2023	**Christina V. Theodoris**	Transfer learning enables predictions in network biology	Nature	47	6.0	机构库版
13	2024	**Haotian Cui**	scGPT: toward building a foundation model for single-cell multi-omics using generative AI	Nature Methods	36	18.4	预印本
14	2024	**Minsheng Hao**	Large-scale foundation model on single-cell transcriptomics	Nature Methods	25	5.2	预印本
15	2026	**Yanay Rosen**	Universal cell embedding provides a foundation model for cell biology	Nature	25	22.8	出版社版
16	2026	**Abhinav Adduri**	Predicting cellular responses to perturbation across diverse contexts with State	Cell	66	30.3	预印本
17	2025	**Yuansong Zeng**	CellFM: a large-scale foundation model pre-trained on transcriptomics of 100 million human cells	Nature Communications	17	4.1	出版社版
18	2024	**Richard J. Chen**	Towards a general-purpose foundation model for computational pathology	Nature Medicine	81	13.4	PMC 全文
19	2024	**Ming Y. Lu**	A visual-language foundation model for computational pathology	Nature Medicine	64	15.0	PMC 全文
20	2024	**Hanwen Xu**	A whole-slide foundation model for digital pathology from real-world data	Nature	22	4.8	出版社版
21	2023	**Yukun Zhou**	A foundation model for generalizable disease detection from retinal images	Nature	26	21.1	出版社版

#	年份	第一作者	标题（点击打开 PDF）	来源	页数	MB	版本
22	2024	**Felix J. Wong**	Discovery of a structural class of antibiotics with explainable deep learning	Nature	66	11.2	PMC 全文
23	2024	**Kehan Wu**	TamGen: drug design with target-aware molecule generation through a chemical language model	Nature Communications	12	1.9	出版社版
24	2023	**Gabriele Corso**	DiffDock: Diffusion Steps, Twists, and Turns for Molecular Docking	arXiv (Cornell University)	29	5.7	arXiv
25	2022	**Renqian Luo**	BioGPT: generative pre-trained transformer for biomedical text generation and mining	Briefings in Bioinformatics	12	0.9	arXiv
26	2025	**Karan Singhal**	Toward expert-level medical question answering with large language models	Nature Medicine	20	2.7	出版社版
27	2025	**Kexin Huang**	Biomni: A General-Purpose Biomedical AI Agent	bioRxiv (Cold Spring Harbor Laboratory)	28	4.5	预印本
28	2025	**Moritz Schaefer**	Multimodal learning enables chat-based exploration of single-cell data	Nature Biotechnology	25	4.3	出版社版
29	2024	**Charlotte Bunne**	How to build the virtual cell with artificial intelligence: Priorities and opportunities	Cell	53	4.5	PMC 全文
30	2025	**Jesse M. Zhang**	Tahoe-100M : A Giga-Scale Single-Cell Perturbation Atlas for Context-Dependent Gene Function and Cellular Modeling	bioRxiv (Cold Spring Harbor Laboratory)	27	24.2	预印本
31	2025	**James D Pearce**	A Cross-Species Generative Cell Atlas Across 1.5 Billion Years of Evolution: The TranscriptFormer Single-cell Model	bioRxiv (Cold Spring Harbor Laboratory)	37	5.4	预印本
32	2023	**Hanchen Wang**	Scientific discovery in the age of artificial intelligence	Nature	38	3.2	机构库版

配套文件：`papers/MANIFEST.csv`（机器可读）、`papers/MANIFEST.md`（人读）、`README.md`（本目录说明）。

本报告用于个人/团队研究与精读，不构成对论文结论的独立复现。PDF 版权归原作者/出版方所有，请遵守各期刊的许可与合理使用条款；预印本与正式版可能不一致，引用前请核对 version of record。